

# 中国科学技术大学

# 硕士学位论文



## 基于深度学习的中文医学文本 生成任务的隐私保护研究

作者姓名： 揭一新

学科专业： 网络空间安全

导师姓名： 张驰副教授

完成时间： 二〇二三年五月二十七日

University of Science and Technology of China  
A dissertation for master's degree



# **Research on Privacy Protection of Chinese Medical Text Generation Task Based on Deep Learning**

Author: Jie Yixin

Speciality: School of Cyber Science and Technology

Supervisor: Prof. Zhang Chi

Finished time: May 27, 2023

## 中国科学技术大学学位论文原创性声明

本人声明所呈交的学位论文，是本人在导师指导下进行研究工作所取得的成果。除已特别加以标注和致谢的地方外，论文中不包含任何他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的贡献均已在论文中作了明确的说明。

作者签名：\_\_\_\_\_

签字日期：\_\_\_\_\_

## 中国科学技术大学学位论文授权使用声明

作为申请学位的条件之一，学位论文著作权拥有者授权中国科学技术大学拥有学位论文的部分使用权，即：学校有权按有关规定向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅，可以将学位论文编入《中国学位论文全文数据库》等有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。本人提交的电子文档的内容和纸质论文的内容相一致。

控阅的学位论文在解密后也遵守此规定。

☒ 公开   ☐ 控阅（\_\_\_\_年）

作者签名：\_\_\_\_\_

导师签名：\_\_\_\_\_

签字日期：\_\_\_\_\_

签字日期：\_\_\_\_\_

## 摘 要

中文医学文本生成任务在提供医疗服务和传播医疗知识中具有显著价值,但该任务由于其特殊性,相比普通的文本生成任务面临着更大的挑战。首先,医学文本数据的规模有限,且受到严格的法律法规限制,这使得训练出高质量的语言模型面临着挑战。其次,在生成结果的要求上,由于需要保证结果的可解释性、准确性等特点,在保障隐私的前提下,不能牺牲太多的表达能力。最后,在隐私保护方面,医学文本生成任务的隐私保护比普通文本生成任务(如对话、翻译等)更为关键,不仅因为其数据敏感性、法律和道德考量、信任问题等,还因为医学文本中的隐私信息更易被筛选,这使得在训练与推断阶段需要考虑更严格的场景,隐私需求更大。

本研究针对以上问题提出了一种全新的解决方案。首先,本文利用在大规模的中文语料上训练的预训练模型作为基础,然后使用无隐私风险的医学领域专业知识语料进行微调,以增强模型的医学领域表达能力。其次,本文通过多方安全计算的方式,使更多的参与方可以在保护隐私的前提下提供训练数据,从而进一步丰富医学文本生成任务的训练数据,有效缓解了医学数据稀缺性带来的问题。

在隐私保护方面,本研究详细分析了医学文本生成任务的隐私攻击模型,及其对隐私安全的威胁程度,并面向推断阶段的模型反演攻击提出了改进的攻击手段。在训练阶段,本文设计并实现了一种面向 Transformer 结构的,基于可信硬件 Intel SGX 的多方安全计算协议,以确保训练过程的安全性;在推断阶段,本文面向 Transformer 的模型结构在训练阶段设计了选择差分隐私优化器,在推断阶段设计了选择差分隐私解码算法,有效防止了恶意攻击者获取模型训练隐私数据,同时保证了生成结果的准确性和可解释性。由于医学文本中的隐私信息更易被筛选,因此选择差分隐私在此领域的应用更具优势。此外,本文还设计了一个评估生成的医学文本的科学性与准确性的困惑度指标,即“医学文本生成科学性指标”,并在实验中进行了评估,从而证明模型的科学性和严谨性。

本研究首次研究了中文医学文本生成任务的隐私问题,并提出了具有针对性的解决方案。这一成果不仅在理论上深化了对于医学文本生成任务隐私保护问题的理解,也在实践上为该领域的隐私保护提供了有效的策略和工具。

**关键词:** 自然语言处理, 医学文本生成, 差分隐私, 多方安全计算, 深度学习隐私保护

## ABSTRACT

The Chinese medical text generation task holds substantial importance in enhancing healthcare services and disseminating medical knowledge. However, it confronts distinct challenges compared with conventional text generation tasks. Firstly, the need for medical text data, compounded by stringent legal and regulatory constraints, creates a significant hurdle in training superior language models. Secondly, the generated output must ensure interpretability and accuracy while not compromising expressive capacity for privacy protection. Thirdly, privacy protection in medical text generation assumes higher criticality than routine tasks such as chat and translation. This is attributable to data sensitivity, legal and ethical considerations, and ease of filtering private information from medical text. This calls for a stricter approach during the training and inference stages to guard against potential malicious attackers.

To address these issues, we present a novel solution. We begin with a pre-trained model trained from extensive Chinese corpora, followed by fine-tuning step using medical knowledge corpora. This process intends to augment the model’s expressive power in the medical domain. Moreover, our strategy utilizes multi-party secure computation to allow several participants to supply training data while preserving privacy. This significantly mitigates the obstacles posed by the scarcity of medical data.

We present a comprehensive analysis of the privacy attack model in medical text generation tasks to address privacy protection issues, demonstrating its threat to privacy and security. We propose an advanced attack method for the model inversion attacks during the inference stage. At the training stage, we construct and implement a multi-party secure computation protocol for the Transformer-based model to ensure training confidentiality. We deploy Intel SGX to guarantee the integrity of the training process. As for the inference stage, we address a selective differential privacy optimizer and a selective differential privacy decoding algorithm for the Transformer-based model. This deters malicious attackers from accessing or inferencing private training data, concurrently ensuring the accuracy and interpretability of the generated outcomes. Given the ease of filtering private information from medical text, deploying selective differential privacy yields considerable benefits. Furthermore, we introduce a new metric - the "medical text generation scientific index" to assess the scientific and the accuracy of the generated medical text. We validated this index through rigorous experimentation, which substantiates the scientific robustness of our model.

This thesis represents a comprehensive exploration of privacy issues on Chinese medical text generation tasks, providing novel solutions simultaneously. This accomplishment extends the theoretical comprehension of privacy protection issues in medical text generation tasks and provides practical, effective strategies and tools for privacy protection within this domain.

**Key Words:** Natural Language Processing, Medical Text Generation, Differential Privacy, Multi-Party Secure Computation, Privacy-preserving Deep Learning

## 目 录

第 1 章 绪论	1
1.1 研究背景和意义	1
1.1.1 研究背景	1
1.1.2 研究意义	3
1.2 研究现状	4
1.2.1 语言模型的记忆问题	5
1.2.2 基于多方安全计算的医学文本生成任务	6
1.2.3 基于差分隐私的医学文本生成任务	7
1.3 研究内容与创新点	9
1.3.1 研究内容	9
1.3.2 创新点	10
1.4 论文组织结构	11
第 2 章 论文相关基础知识	12
2.1 基于深度学习的自然语言处理	12
2.1.1 自然语言处理的形式化定义及任务描述	12
2.1.2 常见的自然语言处理模型结构	13
2.2 多方安全计算	14
2.2.1 多方安全计算定义	14
2.2.2 多方安全计算的安全性	15
2.3 差分隐私	16
2.3.1 差分隐私定义与性质	17
2.3.2 常见的差分隐私实现	18
2.4 可信硬件 Intel SGX	20
第 3 章 医学文本生成任务的隐私攻击模型研究	22
3.1 引言	22
3.2 语言模型的生成过程与隐私泄露风险	22
3.2.1 分词阶段	22
3.2.2 生成嵌入表示	23
3.2.3 编码过程	24
3.2.4 解码过程	25
3.2.5 损失计算与参数更新	26

3.2.6 隐私泄露风险	26
3.3 语言模型的记忆问题	27
3.3.1 训练样本推断攻击	28
3.3.2 改进的攻击策略	30
3.4 训练阶段推断隐私数据以及破坏训练协议的攻击	32
3.4.1 场景描述与安全假设	32
3.4.2 攻击方式与攻击效果	33
3.5 推断阶段恢复训练隐私数据的攻击	34
3.5.1 场景描述与安全假设	34
3.5.2 攻击方式与攻击效果	34
3.6 本章小结	38
第 4 章 医学文本生成任务训练阶段的隐私保护研究	39
4.1 引言	39
4.2 模型与设计目标	39
4.2.1 系统模型	39
4.2.2 威胁模型与安全假设	40
4.2.3 设计目标	41
4.3 训练协议设计	41
4.3.1 多方安全计算深度学习函数的实现	41
4.3.2 语言模型模块的构建	44
4.3.3 可验证外包计算的设计	46
4.4 安全性分析	48
4.4.1 训练安全	48
4.4.2 SGX 被攻破的影响	52
4.5 实验评估	53
4.5.1 实验设置	53
4.5.2 实验结果	53
4.6 本章小结	55
第 5 章 医学文本生成任务推断阶段的隐私保护研究	56
5.1 引言	56
5.2 隐私保护系统设计与优化策略	56
5.2.1 系统模型	56
5.2.2 威胁模型与设计目标	57
5.2.3 训练阶段隐私保护的关联性分析	57



5.2.4 医学领域特定优化策略与评估指标	57
5.3 基于差分隐私算法的推断结果隐私保护方案	59
5.3.1 选择差分隐私定义	59
5.3.2 针对训练阶段的选择差分隐私优化器	60
5.3.3 针对推断阶段的选择差分隐私解码算法	62
5.4 安全性分析	64
5.5 实验评估	68
5.5.1 攻击方式	68
5.5.2 实验设置	70
5.5.3 实验结果	71
5.6 本章小结	76
第 6 章 总结与展望	77
6.1 工作总结	77
6.2 未来展望	77
参考文献	79
致谢	87
在读期间发表的学术论文与取得的研究成果	88

## 插图清单

图 1.1	研究点及主要研究内容	10
图 2.1	差分隐私算法示意图	17
图 2.2	可信硬件 SGX 飞地的隔离执行示意图	21
图 3.1	基于 Transformer 的模型结构 <sup>[4]</sup>	24
图 3.2	在中文语料上预训练的 GPT2 模型结构	29
图 3.3	针对公开语言模型攻击的结果	29
图 3.4	攻击结果的真实性	30
图 3.5	中文医疗对话数据集示例	34
图 3.6	训练的交叉熵损失随训练步数的变化	36
图 3.7	微调预训练模型的损失随训练轮数的变化	37
图 3.8	模型反演攻击恢复出的训练样本示例	37
图 4.1	面向医学文本生成任务训练阶段的系统概述图	40
图 4.2	各函数间的依赖关系	42
图 4.3	外包计算的协议流程	47
图 4.4	等效模型与原模型的训练损失对比	54
图 5.1	医学文本生成任务推断阶段的系统模型	56
图 5.2	使用无隐私风险数据的微调模式	58
图 5.3	串行处理的选择差分隐私训练优化器	61
图 5.4	选择差分隐私解码算法	63
图 5.5	诱饵插入攻击	69
图 5.6	各模型的诱饵暴露度	74

## 表 格 清 单

表 3.1	模型反演攻击的实验环境 ·····	28
表 3.2	针对预训练模型的模型反演攻击结果 ·····	30
表 3.3	改进的模型反演攻击结果 ·····	32
表 3.4	改进的攻击方式与成功次数 ·····	37
表 4.1	协议的开销分析与实验环境 ·····	54
表 4.2	Transformer 模块的通信开销 ·····	55
表 4.3	使用可验证外包计算的加速效果与输入维度的关系 ·····	55
表 5.1	各训练方式下的模型困惑度比较 ·····	72
表 5.2	各训练方式下的模型的医学文本生成科学性指标比较 ·····	72
表 5.3	不同前缀长度下的语言模型的诱饵暴露度 ·····	73
表 5.4	各模型的诱饵暴露度 ·····	73
表 5.5	各模型的困惑度 ·····	75
表 5.6	各模型的模型反演攻击成功次数 ·····	76

## 第1章 绪 论

本章首先阐述了医学文本生成任务的研究背景和研究意义，并针对现有研究工作的现状进行介绍，从而引出本文的研究内容与创新点，最后介绍本文的组织结构。

### 1.1 研究背景和意义

本节首先介绍医学文本生成任务的基本概念，并对其研究背景和研究意义进行详细说明。

#### 1.1.1 研究背景

医学文本生成（Medical Text Generation）任务是一种针对电子病历（Electronic Health Record, EHR）和临床记录（Clinical Notes）等医学内容的自然语言处理（Natural Language Processing, NLP）技术。近年来，医学文本生成任务在电子病历生成<sup>[1]</sup>、临床记录生成<sup>[2]</sup>以及生成式摘要<sup>[3]</sup>等领域得到了广泛应用。医学文本生成任务旨在利用自然语言生成技术自动生成具有医学背景的自然语言文本，如病历报告、症状描述和医疗建议等。这些文本需要准确表达医学术语、疾病、症状、药物等复杂医学概念，同时具备一定的语法和逻辑性。医学文本生成任务可以辅助医学诊断和治疗，帮助医务人员生成病历和病情报告，提高工作效率，减轻工作负担，同时避免错误和疏漏。此外，医学文本生成还有助于患者理解医学术语和治疗方案，提高患者的医疗健康素养。

在面对医学文本生成任务时，需要从两个关键角度来看待：首先，医学文本在生成任务中的特性与其他类型的文本相比存在显著差异；其次，医学文本生成任务在隐私保护上也有其独特于其他文本生成任务的隐私保护之处。

医学文本在文本生成任务中的特性如下：

- 准确性：由于医学文本需要表达具有深度和复杂性的医学知识，因此生成的医学文本必须具有极高的准确性。任何微小的错误都可能导致严重的后果。此外，医学文本经常使用专业术语和行话，这是一个需要特别处理的问题，因为语言模型可能无法完全理解这些术语的含义。
- 可解释性：医学文本生成任务也需要生成的文本具有高度的可解释性。医生、患者和其他医疗保健工作者需要能够理解并解释生成的医学文本。
- 数据稀缺性：医学文本通常来自专业的医学记录，研究报告，或者其他医学文献，而这些数据源往往对模型训练提供有限的数据。因此，找到足够

的训练数据可能是一个问题。

医学文本生成任务在隐私保护层面的特性如下：

- 数据敏感性：医学数据通常包含个人的健康信息，这是非常敏感的信息，如果被泄露，可能对个人的生活产生严重影响。
- 法律和道德考量：在很多地方，处理和共享医疗数据都受到严格的法律规定。例如，美国的 HIPAA 法规就对医疗信息的使用和共享做出了明确的规定。因此，医学文本生成不仅需要考虑技术问题，还需要考虑法律和道德问题。如果数据被非法使用或泄露，能否追溯到数据的来源和流向。
- 信任问题：在医疗领域，建立和保持患者的信任至关重要。如果医学文本的隐私保护措施不足，可能会破坏患者对医疗机构的信任，从而影响他们接受治疗的意愿。

此外，对于医学文本生成技术的另一个重要方面，便是如何利用最新的语言模型来优化生成结果。

近年来，基于 Transformer<sup>[4]</sup> 及其各种衍生模型<sup>[5-7]</sup> 的语言模型在各类自然语言处理任务中都展现出了卓越的性能。然而，这类模型通常具有庞大的参数量，达到千亿规模。在医学文本生成任务中，考虑到病历和记录中包含大量的患者隐私信息，满足如此规模的数据量对单个医疗机构来说是难以实现的。同时，受到患者隐私需求及各国法律法规<sup>①②</sup> 的限制，数据的收集和共享面临更大的挑战。因此，在保护患者和医疗机构隐私的前提下，训练文本生成模型并提供服务成为了一项重要的挑战。此外，语言模型面临着记忆问题，即语言模型容易记住训练数据中出现的特定内容，并会在推断阶段输出训练数据的部分内容。在医学文本生成任务下，语言模型的使用可能会导致患者隐私泄露的风险。因此，解决语言模型记忆问题亦成为一项紧迫任务。

基于语言模型的医学文本生成任务的隐私保护研究主要关注两种安全问题：一方面是防止执行训练与推断算法的计算方访问数据或模型，通常采用多方安全计算（Multi-party Secure Computation, MPC）或同态加密算法实现；另一方面是防止模型使用者从模型的推断结果恢复出部分训练数据，如根据模型参数或模型推断结果判断特定数据是否在训练集中或重建部分训练数据，通常采用差分隐私（Differential Privacy, DP）技术实现。

在训练阶段，隐私数据面临直接的威胁。由于法律法规限制多个拥有患者隐私文本数据的医疗机构之间的数据收集与共享，现有的研究主要针对两种训练方式，即联邦学习<sup>[8]</sup>（Federated Learning, FL）方式与集中式学习方式。为保护训练数据以及模型参数的隐私，研究者将差分隐私<sup>[9]</sup>、多方安全计算<sup>[10]</sup>、同态

<sup>①</sup>欧盟的《通用数据保护条例》

<sup>②</sup>中国的《关于印发国家健康医疗大数据标准、安全和服务管理办法(试行)的通知》

加密<sup>[11]</sup>与可信执行环境<sup>[12]</sup> (Trusted Execution Environment, TEE) 等隐私保护技术与联邦学习或者集中式学习相结合。这两种学习方式均可使各数据持有者充分利用各方数据进行协同训练。然而, 在 NLP 任务中, 特别是医学文本生成任务中, 各数据持有者 (医疗机构) 的 EHR 文本类型数据通常包含该数据持有者的一些独特特征 (如医生写作风格和数据持有者对原始数据的转换整理方式), 导致各数据持有者的数据非独立同分布。在这种情况下, 联邦学习方式的训练精度较低<sup>[13-15]</sup>。相较于联邦学习方式, 集中学习方式训练的模型精度较高, 但同时面临的隐私风险也会更高, 与此同时, 当前针对集中式学习的隐私保护研究面临着安全假设弱的问题。因此, 在医学文本生成任务的训练阶段, 探究如何保护隐私训练数据以及模型参数具有重要意义。

在推断阶段, 语言模型可能会在无意中泄露训练数据。当前多项研究<sup>[16-19]</sup>证实了语言模型具有记忆性。记忆性是指模型容易记住训练数据中出现的特定内容, 即语言模型可能会推断阶段输出训练数据的部分内容。在给定特定前缀 (Prefix) 时, 语言模型甚至可以逐字逐句地生成原始训练样本。攻击者可以大量枚举多种前缀, 对语言模型执行模型反演攻击来恢复训练数据中的隐私信息。在医学文本生成场景下, 前缀的搜索空间更小, 更容易定制, 如“医生给我开的”和“现在只是稍有点咳嗽”等前缀容易联想到, 攻击者的攻击效率和成功率也会比其他场景更高。因此, 如何在推断过程中有效防止隐私数据泄露, 成为当前亟待解决的重要问题。

此外, 目前开源的中文预训练模型资源有限。现有的预训练模型<sup>[5-6]</sup>的训练语料中英文占比在 80% 以上, 迁移学习效果不理想<sup>[20-21]</sup>。为验证医学文本生成任务的语言模型记忆问题, 还需针对医学文本数据进行微调训练。

### 1.1.2 研究意义

相较于通用文本生成任务, 医学文本生成任务面临着诸多独特挑战。首先, 医学文本具有较强的专业性和逻辑性, 因此生成高质量医学文本需要具备较高表达能力的模型。其次, 医学生成任务相关的文本数据量相对较少, 这使得训练具备高表达能力的模型变得更具挑战性。最后, 与通用文本不同, 在医学文本中, 隐私信息如患者个人信息、诊疗剂量以及医院信息等较易被识别和筛选。因此, 将医学文本生成任务作为一个独立的研究方向是有意义的。

当前已有的相关研究面临诸多挑战。首先, 在训练阶段, 现有采用联邦学习的研究, 由于医学文本数据的非独立同分布性质导致训练精度较低<sup>[13-15]</sup>。而使用集中式学习方式的工作面临的隐私风险更高, 目前针对集中式学习的隐私保护研究面临着安全假设弱的问题<sup>[22-25]</sup>。其次, 在推断阶段, 现有研究采用差分隐私技术<sup>[9]</sup>来保护隐私数据。然而, 对所有数据进行差分隐私处理会导致模型

生成效果较差<sup>[26]</sup>。针对上述问题，本研究的主要意义如下：

- 本文针对医学文本生成任务的训练与推断阶段所面临的攻击进行介绍和分类，并深入分析了各类攻击手段对隐私安全的威胁程度。对于面向推断阶段的模型反演攻击，本研究进一步改进了攻击手段，并在医学文本生成任务的场景下实施了这种改进的攻击，以更好地阐释其潜在的隐私风险。
- 本文借助可信硬件 Intel SGX，设计了一套针对 Transformer 结构的多方安全计算协议，以进行医学文本生成任务的训练。该协议旨在提升安全性假设至恶意攻击者假设，以更好地保护训练数据的隐私。同时，本文还针对可并行计算的部分设计了一个外包计算协议来提升执行效率。为训练医学文本生成模型提供了一种新颖的隐私保护方法。
- 本文基于差分隐私技术，分别针对训练阶段与推断阶段设计了选择性差分隐私优化器与选择性差分隐私解码算法。通过这两种算法，可以在保持较高生成质量的同时，有效地缓解语言模型的记忆问题，防止模型训练中的隐私数据被攻击者获取。此外，为了更好地评估模型在医学文本生成领域的效果，本文设计了一个医学文本生成科学性指标，用以衡量语言模型对于医学专业术语的表达能力，从而提供了更专业、准确的评估标准。

本研究旨在提供一种针对医学文本生成任务的隐私保护方法，通过对训练阶段和推断阶段的隐私保护技术的探讨与改进，为后续研究和实际应用提供了重要的参考和借鉴。本文针对训练阶段中存在恶意参与者的问题，引入多方安全计算与可信硬件 Intel SGX，并设计了一个安全的语言模型训练协议来保护训练数据以及模型的安全；同时为有效缓解语言模型的记忆问题，防止恶意攻击者通过模型反演攻击来获取训练隐私数据，本文引入差分隐私，有效的缓解了语言模型的记忆问题。

本研究的深入分析和实践将有助于提高医学文本生成模型的隐私保护水平，降低数据泄露风险，保障患者隐私，同时不会过多影响模型性能。此外，本研究的成果对于其他涉及敏感数据的自然语言处理任务也具有一定的参考价值，有助于推动隐私保护技术在自然语言处理领域的进一步发展。

## 1.2 研究现状

本节首先介绍语言模型的记忆问题及其带来的隐私风险，随后介绍基于多方安全计算的医学文本生成任务的研究状况，最后分析基于差分隐私的医学文本生成任务的研究进展。

### 1.2.1 语言模型的记忆问题

随着深度学习技术的快速发展，大型语言模型在自然语言处理领域取得了重要突破。例如，GPT<sup>[6-7,27-28]</sup>系列和 BERT<sup>[5]</sup>模型已在多个任务上实现了超越人类的表现，近期的 ChatGPT<sup>[27]</sup>以及 GPT4<sup>[28]</sup>的表现效果更为惊人，似乎有着与人类相同的思考、记忆与表达能力。然而，随着模型规模的扩大，其在学习过程中对训练数据的记忆问题引起了人们的关注。具体而言，语言模型的记忆问题是指语言模型在输出时更倾向于输出在训练样本中出现过的内容，在一定条件下甚至可以逐字逐句地生成完整的训练语句。研究表明，这些语言模型可能会在生成结果中泄露训练数据中的敏感信息。

例如，Gehman 等人<sup>[17]</sup>调查了预训练语言模型在生成带有种族主义、性别歧视或其他有害言语方面存在的问题。作者调查了预训练语言模型在受到特定提示时生成有害言语的程度，并研究了可控文本生成算法在防止生成这种有害言语方面的效果。为了找出这种持续的有害退化的潜在原因，作者对用于预训练多个语言模型（包括 GPT-2）的两个网络文本语料库进行了分析，并发现了大量相同的攻击性、违背事实和其他有害的内容。这些发现证明了语言模型具有记忆性。Nicholas 等人<sup>[16]</sup>研究了私有数据集上训练的大型语言模型可能存在的训练数据提取攻击。攻击者可以通过查询语言模型来恢复单个训练样本。作者在 GPT-2 模型上演示了这种攻击，该模型是基于互联网公开的数据进行训练的。他们成功地从模型的训练数据中提取了数百个逐字逐句完整的文本序列。尽管上述序列中的每一个只出现在训练数据的一个文档中，但攻击仍然可行。作者全面评估了提取攻击，以了解其成功的原因。这些发现表明，更大的模型比较小的模型更易受到攻击。Zhang 等人<sup>[18]</sup>探讨了语言模型在训练过程中可能会记忆敏感信息的问题。作者提出了缺省记忆的概念，它描述了在省略训练过程中的某个特定文档的情况下，模型预测的变化。通过在标准文本数据集中识别和研究缺省记忆的训练样本，作者进一步估计了每个训练样本对验证集和生成文本的影响。Brown 等人<sup>[19]</sup>探讨了自然语言隐私问题的广泛性。作者指出，语言模型往往会记忆训练集中存在的短语，而攻击者可以利用这种倾向来提取训练数据，从而破坏模型的隐私性。作者讨论了常见的数据保护技术（数据清理和差分隐私）所做的假设与自然语言的广泛性之间不匹配的问题，认为现有的保护方法不能为语言模型提供通用且有意义的隐私保护。Mireshghallah 等人<sup>[29]</sup>研究了大型语言模型微调过程中不同微调方法（对整个模型、模型头部和适配器进行微调）的记忆风险，并使用成员推断和提取攻击进行实验。作者的研究表明微调模型头部的风险最高，而微调较小的适配器则不容易受到已知的提取攻击的影响。这对于“预训练和微调”范式的应用具有重要意义。



为了解决语言模型的记忆问题，研究者已经开始探索在训练过程中防止模型记忆敏感信息的方法。其中一种方法是改进模型结构，例如引入注意力机制或使用门控循环单元等，这些改进有助于提高模型处理长序列的能力，从而减少对敏感信息的依赖。另一种方法是优化训练过程，例如使用数据增强、对抗训练和知识蒸馏等技术，这些方法可以提高模型的泛化能力，缓解模型对训练数据的过拟合问题。

因此，语言模型的记忆问题给隐私保护带来了挑战。鉴于此，本文在第3章详细概述了医学文本生成任务在训练和推断阶段所面临的各种攻击，并在第5章基于差分隐私原理设计了隐私保护方法，以缓解语言模型的记忆问题。

### 1.2.2 基于多方安全计算的医学文本生成任务

本部分首先介绍基于多方安全计算的深度学习隐私保护技术，然后阐述目前用于医学自然语言处理任务上的多方安全计算的相关工作。

基于多方安全计算的隐私保护深度学习旨在模拟存在可信第三方的计算过程，使得计算过程不会泄露隐私信息，但是其无法为保护模型参数与推断结果提供隐私保护。最经典的隐私保护机器学习框架是由 Mohassel 和 Zhang 设计的 SecureML<sup>[30]</sup>。该方案是基于两个服务器 Client/Server 的使用秘密共享的外包计算模型。其中，服务器从多个客户端接收以秘密份额形式的数据，并基于 SPDZ 框架<sup>[31]</sup>与混淆电路对秘密份额数据进行隐私训练和预测。与 SPDZ 框架类似，为保证训练与推断的及时响应，SecureML 在离线阶段执行复杂运算，从而使得在线阶段处理效率更高。基于 Wu 等人<sup>[32]</sup>通过量化方法减少隐私保护训练阶段中的精度损失，Agrawal 等<sup>[33]</sup>在半诚实攻击者的场景下，设计了 QUOTIENT 协议。该协议使用加法秘密共享机制和 Yao 混淆电路，实现了随机梯度下降算法和自适应梯度下降算法这两种深度学习模型的训练算法。董业等人<sup>[34]</sup>使用秘密共享机制和 Top-K 梯度筛选方法来保护训练阶段中梯度信息的隐私，并且能够验证服务器聚合结果的有效性。Patra 等人<sup>[35]</sup>基于布尔域、算数域和 Yao 混淆电路域上的混合秘密共享机制设计了 ABY 2，其实现了半诚实攻击者场景下的线性回归和卷积网络的训练。进一步地，Mohassel<sup>[36]</sup>等人提出的 ABY3 在 ABY1<sup>[37]</sup>的框架上将原算法进行了扩展，使用三方计算场景进行训练和评估。其可以在布尔域、算数域和 Yao 混淆电路域之间高效地切换，并可以在半诚实攻击者场景下用在训练线性回归、逻辑回归和神经网络模型上。Wagh 等人<sup>[23]</sup>的算法也基于三方服务器，但其第三方服务器并不与秘密份额交互，其仅用于提供运算辅助数据。Rachuri 等人<sup>[38]</sup>基于结合 ABY3 和第三方服务器，首次实现了在恶意攻击者场景下的安全训练。Shen 等人<sup>[39]</sup>利用量化神经网络（QNN）和 MPC 的优势，提出了 ABNN2，一种实用的安全两方框架，可以实现任意位宽量化神经网络预

测。具体而言，作者提出了一种基于 1-out-of-N OT 扩展的高效且新颖的矩阵乘法协议，并通过并行方案优化该协议。此外，作者还为 ReLU 函数设计了优化协议。Gao 等人<sup>[40]</sup>探讨如何使用基于注意力机制的门控循环单元网络实现隐私保护关系分类。具体而言，作者首先利用多方安全计算为非线性函数（Sigmoid 和 Tanh）设计了三个基本的隐私保护协议。然后，基于这三个基本协议提出了一个用于门控循环单元网络的安全计算协议 SecureGRU。最后，基于 SecureGRU 和注意力机制，作者训练了隐私保护关系分类系统 SecureRC。

目前基于 MPC 用于 NLP 领域的主要工作是 Feng 等人<sup>[22]</sup>提出的隐私保护系统 SecureNLP，其重点针对用于神经机器翻译的基于循环神经网络（Recurrent Neural Network, RNN）的序列到序列注意力模型。具体来说，针对 Sigmoid 和 Tanh 等非线性函数，作者使用 MPC 设计了两个高效的分布式协议，用于在 SecureNLP 中执行各自的任務。作者还证明了这两个协议（即隐私保护的长短时记忆网络 PrivLSTM 和隐私保护的序列到序列转换 PrivSEQ2SEQ）在半诚实攻击者模型下是安全的，即任何诚实但好奇的攻击者不能从他们从其他方接收到的消息中了解到任何其他信息。

然而，RNN 的表达能力存在局限性，要实现更高的表达能力，需要采用基于 Transformer 结构的语言模型。因此，在本文的第 4 章中，本文基于多方安全计算设计了一套适用于 Transformer 结构模型的协议，以满足更高表达能力的需求。

### 1.2.3 基于差分隐私的医学文本生成任务

与上述结构相同，本部分首先介绍基于差分隐私的机器学习隐私保护技术，然后阐述目前用于医学 NLP 任务上的差分隐私的相关工作。

差分隐私技术通过在数据输入、算法迭代或算法输出中添加随机噪声来抵抗成员推断攻击与模型反演攻击。例如 Dwork 等人<sup>[9]</sup>进行特征分解之前，在协方差矩阵中加入对称高斯噪声矩阵，使得输出结果是一个差分隐私的投影矩阵。Hardt 和 Price<sup>[41]</sup>则在算法每次迭代中添加高斯噪声，而协方差矩阵保持无扰动状态，实现一个差分隐私的主成分分析。Abadi<sup>[42]</sup>等人则是在随机梯度下降算法的迭代中引入高斯噪声，实现了深度学习神经网络学习的数据隐私。Wu 等人<sup>[32]</sup>通过对输出数据添加噪声扰动，实现了具有隐私保护的线性回归和决策向量机等二分类模型。以上工作均为数据持有者独立训练采用的隐私保护方法。为实现多源数据集的隐私聚合训练，Papernot<sup>[43]</sup>等人提出，首先利用互相独立的数据集学习教师模型，然后使用这些教师模型对公共数据进行带噪声的预测，最后将预测结果迁移到学生模型的构建。该方法中隐私损失取决于学生模型训练期间向教师模型提出的查询次数，与最终投入实用的学生模型的查询次数无关。梁文娟等

人<sup>[44]</sup>面向数据流 Top-K 频繁模式挖掘, 基于差分隐私, 设计了动态发布过程的数据隐私保护方案。史鼎元等人<sup>[45]</sup>则基于略图数据结构和差分隐私技术, 解决排序学习中的交叉特征生成和缺失标签处理问题。

目前基于 DP 用于 NLP 领域的工作有很多。Bombari 等人<sup>[46]</sup>探讨了训练数据集中实体之间的关系被记忆的问题, 即在使用训练好的模型进行问答时产生隐私问题。作者提出了关系记忆的概念, 并规范化了关系隐私的概念。同时, 作者还提出了差分关系隐私的潜在定义, 用于描述和计算模型的界限。Zhao 等人<sup>[47]</sup>提出了一种名为机密去重训练的训练方法, 用于训练语言生成模型时保护隐私信息。该方法借鉴了差分隐私的思想, 通过随机化部分训练过程来防止意外记忆, 并证明了正确的筛选策略可以增强保密性保证。实验结果表明, 机密去重训练方法在保持强大保密性的同时, 能够获得与无隐私保护的模型几乎相同的困惑度指标。Wu 等人<sup>[48]</sup>提出了自适应差分隐私框架来保护语言模型不泄露隐私信息, 避免了传统差分隐私在所有数据点上的不加区分保护所带来的实用性问题。与需要先验隐私信息的方法不同, 自适应差分隐私基于语言模型估算文本项含有隐私信息的概率, 并根据该概率调整注入差分隐私噪声的程度。作者还提出了一种新的 Adam 算法来实现这一目标。实验结果表明, 自适应差分隐私框架能够有效地提高差分隐私语言模型的保护能力, 防止 Canary 攻击。Shi 等人<sup>[49]</sup>提出了选择性差分隐私, 以提供对敏感数据的严格隐私保护, 以提高模型效用。作者开发了一个相应的隐私机制 DPSGD 优化器, 用于基于 RNN 的语言模型。Bu 等人<sup>[50]</sup>提出了一种差分隐私偏置项微调 (DP-BiTfIT) 算法, 该算法在 DP 算法的最新准确性和标准 BiTfIT 的效率上取得了匹配的表现。DP-BiTfIT 对模型无关 (不修改网络架构), 参数高效 (仅训练约 0.1% 的参数), 计算效率高 (几乎消除了 DP 在时间和空间复杂度上的开销)。具体而言, DP-BiTfIT 仅在微调阶段更新线性层中的偏置项 (bias), 从而实现了以很小的训练开销进行微调。Dinh 等人<sup>[51]</sup>提出了具有上下文感知能力的差分隐私语言模型 (CADP-LM), 它依赖于上下文来定义和检测潜在的敏感信息, 并采用差分隐私来保护敏感信息和表征隐私泄漏。CADP-LM 具有定位和保护敏感句子和上下文的能力, 从而提供了高度准确的隐私模型。此外, 研究还讨论了传统差分隐私机制在应用于大型语言模型时存在的问题, 如模型效用不足和非收敛问题, 并提出了一个针对保护敏感属性的修改版差分隐私概念。

总体而言, 基于差分隐私的医学文本生成任务的相关研究主要关注在保护隐私的前提下如何提升模型的性能和效率, 以及如何运用新的隐私保护概念和算法来应对现有方法的局限性。因此, 本文第 5 章针对训练和推断阶段分别设计了基于差分隐私的训练隐私优化器以及推断解码算法, 以满足这些需求。

## 1.3 研究内容与创新点

本节对本文的研究内容进行介绍，并总结创新之处。

### 1.3.1 研究内容

医学文本生成任务相对于普通文本生成任务而言，对表达能力和逻辑性有更高的要求，因此普通文本通用的 RNN 模型不适用于医学文本任务。本文选择参数量大、表达能力强的 Transformer 模型解决上述问题。同时，本文也考虑了 Transformer 模型带来的记忆问题。综上所述，本文首先分析基于 Transformer 模型的医学文本生成任务在训练和推断阶段分别存在的隐私问题，再分别针对训练和推断阶段存在的隐私风险提出相应的隐私保护方案。

本文的主要研究内容总体框架如图 1.1 所示。

#### (1) 医学文本生成任务的隐私攻击模型研究

本文针对医学文本生成任务在训练和推断两个阶段的攻击场景进行详细的分类，并深入分析了各类攻击手段对隐私安全的威胁程度。本文在训练阶段关注攻击者试图推断隐私数据并破坏训练协议的可能性；在推断阶段，本文考虑攻击者试图恢复训练中的隐私数据的威胁。这部分的深入研究为后续设计有效的隐私保护策略提供了关键的基础。同时，对于面向推断阶段的模型反演攻击，本研究进一步改进了攻击手段，并在医学文本生成任务的场景下实施了这种改进的攻击，以更好地阐释其潜在的隐私风险。

#### (2) 医学文本生成任务训练阶段的隐私保护研究

本文借助可信硬件 Intel SGX，设计了一套针对 Transformer 结构的多方安全计算协议，以进行医学文本生成任务的训练。这个协议旨在提升安全性假设至恶意攻击者假设，以更好地保护训练数据的隐私。同时，本文还针对可并行计算的部分设计了一个外包计算协议来提升执行效率。即使面临恶意攻击者，这个协议也能保证训练的安全性，为训练医学文本生成模型提供了一种创新的隐私保护方法。

#### (3) 医学文本生成任务推断阶段的隐私保护研究

本文基于差分隐私技术，针对训练阶段提出了一种选择性差分隐私优化器，针对推断阶段设计了一个选择性差分隐私解码算法。通过这两种方法，可以在保持较高生成质量的同时，有效地缓解语言模型的记忆问题，防止模型训练中的隐私数据被攻击者获取。此外，为了更好地评估模型在医学文本生成领域的效果，本文特意设计了一个医学文本生成科学性指标，用以衡量语言模型对于专业术语的表达能力，从而提供了更专业、准确的评估标准。

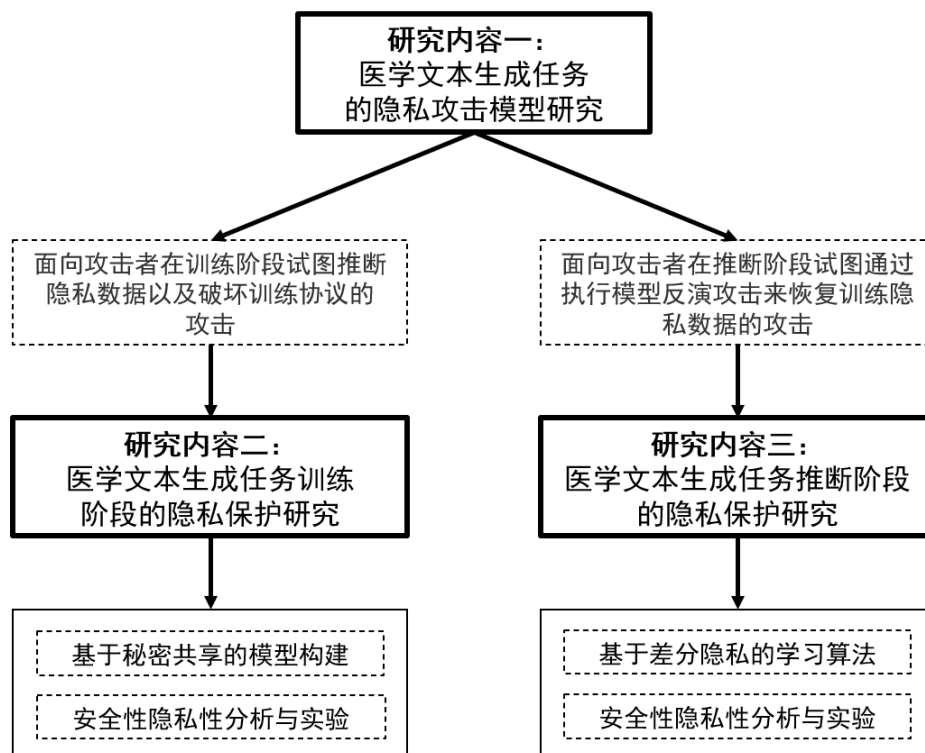


图 1.1 研究点及主要研究内容

### 1.3.2 创新点

本文的主要创新点如下：

- 本研究首次在中文医学文本生成任务中针对推断阶段的模型反演攻击进行改进，并通过实验展示了此改进的有效性。这一贡献揭示了中文医学文本生成任务的潜在隐私风险，且成功地填补了该领域的空白。
- 本文首次基于多方安全计算与可信硬件 Intel SGX，针对基于 Transformer 结构的医学文本生成任务的训练阶段，提出了一种可抵御恶意攻击者的隐私保护协议，并通过设计一个外包计算协议提升其执行效率，为此类任务的隐私保护研究提供了新的策略。
- 本文针对医学文本生成任务的训练阶段与推断阶段分别设计了选择差分隐私优化器与选择差分隐私解码算法。同时还引入了无隐私风险的医学语料用于数据增强。这些算法与数据增强手段是在中文医学文本生成任务中的首次尝试。此外，本文首次提出了医学文本生成的科学性指标，以量化评估语言模型对医学术语的表达能力，为该领域的进一步研究提供了新的评价基准。

## 1.4 论文组织结构

第1章为绪论，介绍了本文的研究背景和意义、相关研究现状、研究内容与创新点、论文组织结构等内容。

第2章为基础知识介绍，介绍深度学习在自然语言处理任务中的应用，多方安全计算和差分隐私这两种在深度学习隐私保护中广泛使用的隐私保护技术，以及可信硬件 Intel SGX。

第3章为医学文本生成任务的隐私攻击模型研究，探讨医学文本生成任务在训练和推断阶段的隐私泄露风险，并分析攻击者在训练阶段推断隐私数据和破坏训练协议的攻击，以及推断阶段攻击者执行的模型反演攻击。同时展示了语言模型记忆问题带来的隐私挑战。

第4章为医学文本生成任务训练阶段的隐私保护研究。该章节设计了基于秘密共享的多方安全计算协议来保障数据机密性，并使用可信硬件保证执行过程的完整性。该协议扩展了基于秘密共享的协议，使得可以构建复杂的 Transformer 语言模型结构，并分析其安全性，验证其有效性和高效性。

第5章为医学文本生成任务推断阶段的隐私保护研究。该章节分别针对训练与推断阶段分别设计了选择差分隐私优化器与选择差分隐私解码算法，并分析证明了它们的安全性。最后，通过设计实验说明了这两种保护方法的优势。

第6章为总结与展望，该章节总结了本文的研究工作，提出了未来的研究方向，并指出了本文所提出的方法在实际应用中的潜在意义和应用前景。

## 第2章 论文相关基础知识

本章将介绍深度学习隐私保护研究的基础知识。具体来说，本章将首先介绍深度学习在自然语言处理任务中的应用，包括任务的定义、常见的模型结构等内容。然后，介绍多方安全计算和差分隐私这两种在深度学习隐私保护中广泛使用的隐私保护技术，包括其定义、性质和常见的实现方式。最后，本文将介绍可信硬件 Intel SGX，它可以为深度学习隐私保护提供一个安全可靠的执行环境。通过本章的介绍，读者可以全面了解本文所涉及的技术基础，并为后续章节的研究工作做好准备。

### 2.1 基于深度学习的自然语言处理

本节将介绍自然语言处理的形式化定义及任务描述与常见的深度学习模型结构。

#### 2.1.1 自然语言处理的形式化定义及任务描述

自然语言处理是一门语言学、计算机科学与人工智能领域的交叉学科，旨在让计算机理解、分析、生成和处理自然语言文本数据。在 NLP 中，文本被视为离散符号序列，记为  $S = (w_1, w_2, \dots, w_n)$ ，其中  $w_i$  表示文本中的第  $i$  个单词或标点符号。为了形式化地描述自然语言处理任务的内容，可以将其定义为从输入序列  $S$  到输出序列  $T$  的映射问题，即  $T = f(S)$ ，其中函数  $f$  根据具体任务的需求进行定义。

在自然语言处理任务中，有许多具体的子任务，如词性标注、命名实体识别、句法分析、语义分析、文本分类、文本摘要、机器翻译、情感分析等。下面将通过一些具体的任务示例来详细描述这些任务的形式化定义：

- 1) 词性标注 (Part-of-Speech Tagging, POS Tagging): 给定一个文本序列  $S = (w_1, w_2, \dots, w_n)$ ，词性标注任务的目标是为每个单词  $w_i$  分配一个词性标签  $t_i$ 。输出序列  $T = (t_1, t_2, \dots, t_n)$ ，其中  $t_i$  表示第  $i$  个单词的词性标签。因此，词性标注任务可以定义为： $T = f_{\text{POS}}(S)$ 。
- 2) 命名实体识别 (Named Entity Recognition, NER): 给定一个文本序列  $S = (w_1, w_2, \dots, w_n)$ ，命名实体识别任务的目标是识别出序列中的命名实体（如人名、地名、组织名等）及其类型。输出序列  $T = (e_1, e_2, \dots, e_m)$ ，其中  $e_i$  表示一个命名实体及其类型。因此，命名实体识别任务可以定义为： $T = f_{\text{NER}}(S)$ 。
- 3) 文本分类 (Text Classification): 给定一个文本序列  $S = (w_1, w_2, \dots, w_n)$ ，文本

- 分类任务的目标是为文本分配一个或多个类别标签。输出  $T = (c_1, c_2, \dots, c_k)$ ，其中  $c_i$  表示一个类别标签。因此，文本分类任务可以定义为： $T = f_{\text{TC}}(S)$ 。
- 4) 文本摘要 (Text Summarization)：给定一个文本序列  $S = (w_1, w_2, \dots, w_n)$ ，文本摘要任务的目标是生成一个较短的文本序列，包含原始文本的主要信息。输出序列  $T = (w'_1, w'_2, \dots, w'_m)$ ，其中  $w'_i$  表示摘要中的第  $i$  个单词或标点符号，且  $m \leq n$ 。因此，文本摘要任务可以定义为： $T = f_{\text{TS}}(S)$ 。
- 5) 机器翻译 (Machine Translation, MT)：给定一个源语言文本序列  $S = (w_1, w_2, \dots, w_n)$ ，机器翻译任务的目标是将其翻译成目标语言文本序列。输出序列  $T = (w'_1, w'_2, \dots, w'_m)$ ，其中  $w'_i$  表示目标语言文本中的第  $i$  个单词或标点符号。因此，机器翻译任务可以定义为： $T = f_{\text{MT}}(S)$ 。
- 6) 情感分析 (Sentiment Analysis)：给定一个文本序列  $S = (w_1, w_2, \dots, w_n)$ ，情感分析任务的目标是判断文本中表达的情感极性（如正面、负面或中性）。输出  $T = (p)$ ，其中  $p$  表示情感极性标签。因此，情感分析任务可以定义为： $T = f_{\text{SA}}(S)$ 。

通过以上描述，可以看到自然语言处理任务涉及多种子任务，每个子任务都可以用一个特定的函数  $f$  来形式化地描述其输入和输出。在实际应用中，根据任务的具体需求，使用者可以选择合适的模型和方法来实现这些函数。

### 2.1.2 常见的自然语言处理模型结构

深度学习技术在自然语言处理领域取得了显著的进展，特别是在文本表示和序列建模方面。以下是一些常见的深度学习模型结构，它们在自然语言处理任务中具有广泛的应用。

- 1) 循环神经网络 (Recurrent Neural Networks, RNN)：RNN 是一种适用于处理序列数据的神经网络结构。它具有内部状态，可以在处理长序列时保留之前时间步的信息。RNN 在词性标注、命名实体识别、机器翻译等任务中有广泛应用。
- 2) 长短时记忆网络 (Long Short-Term Memory, LSTM)：LSTM 是一种特殊的 RNN 结构，它通过引入门控机制来解决 RNN 在处理长序列时的梯度消失和梯度爆炸问题。LSTM 在许多自然语言处理任务中取得了很好的效果，如语言模型、文本摘要、机器翻译等。
- 3) 门控循环单元 (Gated Recurrent Units, GRU)：GRU 是另一种特殊的 RNN 结构，它与 LSTM 类似，但具有更简单的门控结构。GRU 在某些自然语言处理任务中表现出与 LSTM 相近的性能，但计算复杂度较低。
- 4) 卷积神经网络 (Convolutional Neural Networks, CNN)：CNN 是一种广泛应用于计算机视觉领域的神经网络结构。然而，近年来研究发现，CNN 也可



以应用于自然语言处理任务，如文本分类、情感分析等。通过使用一维卷积操作，CNN 可以捕捉文本中的局部特征。

- 5) **Transformer:** Transformer 是一种基于自注意力 (Self-Attention) 机制的神经网络结构。它摒弃了 RNN 和 CNN 中的循环和卷积操作，通过自注意力机制捕捉序列中的长距离依赖关系。Transformer 在诸如机器翻译、语义角色标注和依存句法分析等自然语言处理任务中取得了显著的成果。

## 2.2 多方安全计算

### 2.2.1 多方安全计算定义

多方安全计算技术的研究主要是针对无可信第三方的情况下，多个参与者如何在不暴露己方数据的情况下安全地计算一个约定函数的问题。多方安全计算协议分为信息论安全和密码学安全。如果协议对于拥有无限计算能力的攻击者来说是安全的，那么它被称为信息论安全或无条件安全。如果协议只对拥有多项式计算能力的攻击者是安全的，则称为密码学安全或条件安全。多方安全计算协议的目的是实现一些特定的计算任务。多方安全计算的目的是实现一些特定的计算任务，例如比较、加密、解密、排序、计数、求和等。在多方安全计算中，每个参与方持有自己的输入数据，并且希望在不泄露私有数据的情况下与其他方共同计算结果。

多方安全计算具有以下性质：

- 1) 正确性。采用多方安全计算协议计算的结果与直接使用明文数据计算的结果相同。具体而言，针对输入为  $x$ ，运算法则为  $Q$  的一个多方安全计算协议  $M$ ，有

$$P[M(x, f) = Q(x)] = 1。$$

假设有  $n$  个参与者，分别为  $P_1, P_2, \dots, P_n$ ，他们各自持有输入  $x_1, x_2, \dots, x_n$ ，并希望在不泄露私密输入的情况下计算某个函数  $f(x_1, x_2, \dots, x_n)$ 。多方安全计算协议 (MPC) 是指在参与者之间进行的一系列通信和计算过程，使得每个参与者最终可以获得函数  $f$  的输出，同时不会泄露任何其他参与者的输入。

- 2) 隐私性。任何多方安全计算协议参与方不能获得除协议规定内的额外信息。具体而言，所有参与方  $P = (p_1, p_2, \dots, p_n)$ ，对于参与者  $p_k \in P$ ，使用参与者数据  $F = (f_1, f_2, \dots, f_n)$  输出结果为  $L$  的多方安全计算协议  $M$ ，存在一个可忽略的函数  $\epsilon$ ，有下式成立：

$$P_{p_k}(f_{i, i \neq k} | L = M(F)) + P_k(f_k) \leq P(f_{i, i \neq k}) + \epsilon。$$

### 2.2.2 多方安全计算的安全性

在介绍了多方安全计算的定义后，为理解其安全性，下面介绍多方安全计算场景中不同的安全假设。

- 1) 半诚实 (Semi-honest) 参与者假设：在这种假设下，半诚实的参与者会遵守协议并诚实地执行计算，但他会记录协议执行的上下文来获得更多关于隐私数据的信息。尽管这种安全假设对于参与者的行为作出了相对严格的假设，但在实际场景中仍然相对较强。
- 2) 恶意 (Malicious) 参与者假设：在这种安全假设下，协议不对恶意参与者的行为作任何假设。恶意参与者可以采取偏离、中断或中止协议等手段，从而获取其他参与者的隐私输入信息，因此这种安全假设比半诚实假设更为严格。

现实-理想框架是一种多方安全计算安全性的形式化框架，其使用了一个包含所有安全需求的“理想世界”，通过现实世界与理想世界之间的对应关系定义多方案去计算。

理想世界中，参与方  $P(p_1, p_2, \dots, p_n)$  将各自的输入  $F = (f_1, f_2, \dots, f_n)$  发送给一个可信第三方  $S$ ， $S$  执行函数  $Q$ ，并将计算结果  $Q(F)$  返回给所有参与方。假设存在一个在理想世界中的攻击者  $A$ ，其可以控制除参与方其  $p_k$  外任意数量的参与方  $P_A \subset P$  其中  $p_k \notin P_A$ ，它试图通过各种攻击手段获取  $p_k$  的输入。由于攻击者  $A$  无法控制可信第三方  $S$ ，因此攻击者  $A$  无法获得除  $Q(F)$  外的任何信息。

由于现实世界中不存在上述可信第三方  $S$ ，各参与方需要相互交互以完成计算。在参与方  $p_i$  以其隐私输入  $f_i$ 、当前状态的中间值  $h_i$ 、接收到的所有信息  $Context$ 、随机数  $R_i$ 、安全性参数  $\kappa$  作为输入时，通过执行函数  $\pi_i$ ，获得新的中间值或者输出。

如果攻击者在现实世界达到的攻击效果与其在理想世界的攻击效果相同，那么可以将该协议认为是在现实世界中安全的，即协议使得其在现实世界中提供的安全性与在理想世界中提供的安全性等价。

**定义 2.1** 记  $\pi$  为一个协议， $Q$  为一个函数， $P_A$  为被攻击者  $A$  控制的参与方集合， $Sim$  为仿真算法，定义如下两种协议。

- $Real_{\pi}(\kappa, P_A; f_1, f_2, \dots, f_n)$ : 在安全性参数  $\kappa$  下参与方  $P = (p_1, p_2, \dots, p_n)$  使用各自隐私数据入  $F = (f_1, f_2, \dots, f_n)$  在真实世界执行的协议。记  $V = v_1, v_2, \dots, v_n$  为参与方  $P$  的最终视图，即  $\{v_i | i \in (1, 2, \dots, n)\}$ ;  $y = y_1, y_2, \dots, y_n$  为参与方  $P$  的输出结果。
- $Ideal_{Q, Sim}(\kappa, P_A; f_1, f_2, \dots, f_n)$ : 模拟世界中在安全性参数  $\kappa$  下参与方

$P(p_1, p_2, \dots, p_n)$  使用各自隐私数据输入  $F = (f_1, f_2, \dots, f_n)$  在仿真算法  $\text{Sim}$  与函数  $Q$  的计算下执行的协议，其输出为  $\text{Sim}(P_A, \{(f_i, y_i) \in P_A\})$

在参与方是半诚实的假设下，其会诚实地执行协议，但可能会从接收到的信息中尝试推断更多的信息。

**定义 2.2** 给定协议  $\pi$ ， $Q$  为一个函数， $P_A$  为被攻击者  $A$  控制的参与方集合，如果存在一个为仿真算法  $\text{Sim}$ ，对于攻击者  $A$  控制的所有参与方集合  $P_A$  以及所有的输入  $F = (f_1, f_2, \dots, f_n)$ ，概率分布  $\text{Real}_\pi(\kappa, P_A; f_1, f_2, \dots, f_n)$  与  $\text{Ideal}_{Q, \text{Sim}}(\kappa, P_A; f_1, f_2, \dots, f_n)$  在  $\kappa$  下不可区分，则称此协议在半诚实攻击者的攻击下安全地实现了函数  $Q$ 。

在参与方是恶意的假设下，其不仅会从接收到的信息中尝试推断更多的信息，而且还可以任意破坏、偏离协议。这里使用  $A$  表示攻击程序，用  $\text{Corr}(A)$  表示被现实世界中的攻击者攻陷的参与方集合，用  $\text{Corr}(\text{Sim})$  表示被理想世界中的攻击者  $\text{Sim}$  攻陷的参与方集合。与上述半诚实安全性的方式类似，定义现实世界与理想世界下的概率分布：

- $\text{Real}_{\pi, A}(\kappa; \{x_i | i \notin \text{Corr}(A)\})$ ：在安全性参数  $\kappa$  下，未被攻陷的参与方城市地使用给定的隐私输入执行协议，而被攻陷的参与方  $\text{Corr}(A)$  的信息可以由  $A$  进行篡改，并参与到后续的协议执行过程中。记  $v_i$  为参与方的最终视图，即  $\{v_i | i \in \text{Corr}(A)\}$ ； $y_i$  为诚实参与方  $p_i$  的输出结果，即  $\{y_i | i \notin \text{Corr}(A)\}$ 。
- $\text{Ideal}_{Q, \text{Sim}}(\kappa; \{x_i | i \notin \text{Corr}(A)\})$ ：模拟世界中，在安全性参数  $\kappa$  下，在包含攻陷方输入  $\{x_i | i \in \text{Corr}(A)\}$  的数据上执行  $\text{Sim}$  协议。计算  $(y_1, \dots, y_n) \leftarrow Q(f_1, \dots, f_n)$  后，将  $\{y_i | i \notin \text{Corr}(A)\}$  发送给  $\text{Sim}$ 。记  $V^*$  为  $\text{Sim}$  最终输出，即各参与方的仿真视图集合。

**定义 2.3** 给定协议  $\pi$  与函数  $Q$ ，对任意一个现实世界中的攻击者  $A$ ，存在一个满足  $\text{Corr}(A) \iff \text{Corr}(\text{Sim})$  的仿真者  $\text{Sim}$ ，使得对于诚实参与方的所有输入  $\{x_i | i \notin \text{Corr}(A)\}$ ，概率分布  $\text{Real}_{\pi, A}(\kappa; \{x_i | i \notin \text{Corr}(A)\})$  与  $\text{Ideal}_{Q, \text{Sim}}(\kappa; \{x_i | i \notin \text{Corr}(A)\})$  在  $\kappa$  下不可区分，则称此协议在恶意攻击者的攻击下安全地实现了函数  $Q$ 。

## 2.3 差分隐私

差分隐私<sup>[9]</sup>是一种保护隐私的方法，其基本思想是在不泄露个体信息的前提下，通过添加一定的噪声，使得查询结果的公开不会泄露个体的隐私信息。

### 2.3.1 差分隐私定义与性质

差分隐私是一种保护个人隐私的技术，它可以在不泄露个人隐私的前提下对数据进行分析 and 处理。具体来说，如图 2.1 所示，差分隐私通过限制单条数据对算法输出的影响来保护个人隐私，即无论数据集中是否包含特定个体，算法的输出结果不可区分。这种保护方式确保了即使公开了算法在某个特定数据集上的结果，数据集中的数据仍然受到定量的隐私保护。差分隐私的具体定义如下。

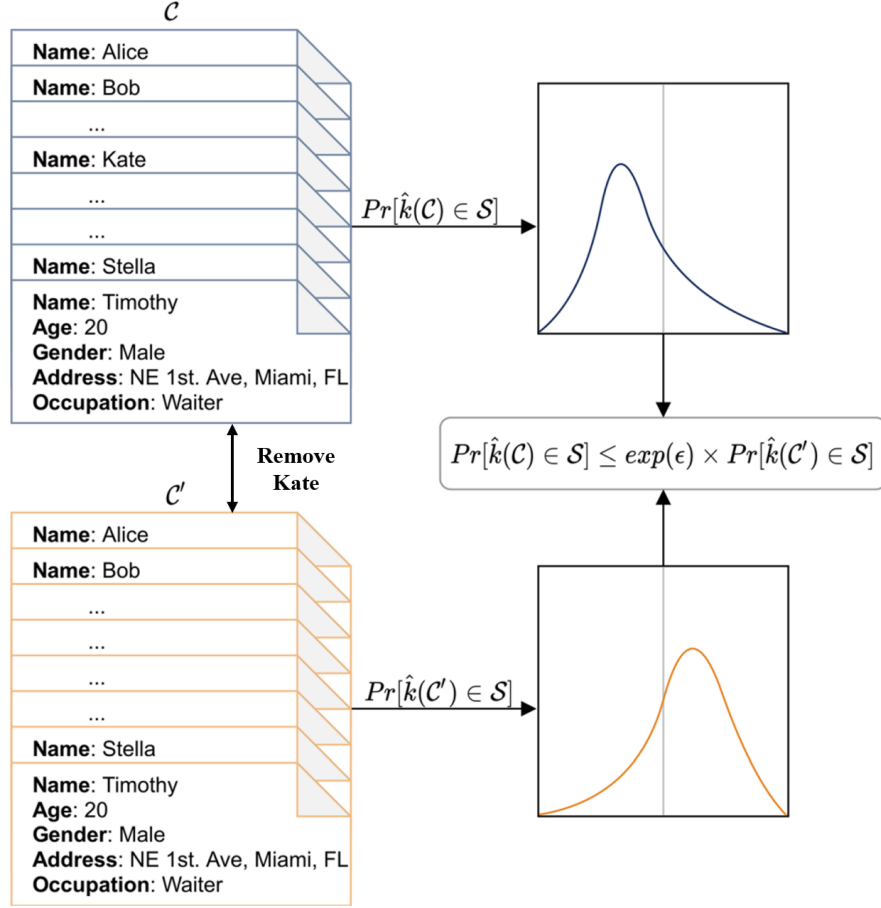


图 2.1 差分隐私算法示意图

**定义 2.4** （近邻数据集<sup>[52]</sup>）若数据集  $D$  与  $D'$  仅有一条记录不同，则称  $D$  与  $D'$  为近邻数据集。

**定义 2.5** ( $\epsilon$ -差分隐私<sup>[52]</sup>) 对于任意近邻数据集  $D$  与  $D'$  以及任意的输出结果  $S$ ，若随机算法  $M$  满足

$$Pr[M(D) = S] \leq e^\epsilon \cdot Pr[M(D') = S], \quad (2.1)$$

则称  $M$  满足  $\epsilon$ -差分隐私。其中  $\epsilon$  表示隐私预算，它是衡量隐私保护程度的指标， $\epsilon$  越小表示算法的隐私保护程度越高，反之  $\epsilon$  越大，算法在近邻数据集的结果之间的差别也越大，隐私保护程度便越低。

式 2.1 的条件在实际场景中往往过于苛刻，导致算法的可用性很差。因此，

可以适当放宽  $\epsilon$ -差分隐私的要求，即松弛一下它的边界，这样就有了  $(\epsilon, \delta)$ -差分隐私。

**定义 2.6** ( $(\epsilon, \delta)$ -差分隐私<sup>[53]</sup>) 对于任意近邻数据集  $D$  与  $D'$  以及任意的输出结果  $S$ ，若随机算法  $M$  满足

$$Pr[M(D) = S] \leq e^\epsilon \cdot Pr[M(D') = S] + \delta, \quad (2.2)$$

则称  $M$  满足  $(\epsilon, \delta)$ -差分隐私。其中  $\epsilon$  同样表示隐私预算，而  $\delta$  为一个概率，算法在  $1 - \delta$  的概率下满足式 (2.1)，即只有至多  $\delta$  的概率不满足式 (2.1)，这便要求  $\delta$  值很小，在数据集样本为  $n$  的情况下<sup>[54]</sup>，需要  $\delta < \frac{1}{n}$ 。 $\epsilon$ -差分隐私可以被视为  $\delta = 0$  的  $(\epsilon, \delta)$ -差分隐私。

下面给出一些形式化定义的定理。

**定理 2.1** <sup>[53]</sup> 若随机算法  $M_1$  满足  $(\epsilon, \delta)$ -差分隐私，则对于任意算法  $M_2$ ，有  $M_2(M_1(\cdot))$  满足  $(\epsilon, \delta)$ -差分隐私。

**证明** 对于  $\forall S \in Range(M_2)$ ，记  $Y = \{y | M_2(y) = S\}$ ，则

$$\begin{aligned} Pr[M_2(M_1(D)) = S] &= Pr[M_1(D) \in Y] \\ &\leq e^\epsilon Pr[M_1(D') \in Y] + \delta \\ &= Pr[M_2(M_1(D')) = S] + \delta \end{aligned}$$

。

**定理 2.2** <sup>[53]</sup> 若随机算法  $M_i$  满足  $(\epsilon_i, \delta_i)$ -差分隐私，其中  $i = \{1, 2, \dots, n\}$ ，则算法  $M(D) = (M_1(D), M_2(D), \dots, M_n(D))$  满足  $(\sum_{i=1}^n \epsilon_i, \sum_{i=1}^n \delta_i)$ -差分隐私。

### 2.3.2 常见的差分隐私实现

差分隐私的实现方法有很多，包括基于噪声的加噪算法、基于随机投影的扰动算法、基于数据扰动的数据变形算法等。其中，添加噪声的加噪算法应用最为广泛，具体包括以下几种方法：拉普拉斯机制<sup>[55]</sup>、高斯机制<sup>[53]</sup>与指数机制<sup>[54]</sup>。下面首先介绍两种全局敏感度的概念，然后一次介绍上述机制的概念。

**定义 2.7** (L1 全局敏感度<sup>[53]</sup>) 对于近邻数据集  $D$  与  $D'$ ，函数  $f$  的 L1 全局敏感度  $\Delta_1 f$  的定义为：

$$\Delta_1 f = \max_{D, D'} \|f(D) - f(D')\|_1. \quad (2.3)$$

**定义 2.8** (L2 全局敏感度<sup>[53]</sup>) 对于近邻数据集  $D$  与  $D'$ ，函数  $f$  的 L2 全局敏感度  $\Delta_2 f$  的定义为：

$$\Delta_2 f = \max_{D, D'} \|f(D) - f(D')\|_2. \quad (2.4)$$

### (1) 拉普拉斯机制

拉普拉斯机制是一种添加噪声的差分隐私算法，它的基本思想是为每个查询结果添加一个服从拉普拉斯分布的噪声，从而保证查询结果的隐私性。

**定义 2.9** （拉普拉斯分布）均值为 0，方差为  $d$  的拉普拉斯概率密度函数为：

$$\text{Laplace}(x, d) = \frac{1}{2d} \exp\left(-\frac{|x|}{d}\right). \quad (2.5)$$

**定理 2.3** （拉普拉斯机制<sup>[56]</sup>）对于任意函数  $f$ ，其 L1 全局敏感度为  $\Delta_1 f$ ，算法  $M = f(D) + \text{Laplace}(\frac{\Delta_1 f}{\epsilon})$  满足  $\epsilon$ -差分隐私。

### (2) 高斯机制

高斯机制是一种添加噪声的差分隐私算法，它的基本思想是为每个查询结果添加一个服从高斯分布的噪声，从而保证查询结果的隐私性。与拉普拉斯机制不同的是，高斯机制引入的噪声值是连续的，并且其分布更加平滑。

**定理 2.4** （高斯机制<sup>[53]</sup>）对于任意函数  $f$ ，其 L2 全局敏感度为  $\Delta_2 f$ ，加上高斯分布噪声的算法  $M = f(D) + N(0, \Delta_2 f \sigma^2)$  满足  $(\epsilon, \delta)$ -差分隐私。其中  $\epsilon < 1$ ，且

$$\delta \geq \frac{4}{5} \exp\left(-\frac{(\sigma \epsilon)^2}{2}\right)。$$

### (3) 指数机制

指数机制是一种添加噪声的差分隐私算法，它的基本思想是将查询结果的隐私性与其“有用性”相平衡，从而选择最优的查询结果。具体地，指数机制会对每个查询结果赋予一个得分值，得分越高表示该结果越有用，然后根据指数分布的概率密度函数从所有结果中以概率  $p_i$  选择结果  $i$ ，其中

$$p_i = \frac{\exp(\epsilon s_i)}{\sum_{j=1}^n \exp(\epsilon s_j)}。$$

上式中  $s_i$  为结果  $i$  的得分值， $\epsilon$  为差分隐私参数，控制查询结果的隐私性和“有用性”之间的平衡。

**定理 2.5** （指数机制<sup>[57]</sup>）可用性函数  $u$  对算法  $M$  在数据集  $D$  上的任何输出数值  $y$  给出一个可用性评估值  $u(D, y) \in \mathbb{R}$ ，若算法  $M$  输出结果  $y$  的概率正比于  $\exp(\frac{\epsilon u(D, y)}{2\delta u})$ ，即

$$\Pr[M(D) = y] = \frac{\exp(\frac{\epsilon u(D, y)}{2\delta u})}{\sum_{y' \in Y} \exp(\frac{\epsilon u(D, y')}{2\delta u})}。 \quad (2.6)$$

其中  $\Delta u = \max_{\{y, D, D'\}} |u(D, y) - u(D', y)|$ ，则算法  $M$  满足  $\epsilon$ -差分隐私。

## 2.4 可信硬件 Intel SGX

可信执行环境是一种在计算机系统中创建的隔离环境，它提供了比普通操作系统更高的安全性和可信度。可信执行环境的目的是保护系统中的敏感数据和代码，以及提供隔离环境来执行受保护的计算，防止恶意软件和攻击者对系统进行攻击和窃取信息。在可信执行环境中，所有的敏感数据和代码都可以得到保护。TEE 提供了一个独立的内存空间，其中的代码和数据与主机操作系统完全隔离，从而可以保护这些数据和代码不受到主机操作系统和其他应用程序的干扰。TEE 还提供了安全的输入和输出通道，使得敏感数据能够安全地进入和离开可信执行环境。在可信执行环境中运行的应用程序必须经过验证和授权才能被允许运行，这样可以防止不受信任的应用程序进入可信执行环境。同时，可信执行环境还提供了追踪和审计功能，用于记录 TEE 中的所有活动，这可以提供重要的证据来追踪和调查安全事件。

Intel SGX 是英特尔公司推出的一种可信计算技术，其目的是提供一种安全的硬件环境，以保护计算机系统敏感数据和代码。Intel SGX 是一种硬件扩展，它通过在处理器中引入特定的安全硬件，创建一种安全的执行环境，可以在这个环境中运行代码和数据，以实现可信计算。Intel SGX 在保护数据和代码时，采用了一种称为“隔离执行”的技术，该技术可以保证数据和代码在安全的执行环境中被隔离开来，从而防止非授权的访问和修改。同时，Intel SGX 还提供了一种特殊的机制，称为飞地 (Enclave)，用于实现在执行环境中运行的应用程序的安全性保护。

### (1) 隔离执行

SGX 安全体系结构保证 Enclave 与其他运行在 Enclave 之外的软件隔离执行，包括操作系统。通过隔离，可以保证 Enclave 控制流的完整性，并且被执行的 Enclave 的内部机密数据不会被任何对手观察到。隔离是通过处理器执行的保护机制实现的。Enclave 的代码和数据存储在称为 EPC(Enclave Page Cache) 的硬件保护内存区域中，该内存驻留在处理器保留内存 (Processor ReservedMemory, PRM) 中，如图 2.2 所示，其中内存加密引擎 (Memory Encryption Engine, MEE) 对 Enclave 中的数据进行加解密，在数据写入内存时加密，在读入 Enclave 时解密。PRM 是动态随机存储器 (Dynamic RandomAccess Memory) 的一个子集，操作系统、应用程序或直接内存访问器都不能访问它。PRM 保护是基于处理器中的一系列内存访问检查，非 Enclave 软件仅允许访问 PRM 范围之外的内存区域，而 Enclave 代码可以访问非 PRM 内存和 Enclave 拥有的 EPC 页面。

### (2) 远程认证

在构建 Enclave 时，Enclave 的测度 (MeasuRement of Enclave, MRE)，即 En-

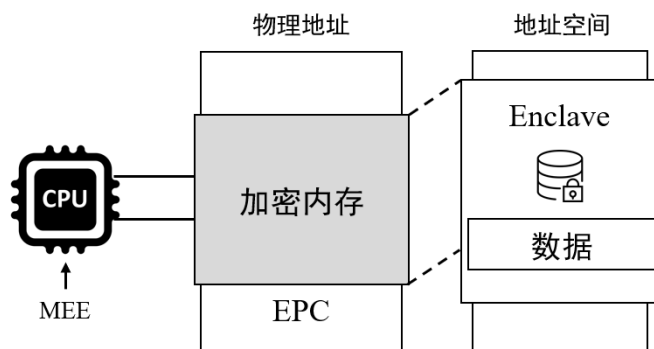


图 2.2 可信硬件 SGX 飞地的隔离执行示意图

clave 初始代码和数据的安全哈希值，由处理器生成，该哈希值保证 Enclave 的完整性。SGX 提供了两种类型的身份认证方式：一种是平台内部 Enclave 间的认证，称为本地认证（Local Attestation）；另一种是平台间的认证，称为远程认证（Remote Attestation）。被认证的 Enclave 通过调用 EREPORT 指令生成报告（Report Structure），EREPORT 是 SGX 提供的一个硬件指令，只有运行在 SGX 平台上的合法 Enclave 才可以调用并生成报告，其中会包含该 Enclave 的测度，其完整性由基于 Intel SGX 硬件产生的密钥保护。

每个 SGX 处理器都有一个根密封密钥（Root Seal Key, RSK），其在制造过程中嵌入，用于生成与 Enclave 身份绑定的密封密钥（Seal Key）。SGX 有一个称为密封的过程，是使用密封密钥加密和验证 Enclave 数据以便持久存储。Enclave 可以使用 EGETKEY 指令从 RSK 派生出密封密钥，并且该密封密钥具有唯一性，即与同一平台的不同 Enclave 或不同平台的任何 Enclave 都不同。



## 第3章 医学文本生成任务的隐私攻击模型研究

### 3.1 引言

为了更好的说明本文所提出的医学文本生成任务隐私保护机制的必要性,本章将详细阐述医学文本生成任务训练的隐私泄露风险以及医学文本生成任务推断阶段的隐私泄露问题。

首先,本章从语言模型的生成过程开始介绍,这一部分阐述了语言模型是如何为自然语言文本建模并生成后续文本的,为后面引入在医学文本生成模型的训练与推断阶段的执行过程做了铺垫。其次,本章针对语言模型的记忆问题进行分析,对公开的预训练模型展开攻击,并且提出了几种改进的攻击策略。随后,本章分析了攻击者在训练阶段试图推断隐私数据以及破坏训练协议的攻击。最后,本章研究了面向攻击者在推断阶段试图通过执行模型反演攻击来恢复训练隐私数据的攻击,以此来探讨医学文本生成任务在训练与推断阶段所面临的攻击,并针对在医学文本数据下训练的语言模型展开攻击,通过实验说明了语言模型记忆问题带来的隐私挑战。

### 3.2 语言模型的生成过程与隐私泄露风险

本部分介绍深度学习语言模型的生成过程,通过从输入数据到输出结果的完整流程来解释前沿 NLP 深度学习模型的构成。

#### 3.2.1 分词阶段

对于本文数据, NLP 使用分词器 (Tokenizer) 将文本按照出现频率的方式切分成独立的词符 (Token), 词符可以是符号、字母、子词、词或者是短语, 比如“我在学习深度学习知识”可以切分成[“我”, “在”, “学习”, “深度学习”, “知识”], “The courtyard is thronged with visitors”可以切分成[“The”, “court”, “yard”, “is”, “th”, “ron”, “ge”, “d”, “with”, “vi”, “sit”, “or”, “s”]。所有词符构成的集合称为词表 (Vocabulary), 其由数据集整体构建。每一个数据持有者拥有一个由  $N$  个句子 (或句对) 构成的文本数据集  $D = \{S_1, S_2, \dots, S_N\}$ , 其中每个句子由  $L_i (i = 1, 2, \dots, n_i)$  个 Token 构成, 且  $S_i = \{t_{i1}, t_{i2}, \dots, t_{iL_i}\}$ 。记由数据集  $D$  建立的大小为  $|V|$  的词表为  $V$ , 则  $t_{ij} \in V$ 。

词表为一个映射, 可以将正整数与字符形式的词符相互转换。假设词表中有“147: ‘啊’”的键值对, 即意味着在分词器处理文本时遇到‘啊’这个字符会把它转换为整数 147, 同样的, 如果模型输出的词表上每个 Token 对应的置信度中

数值最大的 index 是 147，即模型输出的下一个 Token 就是 147，分词器在转换后就会输出 147 所对应的字符‘啊’。在不同的切分方式下，相同的字符可能表示成不同的数。此外，词表一般会有一些特殊字符，比如表示开始的符号“<BOS>”、表示结束的符号“<EOS>”与表示填充的符号“<PAD>”。

NLP 模型的输入是由词表所定义的分词器对句子进行处理后，以整数形式存储的 Tokens 序列，通过字符数字转换过程实现了文本内容的量化表示。具体的切分 Token 的方式有很多，分词的形式也多种多样，从最开始的字切分，词切分，发展到更细粒度的 BPE<sup>[58]</sup>，以及跨语言的 sentencepiece<sup>①</sup>等的切分方法。上述不同细粒度的分词方法是由输入的词表大小以及各个字符出现的频率综合决定的。

在确定了分词方法并将原始的语料通过该方法切分后，得到了词表。分词器会根据词表把数据集的文本内容转换成一个正整数构成的数组，这个过程称为 Tokenizer 的编码过程，同样，正整数组成的数组也可以根据词表由分词器转换成字符，这个过程称为 Tokenizer 的解码过程。

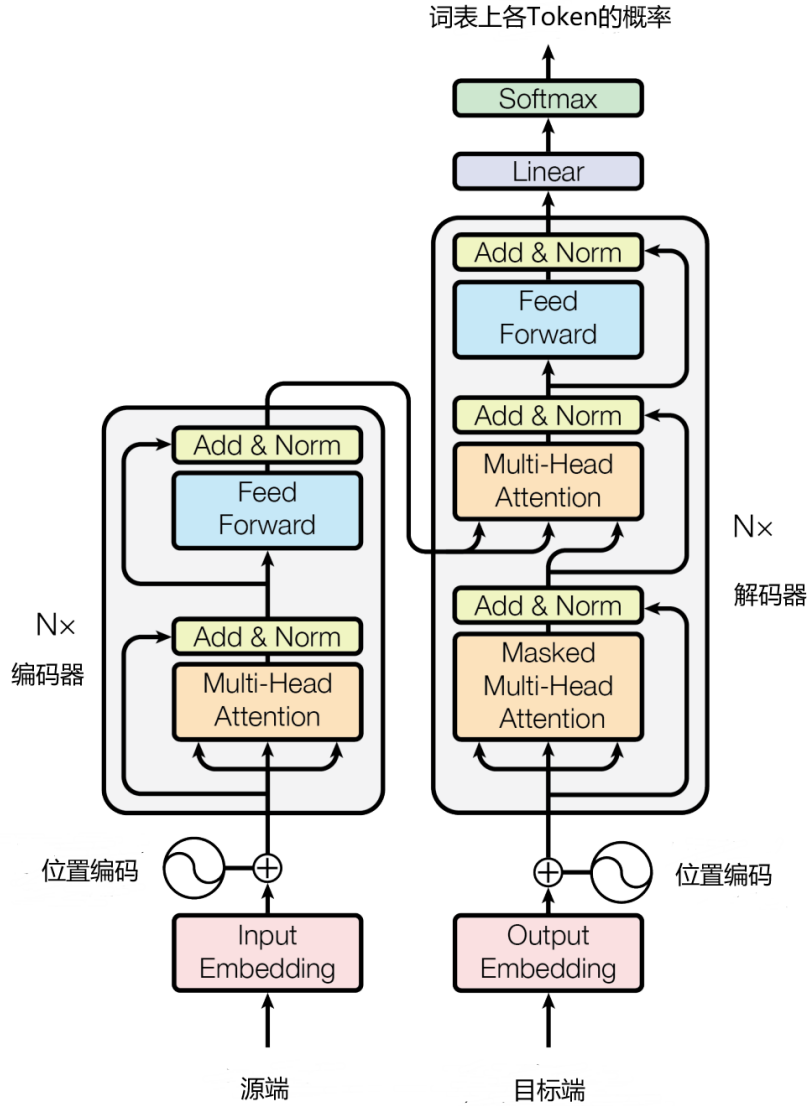
### 3.2.2 生成嵌入表示

为了让字符形式的文本可以让计算机处理，可以通过上述的分词阶段把文本形式的 Token 转换成词表上可以对应的正整数表示。但是一个正整数不能表征整个 Token 的信息，更不能概况整个语义信息。为了丰富表示，可以将每一个 Token 都映射到一个高维向量，通过更复杂的表示带来更好的表达能力，这种高维向量称为 Word Embedding。一般来说，后续要介绍的模型隐层表示维度 hidden\_dim 与 Word Embedding 的维度（后续都简称记为 hidden\_dim）相同，目前最好的模型的 hidden\_dim 通常在 1024 以上。

虽然上述的 Word Embedding 的表达能力提升了，但由于其是固定的，无法更新，因此无法处理这个 Token 在不同语义中的情况。比如，“苹果”这个词（在不同的 Tokenizer 处理下可能是不同的 Tokens）在“我想吃苹果”中表示一种水果，而在“我新买了一个苹果电脑”中表示一个公司的名称。因此，需要根据同序列的其他 Tokens 的信息实时更新 Word Embedding 的表示。这里称更新后的 Word Embedding 为“动态” Word Embedding。

提取动态 Word Embedding 的方式主要是基于 Transformer<sup>[4]</sup>模型，以及在其基础上进行改进的各种变体<sup>[5-7]</sup>。如图 3.1 所示，模型 Transformer<sup>[4]</sup>的结构由两部分组件构成：编码器（Encoder）与解码器（Decoder）。下面两节分别对 Encoder 与 Decoder 进行介绍。

<sup>①</sup><https://github.com/google/sentencepiece>

图 3.1 基于 Transformer 的模型结构<sup>[4]</sup>

### 3.2.3 编码过程

由于同一个 Token 在不同位置表达的含义与对整体语义的影响也是不同的，因此只使用 Word Embedding 表示的信息不够充分，需要引入位置信息，便有了位置编码嵌入（Position Embedding）。本文把 Word Embedding 与 Position Embedding 的结合称为输入嵌入（Input Embedding），作为接下来介绍的编码器的输入。

**编码器：**编码器由  $N$  个完全相同的层堆叠而成。每一层都由两个子层构成，其中第一个子层是一个多路注意力（Multi-Head Attention, MHA）网络，第二子层是一个简单的、位置完全连接的前馈网络（Feed-Forward Network, FFN）。本文对每个子层进行计算的时候，都先经过一个残差连接层（Residual Connection），接着进行层标准化（Layer Normalization, LN）也就是说，每个子层的输出是  $\text{LN}(x + \text{Sublayer}(x))$ ，其中  $\text{Sublayer}(x)$  是由子层本身实现的函数。为了保证这些残差

连接，模型中的所有子层以及嵌入层产生的输出维度都相同。

注意力机制的基本思路是构建一个映射函数来从一组键-值（Key-Value）对中检索出和给定查询（Query）相关的信息，其中查询、键和值都用向量表示。而注意力网络的输出则为值的加权求和，其中分配给每个值的权重由查询与相应键的兼容性函数计算所得。在 Transformer 模型中使用了一种特殊的注意力网络结构，称为缩放点积注意力（Scaled Dot-Product Attention）网络。假设输入的查询  $Q$  和键  $K$  的维度为  $d$ ，值  $V$  的维度为  $d$ ，那么注意力网络的整个过程是先计算查询  $Q$  和每个键  $K$  的点乘操作，并除以  $\sqrt{d}$ ，然后应用 Softmax 函数计算权重，最终通过加权求和得到最终的输出：

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{Q \cdot K^T}{\sqrt{d}}\right) \cdot V。$$

### 3.2.4 解码过程

编码器输出的结果是解码器输入的一部分，解码器另外的输入是与 Input Embedding 生成方式相同的 Output Embedding。解码器每次输出的是目标端各 Token 的“动态”Embedding。取最后一个 Token 的“动态”Embedding，经过一个线性层输出一个大小为词表大小的浮点数数组，记为 Logits，它表示模型输出的词表上每一个词作为下一个 Token 的可能性，通过 Softmax 函数转换为 0 至 1 之间的值以表征概率，选择概率最大值所对应的下标 index 来作为输出，这里的下标值是与词表对应的非负整数，其可以通过 Tokenzier 解码为具体的字符。下面介绍解码器的构成。

解码器：解码器同样由  $N$  个完全相同的层堆叠而成。除了编码器中用到的两个子层之外，解码器还插入了第三个子层，该层对编码器的输出结果执行多路注意力机制，从而来获取代表源语言端的上下文的向量表示。与编码器类似，Transformer 在每个子层先采用残差连接层，然后进行层标准化。由于解码器需要去拟合一个条件语言模型，因此需要在解码器的多路注意力子层中添加一个掩码，以防止每个目标言端的词会直接用到其后面位置的词语信息。这种掩码将输出嵌入偏移一个位置，确保对位置为  $i$  的词的预测只能依赖位置小于  $i$  的已知输出。

解码器每次输出一个 Token，当检测到输出为词表上表示结束的符号“<EOS>”对应的数值时，解码器停止流程，意味着当前解码任务完成，将上面所有解码出来的整数数组通过 Tokenizer 进行解码，即根据词表从数字映射到字符，便得到了最终的文本输出。

### 3.2.5 损失计算与参数更新

前述部分提到，解码器的输出为一个维度为词表大小  $|V|$  的数组 **Logits**，用来表示词表上每个 **Token** 作为下一个 **Token** 的可能性。在训练阶段，由于模型参数是随机初始化的，需要通过训练数据来更新参数表示。对于训练数据中的一个样本  $S = (w_1, w_2, \dots, w_n)$ ，在给定其前缀内容  $S' = (w_1, w_2, \dots, w_i)$  时，将这  $i$  个 **Token** 传入模型，解码器会给出维度为  $|V|$  的数组，作为预测第  $w_{i+1}$  的 **Token**，然而此时模型预测的这个 **Token** 不一定是  $w_{i+1}$ 。这里通过真值  $w_{i+1}$  处的 **Logits** 值，使用 **Softmax** 计算结果的负的对数（即交叉熵损失函数）来表示该场景下的损失函数，以体现模型的预测能力。显然，若模型给出的第  $w_{i+1}$  位置处的 **Token** 的 **Logits** 值越高，其 **Softmax** 后的值越大，则  $-\log(\text{Softmax}(\text{Logits}))$  越小，即损失值越小。有了损失函数，训练阶段通过反向传播来更新模型中的参数。

综上所述，在损失计算与参数更新阶段，首先基于解码器的预测结果与真实值计算损失函数，采用交叉熵损失函数来衡量模型预测能力的好坏。随后，通过反向传播算法来更新模型的参数，以便在后续训练迭代过程中不断优化模型的预测性能。这一过程是训练神经网络的关键部分，为实现高质量的文本生成提供了基础。

### 3.2.6 隐私泄露风险

当 **Embedding** 信息泄露时，恶意攻击者可能会利用这些信息来推断出训练数据的部分或全部内容。在训练过程中，每个单词或短语都会映射到一个高维向量，即 **Embedding** 表示。这些表示包含了训练数据中文本的丰富语义信息，因此可能被用于重构原始文本。

攻击者可以通过比较泄露的 **Embedding** 信息与预先训练好的 **Embedding** 表示来推测出训练数据中的文本内容。此外，攻击者还可以利用机器学习技术来对泄露的 **Embedding** 信息进行聚类分析，以发现训练数据中的潜在模式和关系。这些模式和关系可以用于进一步推断训练数据的隐私信息。

在训练过程中，模型会计算交叉熵损失，用于衡量模型输出与真实标签之间的差异。泄露的交叉熵损失信息可能会被攻击者用来获取训练数据的部分信息。

攻击者可以通过观察泄露的交叉熵损失值来推测训练数据中文本的一些属性，例如文本的长度、复杂度以及与特定主题或领域的关联程度。这些属性可能有助于攻击者进一步推断训练数据的隐私信息。此外，攻击者还可以结合其他辅助信息，如训练模型的参数、结构以及训练过程的元数据，来提高推断攻击的成功率。

### 3.3 语言模型的记忆问题

随着深度学习技术的迅速发展,大型语言模型在自然语言处理领域取得了重要突破。例如,GPT 系列<sup>[6-7]</sup>和 BERT<sup>[5]</sup>模型已经在多个任务上取得了超越人类的表现。然而,随着模型规模的扩大,其在学习过程中对训练数据的记忆问题引起了关注。研究表明<sup>[16]</sup>,这些语言模型可能会在生成结果中泄露训练数据中的敏感信息。下面给出语言模型记忆问题的定义。

**定义 3.1** (模型知识抽取) 如果存在前缀  $c$ ,使得下面的式子成立,则称字符串  $s$  是可从 LM (即  $f_\theta$ ) 中提取的:

$$s \leftarrow \underset{s':|s'|=N}{\operatorname{argmax}} f_\theta(s'|c)。$$

在这里用  $f_\theta(s'|c)$  来表示整个序列为  $s'$  的可能性。由于在大规模的数据集上计算最可能的序列  $s$  是非常困难的,定义 3.1 中的  $\operatorname{argmax}$  可以用一个适当的抽样策略 (例如贪心采样) 来替代,该策略反映了模型  $f_\theta$  在实际应用中是如何生成文本的。

**定义 3.2** ( $k$ -清晰记忆) 如果  $s$  是可以被从 LM ( $f_\theta$ ) 中提取到的,且  $s$  在训练数据  $X$  中最多出现  $k \geq 1$  个示例:  $|x \in X : s \subseteq x| \leq k$ , 那么一个字符串  $s$  是  $k$ -清晰记忆。

这个定义的关键是“示例”的含义。对于 GPT-2,每个完整网页被用作一个训练示例。由于该定义考虑的是包含给定字符串的不同训练示例的数量,而非该字符串出现的总次数,因此一个字符串在同一页中可能出现多次,但仍被视为  $k = 1$  的记忆。

由于 LM 是概率生成模型,本文遵循之前的工作,并使用一种自然的似然度量——困惑度,来评估 LM “预测”序列中 Tokens 的好坏程度。具体地说,

**定义 3.3** (困惑度 (Perplexity)) 对于一个 Tokens 序列:  $(x_1, \dots, x_n)$ , 其困惑度的定义如下:

$$p = \exp\left(-\frac{1}{n} \sum_{i=1}^n \log f_\theta(x_i | (x_1, \dots, x_{i-1}))\right)。$$

上式中的  $f_\theta(x_i | (x_1, \dots, x_{i-1}))$  为在前面  $(x_1, \dots, x_{i-1})$  这些 tokens 的语境下,模型  $f_\theta$  判定下一个 Token 为指定 Token 的概率。由于经过 Softmax 输出后的概率  $0 < p < 1$ , 对其取负对数后变为  $0 < -\log p < +\infty$ , 从前往后对每个 Token 计算上述结果,并取其均值作为结果。因此,如果困惑度较低,则模型对生成的 Token 序列不太“惊讶”(即该序列较为连贯),并为序列中每个 Token 分配了高概率。

### 3.3.1 训练样本推断攻击

#### 1. 攻击描述与设置

本章中的训练样本推断攻击是属于攻击方式中的模型反演攻击。模型反演攻击（Model Inversion Attack）是针对机器学习模型的一种隐私攻击方法。在这种攻击中，攻击者试图通过已知的模型输出（预测结果）以及对模型的访问权限，推断出输入数据的某些敏感特征。该攻击方法侧重于特定个体的敏感信息泄露问题。

模型反演攻击通常分为白盒和黑盒两种场景。在黑盒攻击中，攻击者仅具有有限的模型访问权限，例如仅能使用模型的预测 API。攻击者可以通过探测模型的输入-输出关系，以便从模型的预测结果中提取特定用户的敏感信息。黑盒攻击通常需要攻击者具备一定的辅助信息（如输入数据的部分特征或标签信息），以便构建输入并分析输出。在白盒攻击中，攻击者可以直接访问模型的内部结构、权重和参数。这使得攻击者能够更深入地了解模型的工作原理，并更容易地提取输入数据的敏感信息。白盒攻击通常具有更高的成功率，但在实际场景中，攻击者通常很难获得模型的完整访问权限。

模型反演攻击的成因主要是模型在训练过程中学到了输入数据的某些敏感特征。这些特征可能会用于生成预测结果，从而使攻击者有机会从输出中提取这些特征。

本实验假设恶意攻击者对模型执行黑盒攻击，即攻击者只能从输入与模型的输出关系来推测隐私信息。

#### 2. 实验设置

这里的实验环境如表 3.1 所示：CPU 为 AMD Ryzen 9 5900HX、32GB RAM、GPU 为 RTX3080-Laptop、操作系统为 Windows 11 64 位。

**表 3.1 模型反演攻击的实验环境**

维度	配置
处理器	AMD Ryzen 9 5900HX @ 3.30GHz
内存	32G DDR4 3200Hz
GPU	RTX3080-Laptop 16G VRAM
操作系统	Windows 11 64 位
硬盘	1TB SSD

本节使用的 LM 是 Hugging Face 中的一个中文 GPT2 模型<sup>①</sup>，其参数量为 81.9M，使用的词表大小为 21128，隐层维度为 768。模型由 12 层 GPT2Block 组成，其结构如图 3.2 所示。其中，wte 表示 Word Token Embedding，维度为（词表大小，隐层维度），即为词表上所有 Tokens 的 768 维嵌入表示。另一个初始 Embedding，即 wpe 表示 Word Position Embedding，它表示 Token 的位置编码，维度为（最大

<sup>①</sup><https://huggingface.co/uer/gpt2-chinese-cluecorpussmall>

长度，隐层维度），这里为 1024，表示该语言模型支持最多 1024 个 Token 作为输入。在编码过程中，由 Token Embedding 与 Position Embedding 组合而成的维度为（句子 Tokens 长度，768）的 Input Embedding 通过 12 层 GPT2Block，得到每个 Token 的最终 Embedding。为了输出下一个 Token，最后一个 Token 的最终 Embedding 在通过最后的 `lm_head`，将 768 维的隐层表示映射到词表大小上，以表示语言模型认为词表上每一个 Token 作为下一个 Token 的置信度。

```
GPT2LMHeadModel(
  (transformer): GPT2Model(
    (wte): Embedding(21128, 768)
    (wpe): Embedding(1024, 768)
    (drop): Dropout(p=0.1, inplace=False)
    (h): ModuleList(
      (12x): GPT2Block(
        (ln_1): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (attn): GPT2Attention(
          (c_attn): Conv1D()
          (c_proj): Conv1D()
          (attn_dropout): Dropout(p=0.1, inplace=False)
          (resid_dropout): Dropout(p=0.1, inplace=False)
        )
        (ln_2): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (mlp): GPT2MLP(
          (c_fc): Conv1D()
          (c_proj): Conv1D()
          (act): NewGELUActivation()
          (dropout): Dropout(p=0.1, inplace=False)
        )
      )
    )
    (ln_f): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
  )
  (lm_head): Linear(in_features=768, out_features=21128, bias=False)
)
```

图 3.2 在中文语料上预训练的 GPT2 模型结构

### 3. 攻击结果

本节使用该预训练模型进行解码，其超参数设置如下：温度  $T=0.5$ ，`top_k=20`，`repetition_penalty=5`。当传入的前缀 `prefix` 为“我的手机号是 156”时，采用上述攻击方式得到的部分结果如图 3.3 所示的解码结果。

我的手机号是156051，他们还有一个qq群叫做张小姐。她说：你和老公在外面开了房子住吧？男人  
我的手机号是156112，在线客服也没有回复。这时候她才意识到自己被骗了！因为现实中并不存取  
我的手机号是156229，所以就把他们联系方式告诉了朋友。经过几天交流沟通后得知这个案子已有

图 3.3 针对公开语言模型攻击的结果

下面验证攻击结果的准确性。本节中的攻击方式为黑盒攻击，即攻击者只能从输入与模型的输出关系中推测隐私信息。由于 LM 生成的结果可能包含随机生成的结果。随后对 LM 生成的结果进行筛选，过滤掉其中不符合手机号长度



与字符的生成样本，剩下的即为可能的攻击结果。为了检验生成结果的正确性，第一种验证方式是通过微信添加好友输入生成的结果，若可以检索到用户则为成功，这也是最为强力的验证手段；第二种方式是通过如百度、谷歌等各种搜索引擎检索，若有部分符合区域的前7位段号，则也认为该生成结果是成功的。图3.4为恢复出结果并检验成功的部分样例，具体情况如表3.2所示。



图 3.4 攻击结果真实性

表 3.2 针对预训练模型的模型反演攻击结果

总数	不合规	无效	有效
100	47	24	29

该预训练模型公布于2020年，使用的公开训练数据包含了2019年中文维基百科、2016年的新闻预料、2018年百科问答等<sup>①</sup>以及包含2005-2011年间的74万篇新闻文档的数据集<sup>②</sup>。然而，由于该LM训练语料较早，其中使用到的部分隐私信息可能已过时或不再适用。从本实验结果可以合理推测，使用较新的隐私数据训练的模型可能会面临更大的隐私问题。值得注意的是，此类攻击不仅对公开的预训练模型构成威胁，也会对任何基于语言模型的应用系统产生影响。

### 3.3.2 改进的攻击策略

为了提升模型逆向攻击的成功率，本研究借鉴了相关的研究成果<sup>[16]</sup>，并在此基础上进一步改进了语言模型的攻击策略，旨在验证其对已公开的语言模型攻击的有效性。值得强调的是，相较于上一节描述的基于黑盒访问权限的攻击，这种改进的攻击策略需要具备完全的白盒访问权限，以便实现更深入的攻击手段。

#### 1. 改进的解码方式

执行模型反演攻击时，由于以下语言模型的问题，导致其攻击成功率较低。许多样本被分配了虚假的高概率。这类样本主要有两种：

**琐碎的记忆。**在很多情况下，GPT-2输出的内容是无意义的，因为文本非常

<sup>①</sup>[https://github.com/brightmart/nlp\\_chinese\\_corpus](https://github.com/brightmart/nlp_chinese_corpus)

<sup>②</sup><http://thuctc.thunlp.org/#> 中文文本分类数据集 THUCNews

常见。例如，它以高概率重复从 1 到 100 的数字。

**重复的子字符串。**LM 经常犯的错误是它们倾向于反复生成相同的字符串。很多没有被记忆的高概率样本确实是重复的文本（例如，“我在吃饭。我在吃饭。我在吃饭。……”）。

一个直观的改进想法是通过与第二个 LM 进行比较，过滤掉这些重复（但仍然是高概率的样本）。假设有第二个模型能够准确捕捉文本的置信度，那么它也会给这些记忆内容赋予高置信度。因此，寻找更多样化、更罕见的记忆形式的一个自然策略是，与第二个模型相比，过滤原始模型的置信度“出乎意料地高”的样本。下面本部分将讨论实现这一目标的四种方法。

(1) 与其他 LM 比较。假设有第二个 LM，它记忆的是与原 LM 不同的一组例子。实现这一目标的一个方法是在一组与 GPT-2 训练数据不相交的数据上训练模型，这种情况下两个模型记住相同的  $k$ -清晰记忆概率较小。另一种策略是采取一个小得多的模型在相同的数据集上训练：因为小模型没有较强的记忆能力。因此本部分假设，存在  $k$ -清晰记忆的样本，使得其被大规模的 LM 模型记住，但不被小 LM 模型记住。

(2) 与 zlib 压缩比较。实验中不必与另一个 LM 进行比较。对于给定的序列，任何能赋予序列某种感知程度概念的技术都是有用的。作为一种简单的基线方法，本部分计算文本的 zlib 熵<sup>[59]</sup>：序列用 zlib 压缩时的熵位数。然后，本部分使用原 LM 困惑度和 zlib 熵的比值作为本部分的成员推断度量。虽然文本压缩器很简单，但它们可以识别出上面描述的无意义的重复例子（例如，它们在建模重复子字符串方面非常出色）。

(3) 滑动窗口的困惑度。有时，当样本包含一个记忆的子字符串，周围是一块非记忆（和高困惑度）的文本时，模型给出的置信度不高。为了处理这个问题，本部分取以特定长度 Tokens 为滑动窗口的最小的困惑度作为结果。

(4) 基于衰减温度的采样。如 2.1.1 节所述，给定之前的 Tokens 序列，LM 产生下一个 Token 的概率： $\Pr(x_i|x_1, \dots, x_{i-1})$ 。在实践中，这是通过神经网络  $f_\theta(x_i|x_1, \dots, x_{i-1})$  来得到 Logits 向量  $z$ ，然后计算  $\text{Softmax}(z)$  得到输出概率分布。对于  $t > 1$ ，可以通过将输出  $\text{Softmax}(z)$  替换为  $\text{Softmax}(\frac{z}{t})$  来人为地“压平”这个概率分布，使模型输出的置信度差距不会太大（这里， $t$  被称为温度）。即温度越高，模型的输出越多样化。

然而，在整个生成过程中保持较高的温度意味着，即使采样过程开始发出一个记忆的例子，它也可能会随机偏离记忆输出的路径。因此，使用一种动态衰减的温度可以为模型提供了足够的时间来“探索”一组不同的前缀，同时也允许它遵循它找到的高置信路径。

## 2. 攻击结果

这里实验环境与 3.3.1 相同：CPU 为 AMD Ryzen 9 5900HX、32GB RAM、GPU 为 RTX3080-Laptop、操作系统为 Windows 11 64 位。

实验结果如表 3.3 所示。其中另一个 LM 选择的是原始的 GPT2 模型<sup>[6]</sup>（主要的训练语料是英文），在使用滑动窗口的困惑度解码时滑动窗口的大小设置为 3；使用温度衰减时从  $t = 10$  开始，在前 8 个 Tokens 内线性衰减到  $t = 1$ （由于最关注的输出部分是一开始的 11 位手机号“156XXXXXXXX”，需要 8 位输出），之后保持  $t = 1$ 。

**表 3.3 改进的模型反演攻击结果**

方式	不合规	无效	有效
原始生成	43	28	29
与其他 LM 比较	39	32	29
与 Zlib 压缩比较	41	31	28
使用滑动窗口	36	38	26
使用温度衰减	44	32	24

从表 3.3 可以看出，虽然上述改进的攻击方式的有效比例跟原始的直接生成差别不大，但是从合规的角度，即满足输出的位数是 11 位手机号的形式，这些攻击方式基本都比原始生成要好，这也证明了这些攻击方式可以生成更符合预期推断目的的生成结果。此外，由于人工验证的开销太大，无法执行更大规模的验证，只使用“156”作为开头以及仅 100 条记录的生成结果可能包含很多随机性。

## 3.4 训练阶段推断隐私数据以及破坏训练协议的攻击

### 3.4.1 场景描述与安全假设

在这种场景下，本节假设存在两类实体，一方是拥有医疗隐私数据的多个数据持有者，另一方是提供计算服务的多个计算方。这些数据持有者希望利用计算方提供的服务，协同训练一个模型。计算方在计算服务结束后，将训练好的模型分发给各个数据持有者。

本文遵循常见的安全假设<sup>[22-23]</sup>，认为数据持有者会严格遵循协议提供本地数据，且不会试图推断其他数据持有者的隐私数据，即数据持有者是诚实的。对于计算方，本部分假设它们可能会任意偏离协议，试图从获取的数据中推断数据持有者的隐私信息以及模型参数，即计算方是恶意的。与相关研究<sup>[25]</sup>的设定相同，这种恶意假设是合理且常见的。此外，本文假设多个恶意计算方不会共谋。

### 3.4.2 攻击方式与攻击效果

本部分从两个方向展开分析。首先,本部分讨论针对基于多方安全计算的当前工作所面临的问题;其次,本部分分析引入可信执行环境的相关工作面临的攻击。

当前针对机器学习与深度学习领域的基于 MPC 的相关工作(如 SecureNN<sup>[23]</sup>、SecureNLP<sup>[22]</sup>和 ABY3<sup>[60]</sup>等)可以在半诚实攻击者的安全假设下保障协议的安全性。然而,面对恶意攻击者,不仅可能根据获取到的内容推断更多信息,还可能在执行过程中任意偏离协议,即返回任意非正常结果<sup>[25]</sup>。这意味着在执行过程中,恶意攻击者负责的计算部分可能会遭受破坏,从而导致整个协议的执行过程受到破坏。

为了规范计算方的行为,部分研究集中于使用硬件设备来保护数据隐私以及执行过程的安全。例如, Lee 等人<sup>[61]</sup>提出了一种名为 Occlumency 的创新性云驱动解决方案,旨在在不影响使用强大云资源优势的前提下,保护用户隐私。Occlumency 利用 SGX 的 Enclave 在整个深度学习推理过程中保护用户数据的机密性和完整性。Hua 等人<sup>[62]</sup>提出了一种名为 GuardNN 的安全深度神经网络加速器,它在不受信任的环境中为用户数据和模型参数提供基于硬件的保护。作者通过针对已知的 DNN 加速器内存访问模式定制片外存储器保护,将内存加密和完整性验证的开销降至最低,并在可编程门阵列上进行了原型实现,验证了该方案对推理任务提供了有效的保密性保护。Hashemi 等人<sup>[63]</sup>提供了一个统一的大型深度神经网络的训练和推理框架,旨在在保护输入隐私和计算完整性的同时进行训练和推理。作者提出了一种名为 DarKnight 的方法,它使用一种基于矩阵掩蔽的新颖数据盲化策略,在可信执行环境中创建输入混淆。并通过分析证明了其信息论隐私保证。

尽管上述工作都将可信硬件 Intel SGX 视为一个可信第三方,即其可以提供机密性与完整性,但自 Intel 推出 SGX 以来,各种攻击接踵而至。其中最具代表性的攻击是侧信道攻击,如功耗分析攻击、计时攻击、回滚攻击与缓存冲突攻击等<sup>[64-71]</sup>。这些攻击通常会攻破可信硬件,从而破坏其机密性与完整性。

因此,现有基于多方安全计算的工作在安全假设上存在缺陷,而依赖可信硬件的研究则面临着对硬件信任过强的问题。关于这两类攻击的具体执行方式,已有相关研究详细讨论<sup>[25,64-66]</sup>,故本文不再赘述。针对这两大问题,本文的第四章将提出一个结合可信硬件 Intel SGX 与多方安全计算的新方案,旨在抵御恶意攻击者并限制对可信硬件的信任假设,从而弥补现有工作的不足。

### 3.5 推断阶段恢复训练隐私数据的攻击

本节通过对由原始训练数据训练得到的模型执行模型反演攻击，结果表明模型可能记忆训练数据隐私信息。

首先，本部分介绍场景描述与安全假设。其次，在医学文本生成任务场景下，本节在公开预训练模型基础上通过医学文本数据集微调语言模型，测试针对训练好的模型的训练数据重构攻击效果。最后，本节对上述模型执行 3.3.2 节中相同的改进攻击策略，并通过实验说明这些改进可以从语言模型中抽取更多隐私训练数据。

#### 3.5.1 场景描述与安全假设

在这种场景下，本部分假设有两类实体，一方是模型持有者，另一方是使用模型推断服务的使用方。本文假设模型持有者严格遵循协议执行推断过程，对使用方的假设是其可通过模型推断服务执行模型反演攻击的手段恢复模型训练隐私数据，即模型持有者是诚实的，而使用方是恶意的。

#### 3.5.2 攻击方式与攻击效果

与 3.3.1 节设定相同，本部分考虑针对模型输出结果的恢复训练隐私数据攻击，即执行模型反演攻击。本节考虑攻击者的访问权限是白盒访问权限。

##### 1. 实验设置

本节选择中文医疗对话数据集（Chinese medical dialogue data, CMDD）<sup>①</sup>，包含六个部门的问答句对，如图 3.5 所示。

department	title	ask	answer
心血管科	高血压患者能吃党参吗？	我有高血压这两天女婿来的时候给我拿了些党参泡水喝，您好高血压可以吃党参吗？	高血压病人可以口服党参的。党参有降血脂，降血压的作用，可以彻底消除血液中的垃圾，从而对冠心病以及心血管疾病的患者都有一定的稳定预防工作作用，因此平时口服党参能远离三高的危害。另外党参除了益气养血，降低中枢神经作用，调整消化系统功能，健脾补肺的功能。感谢您的进行咨询，期望我的解释对你有所帮助。
消化科	哪家医院能治胃反流	烧心，打隔，咳嗽低烧，以有4年多	建议你用奥美拉唑同时，加用吗丁啉或莫沙必利或援生力维，另外还可以加用达喜片

心血管科  
消化科

部门  
男科  
内科  
妇产科  
肿瘤科  
儿科  
外科

图 3.5 中文医疗对话数据集示例

本节以 3.3.1 节中的中文预训练模型为基础，在 CMDD 数据集上进行微调训练。实验环境与 3.3.1 相同。

为了微调模型并确保其表达能力，本文对中文医疗对话数据集 (CMDD) 进

<sup>①</sup><https://github.com/Toyhom/Chinese-medical-dialogue-data>

行了适当的预处理。具体来说，CMDD 数据集包含了部分、标题、询问和回答四个字段。本文首先进行数据清洗，包括过滤掉空字段和无关的数字标识等。随后，将每条数据的“标题 + 询问 + 回答”拼接成一条完整的训练语句。

在对数据集进行深入探索后，发现 98% 的训练语句长度小于 320。因此，为了减小模型训练和运算的复杂度，本文将语句长度阈值设定为 320，从而过滤掉长度超过该阈值的样本。同时，为了使模型在各个医学领域内都能均衡地进行学习，避免某一领域样本过多而其他领域样本不足的情况，本文采用了策略确保每个问题类型的样本数量保持一致。

在此基础上，本文筛选出了 7.5 万条符合条件的训练样本。按照 (0.8, 0.1, 0.1) 的比例 (60000, 7500, 7500)，将这些样本分为训练集、验证集和测试集。此后章节的实验均会使用此种划分策略。

本研究的核心目标是深入探索并理解在特定的医学文本数据上进行微调的语言模型的表现，而非只是制定一项通用的策略。在这个背景下，本文特意选择仅在中文医疗对话数据集上进行微调预训练模型，尽管引入医学教科书等域外数据可能有助于弥补医学领域信息的不足，并提高模型的领域适应性。此决策旨在更直观地阐述和探索语言模型在新数据集上微调的记忆性问题，从而深入理解微调过程中的数据敏感性和隐私泄漏风险。然而，在某些情况下，引入额外的领域知识可能有助于提升模型性能。

因此，在第五章，本文将进一步探索额外知识微调的效果。在此环节，本节将比较不同微调策略在性能与隐私保护间的权衡，并深入分析其在实际应用中的可行性和效果。虽然此策略在初步考虑时可能显得有些矛盾，但其目的正是为了提供更全面、更深入的理解，以探索语言模型在处理敏感医学数据时的行为特性和隐私风险，从而在隐私保护方面提供更有价值的见解。

这里实验环境与 3.3.1 相同：CPU 为 AMD Ryzen 9 5900HX、32GB RAM、GPU 为 RTX3080-Laptop、操作系统为 Windows 11 64 位。

本节复用了 3.3.1 节中公开语言模型的词表与模型结构，使用的超参数：训练轮数 `epochs=25`，`warmup_steps=1000`，学习率为  $1e-6$ ，累积梯度 `gradient_accumulation=24`，最大梯度裁剪 `max_grad_norm=3`。训练过程中使用 AdamW 优化器，并且使用 `get_linear_schedule_with_warmup` 的设置。

## 2. 攻击结果

### (1) 正常的生成攻击

实验过程中的每个步骤（模型每通过一个批次的数据训练更新完称为一个步骤）的训练交叉熵损失与推断的交叉熵损失都通过 TensorBoard 的 Summary-Writer<sup>[72]</sup> 进行记录。训练过程中的损失值与步骤之间的关系如图 3.6 所示。从整体来看，训练过程中的损失在开始的 100k 个步骤时下降较明显，但后面变化不

大，整体损失下降的幅度并不大（2.46  $\rightarrow$  1.81）。同时，损失值的波动较大，原因如下：

- 1) 损失下降不多。原始的预训练模型是通过大量各种领域的语料训练收敛的，因此在所有中文语义场景的表达已经有了较好的结果，即在 CMDD 医学对话场景下效果也很好。
- 2) 损失值震荡。由于原始的预训练模型的训练集没有包含很多专门的医学场景语料，因此在医学场景下，如专业名词出现频率低、描述方式较正式、反馈方式独特等特点，模型在某些特殊场景下预测下一个 Token 时可能与实际偏差很大，即 Label Token 的概率很低而损失很大。但是大部分对话的逻辑与预训练模型训练过的模式很接近，即大部分预测的比较好。综上所述，在该特定的医学领域对预训练模型进行微调时，损失值的震荡现象属于正常现象。




图 3.6 训练的交叉熵损失随训练步数的变化

在不同的 Epoch 下，模型在训练集与验证集上的交叉熵损失函数 CrossEntropyLoss 如图 3.7 所示。从图 3.7 中可以看出，在前 15 个 Epoch 中，训练集的损失值稳步下降，后面趋于平稳；而验证集的损失值在前 10 个 Epoch 中稳步下降，后面近乎收敛。在第 6 个 Epoch 时，二者数值近似相等，之后模型更倾向于学习训练集上的数据分布特点，即训练集的损失值要比验证集的损失值低。从训练过程的损失情况来看，本节采用第 10 个 Epoch 的模型参数作为结果，以分析语言模型的记忆性。

## (2) 改进的生成攻击

本实验使用随机采样的 10 个训练数据的前 20 个 Token 作为前缀输入，采用 3.3.1 中的方式分别进行解码，测试其完整恢复训练数据的次数。具体来说，对于每个前缀，本节对上述每个前缀生成 10000 个解码结果，针对其进行平均统计（平均值为分数时向下取整）。




图 3.7 微调预训练模型的损失随训练轮数的变化

例如，当输入前缀为“我弟弟在的那个补习班”（这是训练数据中出现的样本中的前 20 个 Tokens），设置解码长度为 20，即让训练的 LM 生成接下来的 20 个 Tokens。图 3.8 为成功恢复出训练样本的一个实例。



图 3.8 模型反演攻击恢复出的训练样本示例

本实验共产生 10000 个生成样本。将这 10000 个生成结果的前 20 个 Tokens 与原样本的采样后的 20 个 Tokens 进行比较，如果全部相同，则成功恢复次数加一。实验结果如表 3.4 所示。其中与其他 LM 比较的另一个 LM 选择的是原始的 GPT2 模型<sup>[6]</sup>（主要的训练语料是英文），使用滑动窗口的困惑度解码时，滑动窗口的大小设置为 5；使用温度衰减时，从  $t = 10$  开始，在前 10 个 Tokens 的一段时间内衰减到  $t = 1$  ( $\approx$  序列长度的 50%)，之后保持  $t = 1$ 。

表 3.4 改进的攻击方式与成功次数

类型	成功次数
原始生成	14
与其他 LM 比较	19
与 Zlib 压缩比较	14
使用滑动窗口	8
使用温度衰减	10



上述实验攻击出的成功次数较少，而研究工作<sup>[16]</sup>的文中给出的结果相对而言更多，可能的原因如下：一方面，本实验的 LM 参数量较少，只有 81.9M，而文章<sup>[16]</sup>使用的 GPT2-large 为 1.5B 的参数量，更多参数量能够让模型记住更多的信息，这一点在相关文献中得到证实<sup>[5-7,73-75]</sup>；另一方面，本实验的训练语料较少，LM 还没充分的学到医学文本生成场景下的特点，导致其困惑度仍较高。

### 3.6 本章小结

本章探讨医学文本生成任务在训练和推断阶段中的隐私泄露风险，以证明隐私保护机制的必要性。首先，本章详细介绍了语言模型的生成过程，为后续分析医学文本生成模型的训练与推断阶段的执行过程奠定了基础。接着，本章分析了语言模型的记忆问题，进行了攻击实验并提出改进的攻击策略。同时，本章还探讨了攻击者在训练阶段尝试推断隐私数据以及破坏训练协议的可能攻击手段。最后，本章阐述了攻击者尝试通过执行模型反演攻击来恢复训练隐私数据的攻击。通过针对在医学文本数据下训练的语言模型展开的攻击，说明了语言模型记忆问题带来的隐私挑战。本章的内容强调了隐私保护在医学文本生成任务中的重要性。

## 第4章 医学文本生成任务训练阶段的隐私保护研究

### 4.1 引言

本章主要针对医学文本生成任务训练阶段的隐私问题，旨在设计并实现一种能够有效抵抗恶意攻击者的安全协议，以保护医学文本数据在训练阶段的隐私。首先，本章明确了模型与设计目标，在阐述了系统模型与威胁模型的基础上提出了安全目标。随后，本章扩展了基于加法秘密共享的协议，使其能够适配 Transformer 的复杂结构，从而保护数据的机密性。为确保执行过程的完整性，本章引入 SGX，同时为提高计算效率，针对可并行计算的矩阵乘法部分，本章设计了一个高效的外包计算协议。随后，本章进行了协议安全性的分析，并通过理论证明验证其能满足设计目标。最后，本章通过实验证明了该协议的有效性和高效性。

### 4.2 模型与设计目标

#### 4.2.1 系统模型

在这种场景下，本章假设有两类实体，一类是多个拥有医学文本数据（患者医疗隐私数据）的数据持有者，另一类是提供计算服务的三个计算方。多个数据持有者希望通过多个计算方提供的计算服务来协同训练模型，计算方在计算服务结束后将训练好的模型分发给各个数据持有者。其中作为提供计算服务的三个计算方  $p_0$ 、 $p_1$  与  $p_2$  均具有 Intel SGX，且  $p_0$  与  $p_1$  具有高性能计算 GPU 或者 TPU（后文均以 GPU 指代）。如图 4.1 所示，其中①表示多个数据持有者通过秘密共享机制<sup>[76-77]</sup>将数据拆分成两个秘密份额分发给服务器  $p_0$  与服务器  $p_1$ 。②表示在服务器  $p_2$  提供的相应 MPC 计算随机数的辅助下，服务器  $p_0$  与服务器  $p_1$  运行 MPC 协议来执行模型的训练过程。③表示训练结束后，服务器  $p_0$  与服务器  $p_1$  将各自的模型参数份额返还给各数据持有者。本章只关注训练过程中隐私数据的安全性问题。

在将本研究应用于医学文本生成任务的具体场景时，本章依托于预训练模型在医学文本数据上进行微调。所使用的预训练模型是基于广泛的中文语料进行训练的通用模型，包含了各种领域的常见数据。由于医学文本数据在总量上相对较小，为了避免微调过程中的过拟合问题，同时最大限度地利用预训练词嵌入的优势，本章决定在微调阶段固定预训练的词嵌入。这意味着在接下来的实验中，3.2.2 节中所述的 Word Embedding 在微调过程中将保持不变。

此外，鉴于预训练模型的词表涵盖了各种领域，而医学文本领域的特有词汇

在该词表中也可找到对应的 Token，因此本章无需为医学文本重构词表，而是直接复用预训练模型的词表（词表大小为 21128）。

特别地，以医学问答模型的训练场景为例，假设存在多个数据所有者（例如医院），每一方都拥有一份本地医学文本数据集。为了实现协同训练，每个数据所有者首先根据模型的词表将自己的数据集进行切词，整理成 Token 数据集。然后，根据预训练模型的 Word Embedding 将这些 Token 转化为完整的词嵌入。接着，通过秘密共享机制，将词嵌入拆分成秘密份额，然后分发给各计算方服务器。同时，初始预训练模型也根据秘密共享机制被拆分，并存储在两个计算方服务器上。在第三个服务器提供辅助计算的情况下，两个计算方服务器根据各自的词嵌入份额通过执行设计的计算协议进行一次模型前向计算。数据所有者接着根据两个计算方服务器的计算结果进行重构，并依据本地的真实值计算出损失，再根据此损失更新计算方服务器上的参数。

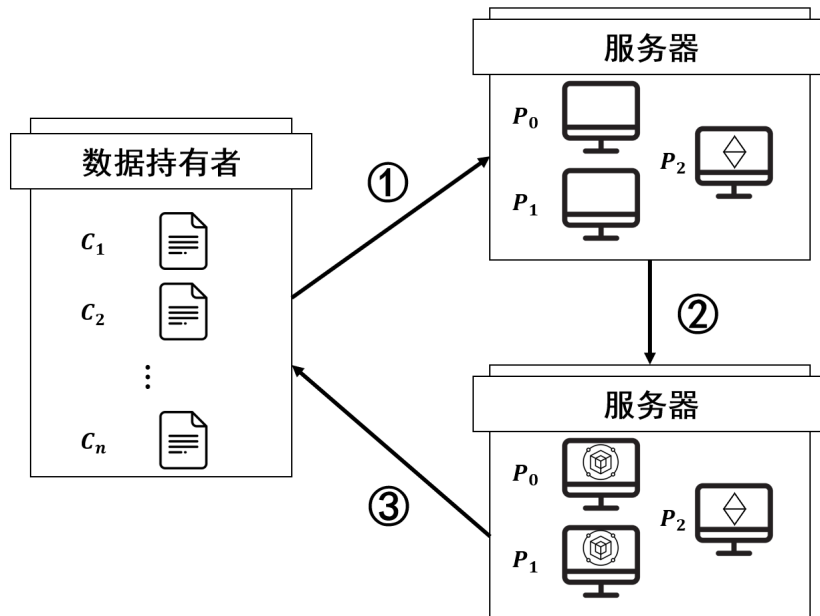


图 4.1 面向医学文本生成任务训练阶段的系统概述图

#### 4.2.2 威胁模型与安全假设

本文对该场景下数据持有者的安全假设是其会严格遵循协议提供本地数据并且不会推测其他数据持有者的隐私数据，对计算方的安全假设是其可以任意偏离协议并且会从获取到的数据推断数据持有者的隐私信息以及模型参数，即数据持有者是诚实的，而计算方是恶意的。计算方服务器不仅会根据获取到的信息来推测隐私数据，而且还会任意偏离协议，即在协议执行过程中返回恶意结果。此外，本文假设多个恶意计算方不会共谋。为规范服务器行为，本章引入可信硬件来保障执行过程的完整性。具体来说，本文引入 Intel SGX<sup>[78]</sup>作为可信硬件。相关研究将 SGX 视为一个可信第三方，即其机密性与完整性都不被破坏，这

样的信任假设过强。由于测信道攻击等攻击手段可能会破坏 SGX 的机密性<sup>[79]</sup>，因此直接将 SGX 作为一个可信第三方有风险。本协议只关注 SGX 中 Enclave 与 GPU 交互数据时由于访问模式导致的侧信道信息泄露问题，而如缓存冲突攻击、计时攻击和工号分析攻击的其他相关侧信道攻击均不在本方案考虑范围内。本协议对计算方上 SGX 的信任假设较弱，即其机密性可以被破坏但是会保留其完整性，这是一种对可信硬件常见的安全假设<sup>[25]</sup>。对计算方上 GPU 的安全假设是其执行内容对服务器可见，但是执行协议不会被破坏。

### 4.2.3 设计目标

对该场景下的安全目标是数据持有者的隐私数据不会被计算方推断出，同时计算方会按照约定的协议严格执行训练过程。

## 4.3 训练协议设计

本节从基于秘密共享的基本神经网络函数的构建入手，逐步拓展至用于实现大型语言模型模块的构建和封装。

### 4.3.1 多方安全计算深度学习函数的实现

Transformer 模型包含线性运算与非线性运算。线性层（Linear Layer）、全连接层（Fully Connected Layer）、卷积层（Convolutional Layer）本质都是矩阵乘法运算，这是神经网络模型中最经常被用到的运算。模型经常会把这些层通过一些比如 ReLU、Sigmoid、Exp 等激活函数进行非线性处理。因此，为了构建常见的神经网络模型结构，本文对于这些线性与非线性函数进行了设计。其中，线性运算是矩阵乘法运算。

本文的非线性运算有 ReLU、Softmax。其中<sup>[23][80]</sup>中已经有了 ReLU、Tanh、Sigmoid 的实现，本章将利用这些函数以及参考<sup>[81]</sup>中的 Trunc、BitDecomp 与 PreMult 函数的实现来构建 Exp 与 Softmax 的实现。其中各函数的调用关系如图 4.2 所示，标记为红色的是构建模型的主要函数。

算法 4.1 描述了本文的三方矩阵乘法协议（ $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$ ），其中参与方  $P_0$  和  $P_1$  持有矩阵  $X$  和  $Y$  的秘密份额，协议输出  $Z = X \cdot Y$  的秘密份额。算法 4.3 描述了本文的三方 Exp 协议（ $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$ ），其中参与方  $P_0$  和  $P_1$  持有矩阵  $X$  的秘密份额，协议输出  $Z = e^X$  的秘密份额。有了 Exp 协议便可以根据其来构建 Softmax 协议。如算法 4.4 所示，本文的三方 Softmax 协议（ $\Pi_{\text{Softmax}}(\{P_0, P_1\}, P_2)$ ）中，参与方  $P_0$  和  $P_1$  持有序列  $Z$  的秘密份额，协议输出  $Z = e^{z_i} / (\sum_{i=1}^k e^{z_i})$  的秘密份额。




图 4.2 各函数间的依赖关系

**算法 4.1**  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$ 

**输入:**  $P_0$  与  $P_1$  分别持有  $(\langle X \rangle_0, \langle Y \rangle_0)$  和  $(\langle X \rangle_1, \langle Y \rangle_1)$ ,  $X$  是  $m \times v$  的,  $Y$  是  $v \times n$  的

**输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得输出的秘密分片  $\langle X \cdot Y \rangle_i$ .

- 1  $P_0$ 、 $P_1$  分别获得从  $P_2$  产生的  $U_0 = \langle 0^{m \times n} \rangle_0^L$  和  $U_1 = \langle 0^{m \times n} \rangle_1^L$
- 2  $P_2$  生成随机的矩阵  $A \in Z_L^{m \times v}$  和  $B \in Z_L^{v \times n}$ , 并计算  $C = A \cdot B$ 。对于  $i \in \{0, 1\}$ ,  $P_2$  将  $A, B, C$  分成秘密份额  $\langle A \rangle_i^L, \langle B \rangle_i^L, \langle C \rangle_i^L$ , 并分发给  $P_0$ 、 $P_1$
- 3 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle E \rangle_j^L = \langle X \rangle_j^L - \langle A \rangle_j^L$  与  $\langle F \rangle_j^L = \langle Y \rangle_j^L - \langle B \rangle_j^L$
- 4  $P_0$ 、 $P_1$  交换秘密份额来重构  $E$  与  $F$
- 5 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $-jE \cdot F + \langle X \rangle_j^L \cdot F + E \cdot \langle Y \rangle_j^L + \langle C \rangle_j^L + U_j$

**算法 4.2**  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\}, P_2)$ 

**输入:**  $P_0$  与  $P_1$  分别持有  $(\langle x \rangle_0^L)$  和  $(\langle x \rangle_1^L)$ , 其中  $|x| < 1$ , 公开的展开阶数  $n(n \geq 4)$

**输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得秘密份额  $\langle y \rangle_i^L = \langle e^x \rangle_i^L$ .

- 1  $P_0$ 、 $P_1$  分别获得由  $P_2$  产生的  $u_0 = \langle 0 \rangle_0^L$  和  $u_1 = \langle 0 \rangle_1^L$
- 2  $P_0$ 、 $P_1$  计算  $\langle c \rangle_j^L = j$
- 3  $P_0$ 、 $P_1$  计算  $\langle \text{numerator} \rangle_j^L = \langle x \rangle_j^L$  并设置  $\text{denominator} = 1$
- 4  $P_0$ 、 $P_1$  计算  $\langle c \rangle_j^L = \langle c \rangle_j^L + \langle \text{numerator} \rangle_j^L$
- 5 **for**  $i = 2, 3, \dots, n$  **do**
- 6      $P_j$  的输入为  $\langle \text{numerator} \rangle_j^L$  与  $\langle x \rangle_j^L$  时, 在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{MatMul}}(\{P_0, P_1\}, P_2)$  后,  $P_j$  获得  $\langle \text{numerator} \rangle_j^L = \langle \text{numerator} \cdot x \rangle_j^L$
- 7      $\text{denominator} = \text{denominator} \times i$
- 8      $P_0$ 、 $P_1$  计算  $\langle c \rangle_j^L = \langle c \rangle_j^L + \frac{\langle \text{numerator} \rangle_j^L}{\text{denominator}}$
- 9 **end**
- 10 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle y \rangle_j^L = \langle c \rangle_j^L + u_j$

**算法 4.3**  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$ **输入:**  $P_0$  与  $P_1$  分别持有  $(\langle x \rangle_0^L)$  和  $(\langle x \rangle_1^L)$ **输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得秘密份额  $\langle y \rangle_i^L = \langle e^x \rangle_i^L$ .

- 1  $P_0$ 、 $P_1$  分别获得由  $P_2$  产生的  $u_0 = \langle 0 \rangle_0^L$  和  $u_1 = \langle 0 \rangle_1^L$
- 2 对于  $j \in \{0, 1\}$ ,  $P_j$  执行  $\Pi_{\text{Trunc}}(\{P_0, P_1\})$  后, 获得  $\lfloor x \rfloor$  的份额  $\langle a \rangle_j^L$
- 3 对于  $j \in \{0, 1\}$ ,  $P_j$  通过计算  $\langle b \rangle_j^L = \langle x \rangle_j^L - \langle a \rangle_j^L$  获得  $x$  的小数部分  $\langle b \rangle_j^L$
- 4 对于  $j \in \{0, 1\}$ ,  $P_j$  执行  $\Pi_{\text{BitDecomp}}(\{P_0, P_1\})$  后, 获得  $\lfloor x \rfloor$  按位展开的秘密份额  $(\langle c_0 \rangle_j^L, \langle c_1 \rangle_j^L, \dots, \langle c_{m-1} \rangle_j^L)$ , 其中得  $\lfloor x \rfloor$  是  $m$  比特数
- 5 **for**  $i = 0, 1, \dots, m-1$  **do**
- 6     对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle v_i \rangle_j^L = e^{2^i} \cdot (\langle c_i \rangle_j^L) + j - (\langle c_i \rangle_j^L)$
- 7 **end**
- 8 对于  $j \in \{0, 1\}$ ,  $P_j$  执行  $\Pi_{\text{PreMult}}(\{P_0, P_1\})$  后, 获得  $(\langle m \rangle_j^L)$
- 9 对于  $j \in \{0, 1\}$ ,  $P_j$  执行  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\})$  后, 获得  $(\langle n \rangle_j^L)$
- 10 对于  $j \in \{0, 1\}$ ,  $P_j$  的输入为时  $(\langle m \rangle_j^L)$  与  $(\langle n \rangle_j^L)$  时, 在执行  $\Pi_{\text{MatMul}}(\{P_0, P_1\}, P_2)$  后,  $P_j$  获得  $\langle y \rangle_j^L = \langle m \times n \rangle_j^L$

算法  $\Pi_{\text{Exp}}(P_0, P_1, P_2)$  是一个多方安全计算协议, 用于计算  $x$  的指数  $e^x$ 。在该协议中, 参与者  $P_0$  和  $P_1$  分别持有  $x$  的秘密份额, 并且希望计算  $e^x$  的秘密份额。此算法利用了算法 10 来近似  $e^x$ , 并利用到前述工作<sup>[81]</sup>中的子协议, 例如  $\Pi_{\text{Trunc}}(P_0, P_1)$ 、 $\Pi_{\text{BitDecomp}}(P_0, P_1)$ 、 $\Pi_{\text{PreMult}}(P_0, P_1)$  和  $\Pi_{\text{TaylorExpansion}}(P_0, P_1)$ 。

**算法 4.4**  $\Pi_{\text{Softmax}}(\{P_0, P_1\}, P_2)$ **输入:**  $P_0$  与  $P_1$  分别持有  $(\langle z_i \rangle_0^L)_{i \in [k]}$  和  $(\langle z_i \rangle_1^L)_{i \in [k]}$ **输出:**  $P_0$ ,  $P_1$  分别获得秘密份额  $(\langle s_{\max}(z_i) \rangle_0^L)_{i \in [k]}$  与  $(\langle s_{\max}(z_i) \rangle_1^L)_{i \in [k]}$ ,

$$\text{其中 } s_{\max}(z_i) = \frac{e^{z_i}}{\sum_{i=1}^k e^{z_i}}.$$

- 1  $P_0$ 、 $P_1$  分别获得由  $P_2$  产生的  $u_0 = \langle 0 \rangle_0^L$  和  $u_1 = \langle 0 \rangle_1^L$
- 2 **for**  $i = 1, 2, \dots, k$  **do**
- 3     在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$  后,  $P_0$ ,  $P_1$  分别获得  $\langle c_i \rangle_0^L$  与  $\langle c_i \rangle_1^L$ , 其中  $c_i^L = e^{z_i}$
- 4 **end**
- 5 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle S \rangle_j = \sum_{i=1}^k \langle c_i \rangle_j^L$
- 6 **for**  $i = 1, 2, \dots, k$  **do**
- 7     在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Division}}(\{P_0, P_1\}, P_2)$  后,  $P_0$ ,  $P_1$  分别获得  $\langle \frac{c_i}{S} \rangle_0^L$  与  $\langle \frac{c_i}{S} \rangle_1^L$
- 8     对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $(\langle s_{\max}(z_i) \rangle_j^L)_{i \in [k]} + u_j$
- 9 **end**

在算法 4.4 中,  $P_0$  和  $P_1$  分别持有  $k$  个数值的秘密份额, 其主要目标是计算 Softmax 函数, 即对每个  $i$ , 算法得到  $s_{\max}(z_i) = \frac{e^{z_i}}{\sum_{i=1}^k e^{z_i}}$  的秘密份额。首先,  $P_0$  和  $P_1$  分别获得由  $P_2$  产生的零值份额  $u_0 = \langle 0 \rangle_0^L$  和  $u_1 = \langle 0 \rangle_1^L$ 。对于每个  $i$ , 使用  $\Pi_{\text{Exp}}(P_0, P_1, P_2)$  算法计算指数值  $e^{z_i}$  的秘密份额  $\langle c_i \rangle_0^L$  和  $\langle c_i \rangle_1^L$ 。接着,  $P_0$  和  $P_1$  计算总和  $S$  的秘密份额  $\langle S \rangle_j = \sum_{i=1}^k \langle c_i \rangle_j^L$ 。再对于每个  $i$ , 通过  $\Pi_{\text{Division}}(P_0, P_1, P_2)$  算法计算  $\frac{c_i}{S}$  的秘密份额  $\langle \frac{c_i}{S} \rangle_0^L$  和  $\langle \frac{c_i}{S} \rangle_1^L$ 。最后,  $P_0$  和  $P_1$  将结果加上零值份额  $u_j$  以获得  $s_{\max}(z_i)$  的秘密份额。

### 4.3.2 语言模型模块的构建

在第 4.3 节中, 本章介绍了神经网络基本函数的设计。接下来, 本节将介绍如何构建语言模型 Transformer 编码器中的各个模块。具体而言, 我们将从线性层 Linear、注意力层 Attention 和前馈网络 FFN 这三个模块的构建进行介绍。

---

#### 算法 4.5 $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$

---

**输入:**  $P_0$  与  $P_1$  分别持有  $(\langle X \rangle_0, \langle W \rangle_0, \langle b \rangle_0)$  和  $(\langle X \rangle_1, \langle W \rangle_1, \langle b \rangle_1)$

**输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得输出的秘密分片  $\langle W \cdot X + b \rangle_i$ .

- 1  $P_0$ 、 $P_1$  分别获得从  $P_2$  产生的  $U_0 = \langle 0^{m \times n} \rangle_0^L$  和  $U_1 = \langle 0^{m \times n} \rangle_1^L$
  - 2 在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  后,  $P_0$ 、 $P_1$  分别获得  $\langle W \cdot X \rangle_0^L$  与  $\langle W \cdot X \rangle_1^L$
  - 3 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle y \rangle_i^L = \langle W \cdot X \rangle_i^L + \langle b \rangle_i^L$
- 

算法 4.5 在  $\Pi_{\text{Matmul}}(P_0, P_1, P_2)$  协议的基础上引入了偏置项 (Bias), 从而将  $\langle W \cdot X \rangle_i$  扩展到了  $\langle W \cdot X + b \rangle_i$ , 以实现 Linear 模块。Linear 模块作为整个模型中最基础的模块之一, 其设计和实现将在后续的模块设计中被频繁调用。

**算法 4.6**  $\Pi_{\text{Attention}}(\{P_0, P_1\}, P_2)$ **输入:**  $P_0$  与  $P_1$  分别持有

$$(\langle X \rangle_0, \langle W_Q \rangle_0, \langle b_Q \rangle_0, \langle W_K \rangle_0, \langle b_K \rangle_0, \langle W_V \rangle_0, \langle b_V \rangle_0, \langle W_P \rangle_0, \langle b_P \rangle_0) \text{ 和}$$

$$(\langle X \rangle_1, \langle W_Q \rangle_1, \langle b_Q \rangle_1, \langle W_K \rangle_1, \langle b_K \rangle_1, \langle W_V \rangle_1, \langle b_V \rangle_1, \langle W_P \rangle_1, \langle b_P \rangle_1)$$

**输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得输出的秘密分片

$$\langle W_P \cdot \text{Softmax}(\frac{(W_Q \cdot X + b_Q)(W_K \cdot X + b_K)^T}{\sqrt{d_k}})(W_V \cdot X + b_V) + b_P \rangle_i.$$

- 1  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$ ,  $P_0$ 、 $P_1$  分别获得  
 $Q = W_Q \cdot X + b_Q$ ,  $K = W_K \cdot X + b_K$ ,  $V = W_V \cdot X + b_V$  的秘密份额  
 $(\langle Q \rangle_0, \langle K \rangle_0, \langle V \rangle_0)$  与  $(\langle Q \rangle_1, \langle K \rangle_1, \langle V \rangle_1)$
- 2  $P_0$ 、 $P_1$  分别将  $\langle K \rangle_0$  与  $\langle K \rangle_1$  转置得到  $\langle K^T \rangle_0$  与  $\langle K^T \rangle_1$
- 3  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{MatMul}}(\{P_0, P_1\}, P_2)$ ,  $P_0$ 、 $P_1$  分别获得  $QK^T$  的秘密份  
额  $\langle QK^T \rangle_0$  与  $\langle QK^T \rangle_1$
- 4  $P_0$ 、 $P_1$  分别将  $\langle QK^T \rangle_0$  与  $\langle QK^T \rangle_1$  按元素除  $W_K$  的维度  $\sqrt{d_k}$  得到  
 $\langle \frac{QK^T}{\sqrt{d_k}} \rangle_0$  与  $\langle \frac{QK^T}{\sqrt{d_k}} \rangle_1$
- 5  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Softmax}}(\{P_0, P_1\}, P_2)$ ,  $P_0$ 、 $P_1$  分别获得  
 $A = \text{Softmax}(\frac{QK^T}{\sqrt{d_k}})$  的秘密份额  $\langle A \rangle_0$  与  $\langle A \rangle_1$
- 6  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$ ,  $P_0$ 、 $P_1$  分别获得  $\langle A \cdot V + b_V \rangle_0$  与  
 $\langle A \cdot V + b_V \rangle_1$
- 7  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$ ,  $P_0$ 、 $P_1$  分别获得  
 $\langle y \rangle_0 = \langle W_P(A \cdot V + b_V) + b_P \rangle_0$  与  $\langle y \rangle_1 = \langle W_P(A \cdot V + b_V) + b_P \rangle_1$

算法 4.6 展示了在  $\Pi_{\text{Linear}}(P_0, P_1, P_2)$  和  $\Pi_{\text{MatMul}}(P_0, P_1, P_2)$  协议的基础上如何构建注意力机制 (Attention)。该算法提供了对输入  $\langle X \rangle_i$  进行注意力变换后的秘密共享结果, 其输出为  $\langle W_P \cdot \text{Softmax}(\frac{(W_Q \cdot X + b_Q)(W_K \cdot X + b_K)^T}{\sqrt{d_k}})(W_V \cdot X + b_V) + b_P \rangle_i$ 。

该算法中, 注意力变换首先对输入  $\langle X \rangle_i$  分别进行三次线性变换, 得到  $Q = W_Q \cdot X + b_Q$ ,  $K = W_K \cdot X + b_K$  和  $V = W_V \cdot X + b_V$ 。然后, 算法利用了线性模块进行计算, 得到  $QK^T$ , 并将其除以  $\sqrt{d_k}$  进行缩放。这个缩放过程使得模型在进行自注意力计算时能更好地保持稳定性。接下来, 算法对缩放后的结果进行 Softmax 变换, 得到注意力分布  $A = \text{Softmax}(\frac{QK^T}{\sqrt{d_k}})$ 。然后, 将注意力分布与  $V$  进行乘积运算, 并加上偏置项  $b_V$ 。最后, 算法对上一步得到的结果再进行一次线性变换, 得到最终的输出  $\langle y \rangle_i = \langle W_P(A \cdot V + b_V) + b_P \rangle_i$ 。

注意力机制是 Transformer 中的核心组成部分, 它允许模型在处理序列数据时, 对输入数据中的不同部分分配不同的注意力权重。通过这种方式, 模型可以更好地理解和表示序列中的依赖关系。这个  $\Pi_{\text{Attention}}(P_0, P_1, P_2)$  算法正是基于这种思想, 将注意力机制融入到大型语言模型的构建过程中, 从而提升模型的表达



能力。

---

**算法 4.7**  $\Pi_{\text{FFN}}(\{P_0, P_1\}, P_2)$ 


---

**输入:**  $P_0$  与  $P_1$  分别持有  $(\langle X \rangle_0, \langle W_1 \rangle_0, \langle W_2 \rangle_0, \langle b_1 \rangle_0, \langle b_2 \rangle_0)$  和

$(\langle X \rangle_1, \langle W_1 \rangle_1, \langle W_2 \rangle_1, \langle b_1 \rangle_1, \langle b_2 \rangle_1)$

**输出:** 对于  $i \in \{0, 1\}$ ,  $P_i$  获得输出的秘密分片

$\langle W_2 \cdot \text{ReLU}(W_1 \cdot X + b_1) + b_2 \rangle_i$ .

- 1  $P_0$ 、 $P_1$  分别获得从  $P_2$  产生的  $U_0 = \langle 0^{m \times n} \rangle_0^L$  和  $U_1 = \langle 0^{m \times n} \rangle_1^L$
  - 2  $P_j$  的输入为  $\langle X \rangle_j^L$  与  $\langle W_1 \rangle_j^L$  时, 在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$  后,  $P_j$  获得  $\langle H \rangle_j^L = \langle W_1 \cdot X + b_1 \rangle_j^L$
  - 3 在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{ReLU}}(\{P_0, P_1\}, P_2)$  后,  $P_j$  获得  $\langle \text{ReLU}(H) \rangle_j^L$
  - 4  $P_j$  的输入为  $\langle \text{ReLU}(H) \rangle_j^L$  与  $\langle W_2 \rangle_j^L$  时, 在  $P_0$ 、 $P_1$ 、 $P_2$  执行  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$  后,  $P_j$  获得  $\langle O \rangle_j^L = \langle W_2 \cdot \text{ReLU}(H) + b_2 \rangle_j^L$
  - 5 对于  $j \in \{0, 1\}$ ,  $P_j$  计算  $\langle O \rangle_j^L + U_j$
- 

算法 4.7 表示的是一个前馈神经网络的计算过程, 其中包含了两个线性 (Linear) 变换和一个 ReLU 激活函数。在算法执行过程中, 首先在  $\Pi_{\text{Linear}}(P_0, P_1, P_2)$  协议的基础上对输入  $X$  进行第一次线性变换, 即乘以权重  $W_1$  并加上偏置  $b_1$ , 获得  $H$ , 然后将  $H$  通过 ReLU 激活函数进行非线性变换。ReLU 函数的作用是将所有负数变为 0, 对所有正数保持不变, 其计算公式为:  $\text{ReLU}(x) = \max(0, x)$ 。这个操作是在  $\Pi_{\text{ReLU}}(P_0, P_1, P_2)$  协议中进行的。接着, 对 ReLU 激活后的结果进行第二次线性变换, 即乘以权重  $W_2$  并加上偏置  $b_2$ , 得到  $O$ 。最后,  $P_0$  和  $P_1$  对各自得到的结果进行一次局部计算, 即与零矩阵的份额  $U_j$  相加, 得到最终的结果  $\langle O \rangle_j^L$ 。

FFN 模块是神经网络中的一个基本模块, 其功能是在保持输入和输出的维度不变的同时, 对输入进行复杂的非线性变换, 从而增加模型的表达能力。在多层神经网络中, 通常会使用多个此类模块进行堆叠, 以构建更深的网络结构。

### 4.3.3 可验证外包计算的设计

本节介绍了一个可验证外包计算的设计, 与前一部分不同的是, 此设计需要每个服务器都拥有高性能的 GPU 计算资源。回顾 4.2.2 节中的安全假设, 本章假设计算方是恶意的, 可以任意偏离协议并推断数据持有者的隐私信息和模型参数。对于计算方上的 SGX, 本章假设其机密性可能被破坏但会保留其完整性; 对于计算方上的 GPU, 本章假设其执行内容对服务器可见, 但执行协议不会被破坏。这是一种对可信硬件常见的安全假设<sup>[25]</sup>。

如图 4.3 所示, 首先, 数据持有者使用秘密共享方法将数据拆分成两个秘密份额, 并在与两个服务器的可信硬件进行远程认证后, 将数据分发至服务器。然

后，在与第三个持有可信硬件的服务器认证后，服务器之间根据算法的具体实现方式进行交互。两个获得秘密份额的服务器在第三个服务器提供的随机数的帮助下，完成相应的算法计算。最终，两个服务器分别得到的预测结果的秘密份额，在交互重构后得到最终的预测结果，并通过真值计算损失函数来更新存储在两个服务器上的权重。

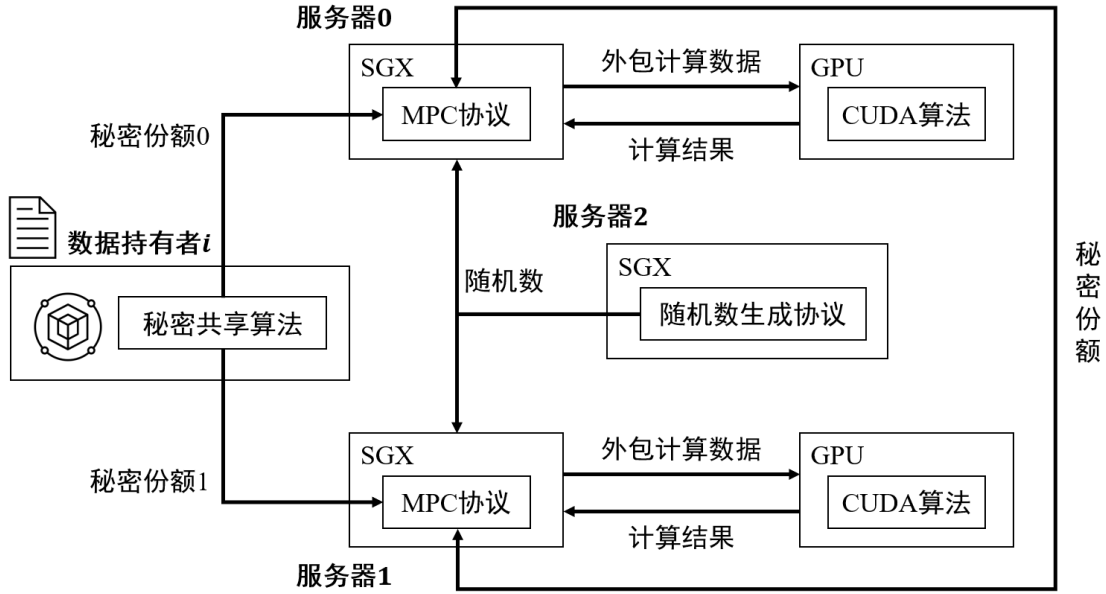


图 4.3 外包计算的协议流程

#### 算法 4.8 外包计算并验证正确性

**输入:** SGX 持有模型矩阵参数  $M$  的秘密份额  $\langle M \rangle_j^L \in Z_L^{m \times d}$  与输入  $x$  的

秘密份额  $\langle x \rangle_j^L \in Z_L^{d \times n}$

**输出:** SGX 获得计算结果  $\langle M \rangle_j^L \cdot \langle x \rangle_j^L$

- 1 SGX 将  $\langle M \rangle_j^L$  与  $\langle x \rangle_j^L$  分发给 GPU
- 2 GPU 计算  $y = \langle M \rangle_j^L \cdot \langle x \rangle_j^L$
- 3 **for**  $i = 1, 2, \dots, n$  **do**
- 4     SGX 生成随机向量  $\alpha \in Z_L^{n \times 1}$
- 5     SGX 验证  $y \cdot \alpha$  与  $\langle M \rangle_j^L \cdot (\langle x \rangle_j^L \cdot \alpha)$  是否相等
- 6 **end**

算法 4.8 描述了本文的外包计算协议。为了加速计算，本文引入了 GPU 并进行了外包计算。具体来说，SGX 将需要计算的秘密份额分发给本地的 GPU，GPU 计算完结果后返回给 SGX。然后，SGX 使用 Freivalds' 验证算法<sup>[82]</sup>来校验计算结果的正确性。该算法通过引入一个列向量  $x$ ，计算  $A \cdot (B \cdot x)$  与  $C \cdot x$  的结果，来验证矩阵运算  $A \cdot B = C$  的正确性。由于矩阵与列向量的运算时间短，该验证算法能将验证时间由  $O(n^3)$  降至  $O(kn^2)$ ，其中  $k$  为验证次数。因此，Freivalds' 验证算法确保了外包计算的正确性，而秘密共享技术则保护了数据的隐私，整体实

现了计算过程的隐私保护和计算正确性验证。

## 4.4 安全性分析

### 4.4.1 训练安全

基于通用可组合模型<sup>[83-84]</sup> (Universally Compsable, UC), 本部分给出 4.3 中各算法的系统安全性的理论证明。根据 4.2 的定义, 本部分证明本章的系统在恶意攻击者存在的情况下能够保证安全性。在 4.2 的安全假设中, 假设存在一个敌手  $A$ , 它能够控制其中一个参与方。令  $I \subset N$  表示被控制方的集合,  $|I| = 1$ 。设  $J = N/I$  是诚实的参与者的集合。在整个证明过程中,  $P_i (i \in I)$  表示被攻击者操作一方, 而  $P_j (j \in J)$  表示诚实方。安全性定义遵循相关工作中的方法。与研究工作<sup>[22,85-86]</sup>相同, 在本章条件下有如下引理成立:

**定义 4.1** 对于任何多项式时间的攻击者  $A$ , 如果存在一个模拟器  $S$  能够构建一个模拟世界, 在这个模拟世界中  $A$  的视图与真实世界中  $A$  的视图在计算上不可区分, 那么该协议是可证明安全的。

**引理 4.1** 如果一个协议的所有子协议都是完全可模拟的, 那么该协议本身也是完全可模拟的。

在 UC 框架中, 一个协议通常由多个子协议组成, 每个子协议都有自己的安全性质。如果每个子协议都是可模拟的, 也就是说, 每个子协议都可以在模拟环境中与理想功能模型等效地运行, 那么整个协议也可以在模拟环境中与理想功能模型等效地运行。

这是因为在 UC 框架中, 可以使用虚拟攻击者来证明协议的安全性, 虚拟攻击者在真实环境和模拟环境下执行相同的攻击, 然后证明模拟环境中的协议能够抵御虚拟攻击者的攻击。如果每个子协议都是可模拟的, 那么整个协议也可以在模拟环境中与理想功能模型等效地运行, 因此整个协议也可以被证明是安全的。

**引理 4.2** 如果  $r$  是攻击者未知的且服从均匀分布的一个随机数, 那么  $x \cdot r$  对攻击者也是未知的, 并且与  $x$  独立。

**引理 4.3** 如果  $r$  是攻击者未知的且服从均匀分布的一个随机数, 那么  $x \pm r$  对攻击者也是未知的, 并且与  $x$  独立。

**引理 4.4**  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  以及其线性组合是安全的<sup>[87-88]</sup>。

**引理 4.5**  $\Pi_{\text{Trunc}}(\{P_0, P_1\})$ 、 $\Pi_{\text{BitDecomp}}(\{P_0, P_1\})$ 、 $\Pi_{\text{PreMult}}(\{P_0, P_1\})$  是可模拟的<sup>[89]</sup>

基于上述的引理, 下面本节提供 4.3 中各算法的系统安全性的理论证明, 即存在模拟器  $S$  使得攻击者  $A$  在现实世界与理想世界中的视图在计算上是不可区

分的。

**定理 4.6** 在 4.2 中的安全假设下,  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\}, P_2)$  可以保证面对恶意攻击者攻击的安全性。

**证明**

1) *a* 若  $P_i = P_0$  或  $P_i = P_1$ , 其持有数据的视图如下:

$$\begin{aligned} \text{view}_i^{\text{TaylorExpansion}} &= \{u_i, \langle x \rangle_i, \langle \text{numerator} \rangle_i, \text{denominator}, \langle c \rangle_i\}, \\ \text{output}_i^{\text{TaylorExpansion}} &= \{y_i\}, \end{aligned}$$

其中秘密份额  $\langle x \rangle_i$  的安全性由引理 4.3 保障。根据引理 4.4, 现有工作已证明  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  在半诚实攻击者存在情况下的安全性, 因此在以  $\langle x \rangle_i$  作为输入的情况下,  $\langle \text{numerator} \rangle_i$  的值满足均匀随机性。此外, 由于  $\text{denominator}$  是每一阶 Taylor Expansion 的常数, 与  $x$  无关。在以  $\langle \text{numerator} \rangle_i$  与  $\text{denominator}$  作为输入的  $\langle c \rangle_i$  同样满足均匀随机性。至此, 模拟器可以使用均匀分布的随机数来模拟  $\text{view}_i^{\text{TaylorExpansion}}$ , 即攻击者的模拟视图与现实视图的概率分布不可区分。对于计算结果  $\text{output}_i^{\text{TaylorExpansion}} = \{y_i\}$ ,  $x$  为加法秘密共享  $\langle x \rangle_i$  的重构值, 由计算过程  $c$  为计算  $x$  的  $n$  阶 Taylor 展开值的加法秘密共享  $\langle c \rangle_i$  的秘密份额, 因此输出  $\langle y \rangle_j^L = \langle c \rangle_j^L + u_j$  满足均匀随机性, 并且重构结果等于正确的计算结果, 故模拟器可以通过满足均匀分布的随机数与理想功能的输出对  $\text{output}_i^{\text{TaylorExpansion}} = \{y_i\}$  进行有效模拟, 即其输出的概率分布与真实世界的输出满足不可区分性。至此, 证明了  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\}, P_2)$  可抵抗半诚实攻击者。

*b* 若  $P_i = P_2$ , 其持有数据的视图为:

$$\begin{aligned} \text{view}_i^{\text{TaylorExpansion}} &= \{u_0^s, u_1^s, \langle A \rangle_i^s, \langle B \rangle_i^s, \langle C \rangle_i^s, A^s, B^s, C^s\}, \\ \text{output}_i^{\text{TaylorExpansion}} &= \{u_0^s, u_1^s, \langle A \rangle_i^s, \langle B \rangle_i^s, \langle C \rangle_i^s\}, \end{aligned}$$

其中  $s$  为  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\}, P_2)$  中调用  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  的场景。 $P_2$  在整个过程中只对  $P_0, P_1$  单向提供  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  计算所需随机数, 故不会获取任何有关  $x$  的任何信息。由于  $u_0^s, A^s, B^s, \langle A \rangle_0^s, \langle B \rangle_0^s, \langle C \rangle_0^s$  为  $P_2$  独立生成的随机数, 在半诚实的场景下, 其计算的  $u_1^s, C^s, \langle A \rangle_1^s, \langle B \rangle_1^s, \langle C \rangle_1^s$  均满足均匀随机性, 并且  $\{(u_0^s, u_1^s), (\langle A \rangle_0^s, \langle A \rangle_1^s), (\langle B \rangle_0^s, \langle B \rangle_1^s), (\langle C \rangle_0^s, \langle C \rangle_1^s)\}$  可分别重构为  $\{0, A, B, C\}$ , 故模拟器可以通过满足均匀分布的随机数与理想功能的输出对  $\text{output}_i^{\text{TaylorExpansion}}$  进行有效模拟, 其输出的概率分布与真实世界的输出满足不可区分性。

2) 同时,在 4.2 中的安全假设下,由于 SGX 的完整性保障<sup>[78]</sup>,  $P_i$  无法对 SGX 飞地内的数据进行篡改,即将上述半诚实攻击者升级为恶意攻击者时,协议仍可以保障攻击者严格遵守协议。因此,恶意攻击者不仅推断不出隐私数据,而且不能偏离协议执行其他操作,即本协议可以抵御恶意攻击者的攻击。

因此,  $view_i^{\text{TaylorExpansion}}$  是可模拟的,无法找到一个概率多项式时间算法来区分  $view_i$  和  $P_i$  的模拟视图。因此,  $\Pi_{\text{TaylorExpansion}}(\{P_0, P_1\}, P_2)$  在 4.2 中的安全假设下是安全的。

■

**定理 4.7** 在 4.2 中的安全假设下,  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$  可以保证面对恶意攻击者攻击的安全性。

**证明** 若  $P_i = P_0$  或  $P_i = P_1$ , 其持有数据的视图如下:

$$view_i^{\text{Exp}} = \{u_i, \langle x \rangle_i, \langle a \rangle_i, \langle b \rangle_i, \langle c[0], \dots, c[m-1] \rangle_i, \langle m \rangle_i, \langle n \rangle_i\},$$

$$output_i^{\text{Exp}} = \{y_i\},$$

其中秘密份额  $\langle x \rangle_i$  的安全性由引理 4.3 保障。引理 4.5 保障了  $\langle a \rangle_i = \lfloor x \rfloor$  的安全性,进而获得  $x$  的小数部分  $\langle b \rangle_j^L = \langle x \rangle_j^L - \langle a \rangle_j^L$  满足均匀随机性。同样的,在执行  $\Pi_{\text{BitDecomp}}(\{P_0, P_1\})$  获得的  $\langle c[0], \dots, c[m-1] \rangle_i$  以及执行  $\Pi_{\text{PreMult}}(\{P_0, P_1\})$  获得的  $\langle m \rangle_i$  也满足均匀随机性。根据定理 4.6, TaylorExpansion 的计算结果  $\langle n \rangle_i$  满足均匀随机性。根据引理 4.4, 现有工作已证明  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  在半诚实攻击者存在情况下的安全性,因此在以  $\langle m \rangle_i$  与  $\langle n \rangle_i$  作为输入的情况下,  $\langle y \rangle_i$  的值满足均匀随机性,并且重构结果等于正确的计算结果,故模拟器可以通过满足均匀分布的随机数与理想功能的输出对  $output_i^{\text{Exp}} = \{y_i\}$  进行有效模拟,其输出的概率分布与真实世界的输出满足不可区分性。至此,证明了  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$  可抵抗半诚实攻击者。

与定理 4.6 的证明相同,同理可证在  $P_i = P_2$  时,模拟器可以通过满足均匀分布的随机数与理想功能的输出对  $view_i^{\text{Exp}}$  与  $output_i^{\text{Exp}}$  进行有效模拟,其输出的概率分布与真实世界的输出满足不可区分性。

同样的,在 4.2 中的安全假设下,由于 SGX 的完整性保障<sup>[78]</sup>,  $P_i$  无法对 SGX 飞地内的数据进行篡改,即将上述半诚实攻击者升级为恶意攻击者时,协议仍可以保障攻击者严格遵守协议。因此,恶意攻击者不仅推断不出隐私数据,而且不能偏离协议执行其他操作,即本协议可以抵御恶意攻击者的攻击。

因此,  $view_i^{\text{Exp}}$  是可模拟的,无法找到一个概率多项式时间算法来区分  $view_i$  和  $P_i$  的模拟视图。因此,  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$  在 4.2 中的安全假设下是安全的。

**定理 4.8** 在 4.2 中的安全假设下,  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$  可以保证面对恶意攻击者攻击的安全性。

**证明** 若  $P_i = P_0$  或  $P_i = P_1$ , 其持有数据的视图如下:

$$\begin{aligned} \text{view}_i^{\text{Linear}} &= \{u_i, \langle X \rangle_i, \langle W \rangle_i, \langle b \rangle_i\}, \\ \text{output}_i^{\text{Linear}} &= \{y_i\}, \end{aligned}$$

其中秘密份额  $\langle X \rangle_i$  与权重矩阵  $\langle W \rangle_i$  的安全性由 4.3 保障。根据引理 4.4, 现有工作已证明  $\Pi_{\text{Matmul}}(\{P_0, P_1\}, P_2)$  在半诚实攻击者存在情况下的安全性, 因此在以  $\langle W \rangle_i$  与  $\langle X \rangle_i$  作为输入的情况下,  $\langle W \cdot X \rangle_i$  的值满足均匀随机性。进而由引理 4.3 可知,  $\langle W \cdot X \rangle_i + \langle b \rangle_i$  的值满足均匀随机性, 并且重构结果等于正确的计算结果, 故  $\text{output}_i^{\text{Exp}} = \{y_i\}$  可以通过满足均匀分布的随机数与理想功能的输出对计算结果进行有效模拟, 其输出的概率分布与真实世界的输出满足不可区分性。至此, 证明了  $\Pi_{\text{Linear}}(\{P_0, P_1\}, P_2)$  可抵抗半诚实攻击者。

与定理 4.6 的证明相同, 同理可证在  $P_i = P_2$  时,  $\text{view}_i^{\text{Linear}}$  与  $\text{output}_i^{\text{Linear}}$  可以通过满足均匀分布的随机数与理想功能的输出对计算结果进行有效模拟, 其输出的概率分布与真实世界的输出满足不可区分性。

同样的, 在 4.2 中的安全假设下, 由于 SGX 的完整性保障<sup>[78]</sup>,  $P_i$  无法对 SGX 飞地内的数据进行篡改, 即将上述半诚实攻击者升级为恶意攻击者时, 协议仍可以保障攻击者严格遵守协议。因此, 恶意攻击者不仅推断不出隐私数据, 而且不能偏离协议执行其他操作, 即本协议可以抵御恶意攻击者的攻击。

因此,  $\text{view}_i^{\text{Linear}}$  是可模拟的, 无法找到一个概率多项式时间算法来区分  $\text{view}_i$  和  $P_i$  的模拟视图。因此,  $\Pi_{\text{Exp}}(\{P_0, P_1\}, P_2)$  在 4.2 中的安全假设下是安全的。

**定理 4.9** 在 4.2 中的安全假设下,  $\Pi_{\text{Attention}}(\{P_0, P_1\}, P_2)$  可以保证面对恶意攻击者攻击的安全性。

**证明** 若  $P_i = P_0$  或  $P_i = P_1$ , 其持有数据的视图如下:

$$\begin{aligned} \text{view}_i^{\text{Attention}} &= \{\langle X \rangle_0, \langle W_Q \rangle_0, \langle b_Q \rangle_0, \langle W_K \rangle_0, \langle b_K \rangle_0, \langle W_V \rangle_0, \langle b_V \rangle_0, \langle W_P \rangle_0, \langle b_P \rangle_0\}, \\ \text{output}_i^{\text{Attention}} &= \{y_i\}, \end{aligned}$$

由引理 4.4 与定理 4.8,  $P_i$  计算的  $(\langle Q \rangle_i, \langle K \rangle_i, \langle V \rangle_i, \langle QK^T \rangle_i, \langle \frac{QK^T}{\sqrt{d_k}} \rangle_i)$  满足均匀随机性。根据  $\Pi_{\text{Softmax}}(\{P_0, P_1\}, P_2)$  的安全性, 注意力值  $A = \text{Softmax}(\frac{QK^T}{\sqrt{d_k}})$  同

样满足均匀随机性。同样由定理 4.8 可知, 通过矩阵乘法以及 Linear 的计算结果  $\langle y \rangle_i$  的值满足均匀随机性, 并且重构结果等于正确的计算结果, 故模拟器可以通过满足均匀分布的随机数与理想功能的输出对  $output_i^{\text{Attention}} = \{y_i\}$  进行有效模拟, 其输出的概率分布与真实世界的输出满足不可区分性。至此, 证明了  $\Pi_{\text{Attention}}(\{P_0, P_1\}, P_2)$  可抵抗半诚实攻击者。

与定理 4.6 的证明相同, 同理可证在  $P_i = P_2$  时,  $view_i^{\text{Attention}}$  与  $output_i^{\text{Attention}}$  可以通过满足均匀分布的随机数与理想功能的输出对计算结果进行有效模拟, 其输出的概率分布与真实世界的输出满足不可区分性。

同样的, 在 4.2 中的安全假设下, 由于 SGX 的完整性保障<sup>[78]</sup>,  $P_i$  无法对 SGX 飞地内的数据进行篡改, 即将上述半诚实攻击者升级为恶意攻击者时, 协议仍可以保障攻击者严格遵守协议。因此, 恶意攻击者不仅推断不出隐私数据, 而且不能偏离协议执行其他操作, 即本协议可以抵御恶意攻击者的攻击。

因此,  $view_i^{\text{Attention}}$  是可模拟的, 无法找到一个概率多项式时间算法来区分  $view_i$  和  $P_i$  的模拟视图。因此,  $\Pi_{\text{Attention}}(\{P_0, P_1\}, P_2)$  在 4.2 中的安全假设下是安全的。

■

#### 4.4.2 SGX 被攻破的影响

自 Intel 推出 SGX 以来, 各种攻击接踵而至。其中最具有代表性的攻击是侧信道攻击, 如功耗分析攻击、计时攻击、回滚攻击与缓存冲突攻击等<sup>[64-71]</sup>。目前也有很多缓解这些攻击的研究<sup>[90-97]</sup>, 这些工作与本方案是互补的。

考虑到比 4.2 中的安全假设更具挑战的情况——SGX 被完全攻破, 即在上述针对保护 SGX 的方案均失效的情况下, SGX 不仅丧失机密性, 而且完整性也被破坏。这种情况下, 本协议只损失了协议执行结果正确性, 而隐私性仍能得到保证。由于在 4.3 中各函数执行过程中均使用秘密份额进行交互, 由前述安全性分析以及 4.2 中的安全假设, 在任意两方不共谋的情况下, 任何一方均不能重构出原始训练数据以及模型参数的任何信息, 故 SGX 被完全攻破的情况下, 协议仍保障了隐私性。而由于丧失了完整性, 恶意的计算方服务器可能使用一些恶意的结果作为秘密份额与其他计算方服务器进行交互, 导致重构结果与正确结果不同, 即损失了正确性。总的来讲, 即使 SGX 被完全攻破, 本协议仍能保障半诚实安全假设下的安全性。此外, 本协议不局限于使用 SGX 作为可信硬件, 其他如 Keytone<sup>[98]</sup>、HyperEnclave<sup>[99]</sup>等的可信执行环境可替代 SGX。此外, 与本方案互补的 SGX 防御技术可以为本协议的 SGX 进行补充, 如随机化技术、异常检测、源码重构与增强隔离等。

## 4.5 实验评估

### 4.5.1 实验设置

本实验的目标与 3.5 节的设定相同，在中文预训练模型的基础上在 CMDD 数据集上进行微调。由于其参数量为 81.9M，使用的词表大小为 21128，隐层维度为 768，12 层的 GPT2Block，这些设定通过本节协议完整的训练完时间硬件成本开销过于大，而成熟的框架如 Pytorch 对底层很多实现细节进行了优化。因此，这里分两个部分来说明本章协议的有效性：

- 1) 等效模型训练。使用与本协议执行等价的 Pytorch 代码执行相应的训练微调工作，即通过一个等价的高效框架来说明本协议计算的正确性以及与传统模型计算结果的一致性。
- 2) 协议的开销分析与实验。分析 4.3 节中各函数与模块的执行开销，包括执行时间复杂度与通信开销的理论分析与实验结果。

#### 等效模型训练

本章使用以下参数设置实例化 4.3 节中的子协议。机器学习算法通常使用实数 (float32)，而加法秘密共享仅限于整数计算。与相关研究工作相同<sup>[24,30,60,100]</sup>，本部分在安全协议中使用实数的定点编码。具体来说，对于实数  $x$ ，本部分考虑  $t$  位精度的定点编码： $\lfloor x \cdot 2^t \rfloor$ 。当乘以两个定点编码的数字时，由于它们都乘以  $2^t$ ，因此两个方需要额外缩放由  $2^{2t}$  缩放的乘积，本章使用来自<sup>[30]</sup>的截断技术。本章的实验考虑带有 15 位精度的  $\mathbb{Z}_{2^{64}}$  环。

这里与主要修改的是非线性运算的逻辑。第一，由于这里使用的  $\Pi_{\text{ReLU}}$  函数的一个重要前置函数是调用  $\Pi_{\text{MSB}}$  来计算最高位的值，即符号位，这就要求数据是在整数域上。因此，在执行 ReLU 前，需要对中间结果调用  $\Pi_{\text{Trunc}}$  来获取其整数部分。第二，在调用  $\Pi_{\text{Softmax}}$  时，由于其中使用到的  $\Pi_{\text{Exp}}$  函数中需要调用的  $\Pi_{\text{TaylorExp}}$ ，这里本实验设置的是展开到 5 阶 ( $n = 5$ )，那么与实际结果相比，会在精度上有一定的误差。

实验环境与 3.3.1 相同：CPU 为 AMD Ryzen 9 5900HX、32GB RAM、GPU 为 RTX3080-Laptop、操作系统为 Windows 11 64 位。

#### 协议的开销分析与实验

这里的实验环境如表 4.1 所示：CPU 为 Intel i7-8750H（支持 SGX，实验中主频均在 4.0GHz 以上）、16GB RAM、GPU 为 GTX1060-Laptop、操作系统为 Ubuntu16.04。

### 4.5.2 实验结果

#### (1) 等效模型训练



表 4.1 协议的开销分析与实验环境

维度	配置
处理器	Intel Core i7-8750H @ 4.20GHz
内存	16G DDR4 3200Hz
GPU	GTX1060 6G VRAM
操作系统	Ubuntu 16.04
硬盘	512G SSD

在其他与本方案类似的工作中<sup>[23-24,30]</sup>，使用到的数据集和训练模型的结构与大小都比本章实验相差很多，如 MNIST、Cora 等数据集。本章实验基于 GPT2 的模型以及中文医学生成数据集 CMDD 上微调的情况更能反应在大模型上的训练情况。

图 4.4 所示等效模型和原模型的训练损失函数与训练轮数的变化情况，由于 4.5.1 节中提到的非线性函数的截断与近似导致的模型训练效果稍差，这种现象与研究模型量化的工作<sup>[101-102]</sup>以及研究在 NLP 领域量化<sup>[103-104]</sup>的工作中的结论相似。在数值上，原训练模型与本协议的等效训练模型在训练阶段的交叉熵损失（Cross-Entropy Loss）之间的差距大约为 0.65，而且协议等效训练的波动稍大。这种差别主要是由于模型量化导致的精度损失。如果选择更高位数的量化情况，其表现效果应会有所提升。

此外，本节还研究了等效模型与原模型在困惑度指标上的差别。原模型的困惑度为 7.06，而等效模型的困惑度为 13.51。这反映了等效模型相比于原模型在性能上有一定的下降，这与图 4.4 中观察到的训练阶段的平均损失函数值是一致的。等效模型的损失函数值高于原模型，因此，困惑度也相对较高。




图 4.4 等效模型与原模型的训练损失对比

这种性能下降主要是由于模型权重量化以及函数近似导致的精度损失。不过值得注意的是，如果选择更高位数的量化情况，模型的表现效果应该会有所提升。总的来说，尽管等效模型在性能上略有下降，但在保护隐私的前提下，其仍然具有一定的应用价值。

## (2) 协议的开销分析与实验

表 4.2 展示了 4.3.2 节中构建的 Transformer 模块的通信开销。其中  $n$  为输入矩阵的维度，这里的设定跟实际模型执行过程的设定相同，即每个矩阵为  $n$  维方阵； $l$  为数据类型的比特数，如  $l_{\text{float}} = 32, l_{\text{int}} = 32$ ； $p$  为执行比较协议的小整数域  $Z_p$  的大小（本实验中  $p = 67$ ）。

**表 4.2 Transformer 模块的通信开销**

协议	通信开销
Linear	$5n^2l$
Attention	$(30 + 5ks)n^2l + (8l \log(p) + 24l)s$
FFN	$10n^2l + 8l \log(p) + 24l$

表 4.3 展示了使用可验证外包计算的加速效果与输入维度的关系。其中，执行时间为所有在 SGX 上完成矩阵乘法的时间；传输时间为将数据从 Enclave 通过总线传到 GPU 以及计算结果从 GPU 通过总线传输回 Enclave 的总时间开销；验证时间为在 Enclave 中验证乘法结果计算正确性的时间；总外包时间包括了传输时间验证时间以及在 GPU 上的计算时间；加速比为执行时间与总外包时间的比值，反应了外包计算协议的执行加速效果。

**表 4.3 使用可验证外包计算的加速效果与输入维度的关系**

维度	执行时间	传输时间	验证时间	总外包时间	加速比
64	0.0001	0.0014	0.0002	0.0016	0.0753
128	0.0002	0.0016	0.0005	0.0011	0.1909
256	0.0021	0.0023	0.0012	0.0036	0.5930
512	0.0094	0.0072	0.0024	0.0098	0.9634
768	0.0257	0.0136	0.0041	0.0179	1.4419
1024	0.0611	0.0114	0.0085	0.0201	3.0509
2048	0.4173	0.0517	0.0486	0.1006	4.1497

可以看出，在矩阵计算维度为 512 时，二者计算开销大致相同，若维度小于 512，则不使用外包计算的效果更好。反之，若维度大于 512，使用外包计算的时间开销回更少，并且随着维度的增加，这个结果在不断扩大，在 2048 维时，通过外包计算的时间仅不到执行时间的 1/4。

## 4.6 本章小结

本章针对医学文本生成任务训练阶段的隐私问题，设计并实现了一种有效抵抗恶意攻击者的安全协议。本部分详细描述了系统模型、威胁模型以及安全目标，并扩展了基于加法秘密共享的协议，使之可以支持 Transformer 的复杂结构。本章引入了 Intel SGX 以确保协议执行的完整性，并设计了高效的外包计算协议以提高矩阵乘法的计算效率。最后，本章通过理论分析与实验验证，成功地验证了所提协议的安全性及高效性。

## 第5章 医学文本生成任务推断阶段的隐私保护研究

### 5.1 引言

为防止攻击者在推断阶段试图通过模型反演攻击来恢复训练隐私数据，同时保持语言模型的表现效果，本章基于差分隐私算法提出两种方法来缓解语言模型的记忆问题，从而保护隐私数据。首先，本章将介绍系统模型与设计目标，引入本章的保护对象与攻击者的行为。其次，介绍选择差分隐私的定义，并针对训练与推断阶段分别设计了选择差分隐私优化器与选择差分隐私解码算法，作为两种提供选择差分隐私的方式。随后，对前述设计的选择差分隐私优化器与选择差分隐私解码算法进行隐私性分析，以证明其满足差分隐私的定义。最后，本章通过设计实验说明这两种保护方式的优势。

### 5.2 隐私保护系统设计与优化策略

#### 5.2.1 系统模型

如图 5.1 所示，在这种场景下，拥有隐私医学文本数据集的数据持有者通过一种训练策略得到一个针对该领域医学文本的语言模型，其通过公开推断查询的接口来提供查询服务。正常的诚实使用者将输入传给模型持有者，模型持有者通过语言模型执行推断，并将语言模型的输出返回给使用者。而调用查询接口的使用者可能会定制攻击输入前缀并通过执行多次推断服务来尝试恢复模型的隐私数据。

本节研究持有隐私数据集的数据持有者如何保障在执行推断阶段时，训练好的语言模型不会由于“记忆性”导致泄露出训练的隐私内容，即使用何种训练策略才能让模型主要关注于文本构成以及生成逻辑，而不是“记住”具体的隐私信息。因此，本节考虑两个实体，第一个是拥有隐私医学文本数据集的数据持有者，第二个是调用查询接口的使用者。

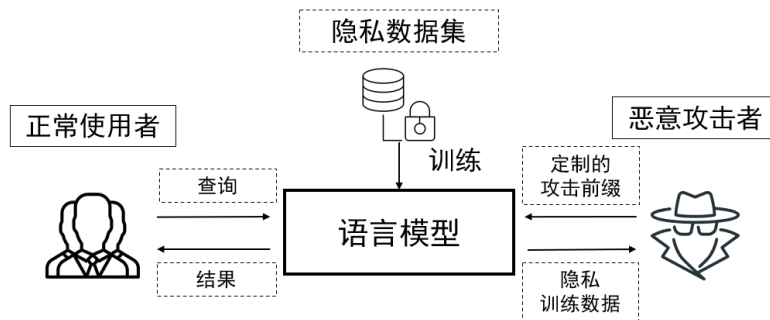


图 5.1 医学文本生成任务推断阶段的系统模型

### 5.2.2 威胁模型与设计目标

#### (1) 威胁模型

本节对该场景下拥有隐私医学文本数据集的数据持有者的安全假设是诚实的，即它会使用真实的医学隐私训练语料通过特定的训练方式来训练模型，也称为模型持有者（后文提到的数据持有者与模型持有者在本章中都是相同的）。对于调用查询接口的使用者，本章假设其是恶意的，它可以通过定制任何攻击前缀来从模型持有者的模型中推断训练数据集的隐私信息。

#### (2) 设计目标

- a) 训练阶段引入差分隐私。数据持有者通过一个隐私保护的训练算法在隐私数据上进行模型训练，推断阶段直接输出推断结果。
- b) 推断阶段引入差分隐私。数据持有者直接使用隐私数据进行训练，推断阶段使用一个隐私保护的推断算法输出推断结果。

### 5.2.3 训练阶段隐私保护的关联性分析

在训练阶段的执行过程中，如果仅在训练阶段应用差分隐私算法，而不采取其他隐私保护措施，这样无法直接保护隐私信息。原因在于，即使在半诚实攻击者的场景下，以下两种情况都可能导致隐私泄露：1. 如果词嵌入（Word Embedding）也位于计算方，即使假设词表对其不可见，攻击者仍可通过接收到的输入（表示原始隐私词表上 Token 的序号信息）结合统计学方法和常见词表生成算法来重构隐私词表，进而恢复原始训练样本。2. 如果计算方仅处理经过词嵌入的 Token，由于攻击者拥有完整模型，他们可以利用这些中间值来重构并恢复原始 Token 内容。因此，在训练阶段，不能直接应用第五章的方法来防止训练者窥探训练数据的隐私信息。

实际上，第四章与第五章的研究目标是不同的。第四章假设训练阶段的计算方是恶意的，旨在防止计算方获取训练隐私数据；而第五章假设推断阶段的使用者是恶意的，目的在于缓解语言模型的记忆性，从而防止模型恢复原始训练数据。这两个章节的内容是正交的，没有直接的耦合关系。因此，可以将这两种方法结合起来，这样既能防止训练时计算方窥探隐私数据，又能防止推断时使用者利用模型反演攻击恢复训练隐私数据。这样的组合方法将在保护用户隐私和数据安全方面发挥更大的作用。

### 5.2.4 医学领域特定优化策略与评估指标

在进行医学文本生成任务的研究中，本章致力于开发特定于该领域的优化策略。为此，本章引入了一种专用的知识输入方法，该方法以开源医学教材作为主要知识来源。这些教材覆盖了医学的各个领域，包括基础医学、临床医学等，

由专业的医学人员编写和审查，因此其内容准确且可靠。

这些教材包含了丰富的医学知识，包括但不限于疾病的定义、症状、诊断、治疗、预防以及医学术语等。通过这些知识纳入模型的输入，本章的语言模型能够更深入地理解和生成与医学相关的文本，从而提高文本生成的质量。

同时，通过引入医学专业知识，本章的方法也有助于保护患者的隐私。具体来说，由于模型主要依赖于医学教材的公开知识，而非个体特定的隐私信息，因此在生成文本时，模型更少地依赖于训练数据中的隐私信息，从而降低了隐私泄露的风险。综上所述，在补充了医学教材语料后，本章的医学领域专用优化方法不仅提高了文本生成的质量，也有助于保护患者的隐私。

如图 5.2 所示，本章首先在诸如翻译、新闻、论坛等大量中文语料上预训练的基础上，以非隐私的医学教材语料内容进行微调，从而向模型引入医学领域的专业知识。接下来，在涉及患者隐私信息的医学文本数据上，本章采用了后续设计的选择性差分隐私优化器或选择性差分隐私解码算法。这些方法旨在缓解由于语言模型的记忆性所可能导致的隐私训练数据的泄露问题。整体上，这种策略保证了医学领域文本生成任务的高质量执行，同时也有效地维护了患者的隐私。

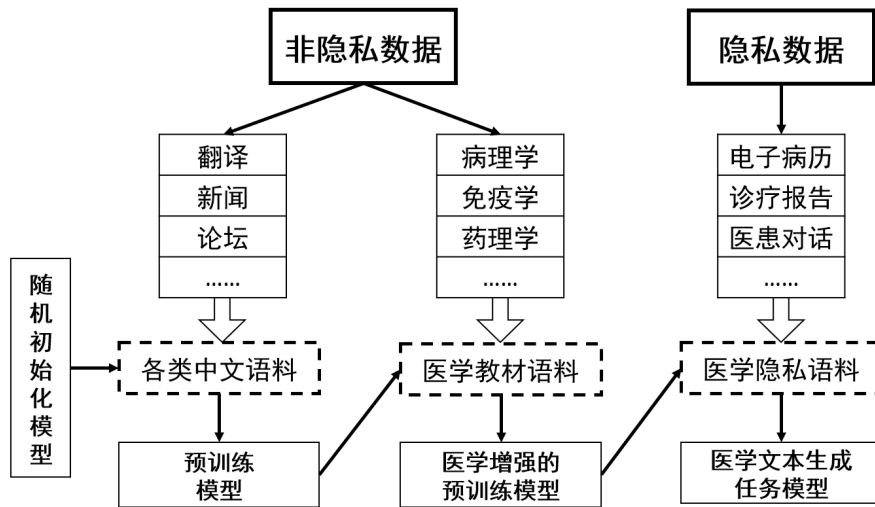


图 5.2 使用无隐私风险数据的微调模式

在进行医学文本生成任务的过程中，对生成的文本在科学性和准确性方面有着较高的要求。为此，本章设计了一个名为“医学文本生成科学性指标”的评估方法，如算法 5.1 所示。

该评估方法的输入包括一个语言模型  $M$ ，一份医学文本  $D$ ，一个策略函数  $F$ ，以及一个损失函数  $L$ 。其中，语言模型  $M$  被用于在医学文本上生成预测的标记分布，即 Logits；策略函数  $F$  则用于从医学文本中识别医学术语 Token，例如“双侧侧脑室显饱满”、“毛玻璃结节”、“癌胚抗原”等。

算法的核心部分是对每一篇文本  $x \in D$  进行处理。首先，利用语言模型  $M$  在  $x$  上生成 Logits。然后，根据隐私筛选函数  $F$  选取医学术语对应的 Logits，记

为  $Med\_Term\_Logits$ 。接下来, 将这些  $Logits$  与语言模型对相应医学术语的预测进行比较, 计算得到损失值并累加。在处理完所有的文本后, 计算总损失的平均值, 并将其转换为困惑度, 以此作为评估指标。

这种评估方法能够反映出语言模型在生成医学术语上的准确性, 从而为医学文本生成任务提供了一种可靠的评估手段, 帮助研究者理解和改进模型的表现。

---

**算法 5.1 医学文本生成科学性指标**


---

**输入:** 语言模型  $M$ , 医学文本  $D$ , 策略函数  $F$ , 损失函数  $L$

**输出:** 医学文本生成的科学性指标  $Evaluation\_Score$

```

1 for  $x \in D$  do
2     # 利用语言模型在医学文本上生成  $Logits$  列表
3      $Logits = M(x)$ 
4     # 选取医学术语对应的  $Logits$ 
5      $Med\_Term\_Logits = Logits[F(x)]$ 
6     # 计算每个医学术语的  $Loss$ 
7      $Loss = Loss + L(Med\_Term\_Logits, M[F(x)])$ 
8 end
9 # 计算平均损失
10  $Loss = Loss/|D|$ 
11 # 计算平均困惑度, 作为生成能力评估值  $Evaluation\_Score$ 
12  $Evaluation\_Score = \exp(Loss)$ 

```

---

### 5.3 基于差分隐私算法的推断结果隐私保护方案

#### 5.3.1 选择差分隐私定义

参考 2.1.1 节的介绍, 考虑一个由词表  $V$  中的多个 tokens 组成的文本序列, 即  $x = (x_1, \dots, x_n)$ , 其中  $x_i$  为第  $i$  个 token。语言建模的目标是, 通过应用链式法则  $\Pr(x) = \prod_{i=1}^n \Pr(x_i|x_{<i})$  构建分布的生成模型  $\Pr(x)$ 。当用参数  $\theta$  评估神经网络  $f$  时, 本节让  $f_\theta(x_i|x_{<i})$  表示 token  $x_i$  的概率。通过训练最小化负对数似然函数  $L(\theta) = -\log \prod_{i=1}^n f_\theta(x_i|x_{<i})$ , 来使得模型最大化训练集  $W$  中数据的概率。

由 2.2 中 DP 的定义, 若将 DP 直接部署在医学文本生成任务上, 其对所有内容进行保护, 即将所有记录视为敏感的。相关工作研究了在 NLP 领域使用 DP 的一些变体, 如个性化 DP<sup>[105]</sup> 和 onesided DP<sup>[106]</sup>。然而, 现有的隐私概念不允许给定记录中的不同属性具有不同的隐私级别, 特别是对于隐私属性极为稀疏的 NLP 任务。因此, 本文参考<sup>[49]</sup>, 引入了一种新的隐私概念——选择差异隐私,

即使用策略函数区分一个数据样本内部的私有和非私有属性，并保护一个数据样本的私有部分。

**定义 5.1** （策略函数）策略函数  $F : \tau \rightarrow \{0, 1\}^{n_r}$  表示一个记录  $r \in \tau$  的哪些属性是敏感的 ( $F(r)_i = 0$ ) 或不敏感的 ( $F(r)_i = 1$ )，其中  $n_r$  是  $r$  中的属性数量。其中， $n_r$  依赖于记录，而不是一个固定的数。

用户可以自由定义策略函数来编码具体的隐私规定，并根据具体应用保护任何敏感属性。受保护的敏感属性类型是无限的，可以是实体 (如姓名、电子邮件等)、上下文 (如健康相关信息、说话风格等)，等等。例如，用户可以设计一个保守的政策功能，在必要时保护选定的完整句子。策略函数的形式也是无限的，可以是神经网络、正则表达式等。

在语言建模的情况下，每个记录是一个文本序列  $x$ ，每个属性是  $x$  中的一个 token  $x_i$ ， $F(x)$  是一个位向量，表示哪些标记包含私有信息。本章在新的隐私概念下定义如下所示的相邻数据集。

**定义 5.2** （F-Neighbors） $D, D'$  是两个数据集， $F$  是一个策略函数。当且仅当  $\exists r \in D$  使得  $F(r)$  包含至少一个私有属性， $\exists r' \in D'$  使得  $F(r)$  和  $F(r')$  至少有一个私有属性不同，且  $D' = D/\{r\} \cup \{r'\}$  时，则称  $D'$  是  $D$  的相邻数据集。简记为  $D' \in N_F(D)$ 。

在这个定义下，包含“我的 ID 是 123”的数据集和包含“我的 ID 是 456”的数据集是相邻的。但带有“Hello there”的数据集和带有“Hi there”的数据集不是邻居，因为它们不包含隐私信息。

**定义 5.3** （选择差分隐私<sup>[49]</sup>）给定一个策略函数  $F$ 。对于  $\forall D, D' \in N_F(D)$  以及  $\forall T \subseteq R$ ，如果  $Pr[M(D) \subset T] \leq e^\epsilon Pr[M(D') \subset T] + \delta$ ，则称随机算法  $M : D \rightarrow R$  满足  $(F, \epsilon, \delta)$ -Selective DP。

本质上，选择性差分隐私也提供了类似于规范 DP 的不可区分性，但只针对记录中的敏感属性。只要保留敏感属性的隐私，选择性差分隐私并不约束非敏感属性的信息泄露。因此，选择性差分隐私在最坏的情况下 (即攻击者可能知道除目标敏感属性之外的所有信息) 保护敏感属性的隐私。

### 5.3.2 针对训练阶段的选择差分隐私优化器

本节介绍针对训练阶段的选择性差分隐私优化器。虽然使用选择性差分隐私机制的相关工作<sup>[49]</sup>已在 RNN 式的语言模型上实施，但 RNN 式的模型按照 token 出现的顺序从前往后滑动处理，如图 5.3 所示，这种情况下较容易分开处理隐私 tokens 与非隐私 tokens。而基于 Transformer 结构的模型中，所有 tokens 是并行处理的，因此无法直接将研究工作<sup>[49]</sup>中的 RNN 式处理方法应用于基于 Transformer 的模型。接下来，本部分将详细介绍针对训练阶段的选择性差分隐

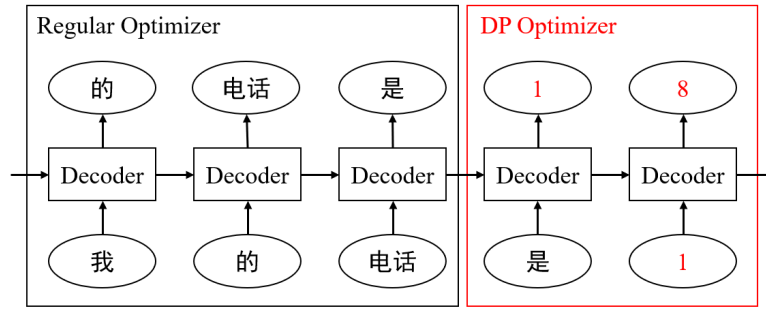


图 5.3 串行处理的选择差分隐私训练优化器

私优化器。

算法 5.2 概述了选择性差分隐私优化器中的步骤。本算法独特地针对了 Transformer 模型中的单一解码器架构，并开发了一种新的训练协议。这与常规的 RNN 模型从前向后的处理方式有着显著的区别。在选择性差分隐私优化器的实现中，该算法在 Word Embedding 阶段加入噪声，然后并行处理整个句子，而不是逐字处理。这是基于 Transformer 模型的自然特性，即其并行处理能力和对顺序无关性。

首先，通过引入策略函数  $F$ ，本算法将输入的训练批样本  $B$  映射到一个隐私矩阵  $M_p$ ，其中  $M_p$  指示了哪些 tokens 是私有信息。对于每个训练批样本，本算法对 Word Embedding 阶段以及 Encoder 输出阶段应用了噪声注入。具体来说，如果某个 token 的输出  $E_p$  与隐私矩阵  $M_p$  中的项对应，就在其上添加高斯噪声，同时还执行 L2 范数的裁剪以满足差分隐私的有界性需求。

接下来，算法对训练批样本进行传统的前向传播，输出逻辑值向量  $Logits$ 。然后，算法根据隐私矩阵  $M_p$ ，对模型参数进行选择性的差分隐私优化。对于非私有的 tokens，本算法简单地计算损失函数  $L(\theta)$  的梯度并进行参数更新。然而，对于私有的 tokens，算法首先计算损失函数的梯度  $g(k)$ ，对其进行 L2 范数裁剪，然后再加上与隐私级别成比例的高斯噪声。最后，算法使用含噪声的梯度进行模型参数的更新。这样，所有的私有变量都得到了保护，从而实现了在训练神经网络模型时对个体隐私的保护。



**算法 5.2 并行处理的选择差分隐私优化器**

**输入:** 训练批样本  $B$ , 策略函数  $F$ , 隐私矩阵  $M_p = F(B)$ , 损失函数  $L(\theta)$ , 超参数: 学习率  $\eta$ 、噪声指数  $\sigma$ 、梯度裁剪上界  $C$ 、批大小  $B$ , 模型参数

Model = {Token\_Embedding, Encoder, Vocab\_Projection}

**输出:** 更新后的模型参数 Model

```

1  for  $x \in B$  do
2       $E = \text{Token\_Embedding}(x)$ 
3      for  $x_k \in M_p$  do
4           $E_p = E[x_k]$ 
5           $E_p \leftarrow E_p / \max(1, \frac{\|E\|_2}{C})$ 
6           $E_p \leftarrow E_p + \sigma C \cdot N(0, I)$ 
7      end
8       $\text{Out\_E} = \text{Encoder}(E)$ 
9       $\text{Logits} = \text{Vocab\_Projection}(\text{Out\_E}[1 : -1])$ 
10 end
11 for  $x \in B$  do
12     if  $x_k \in M_p$  then
13          $g(x_k) \leftarrow \nabla_{\theta} L(\theta, \text{Logits}[x_k], x_k)$ 
14          $g(x_k) \leftarrow g(x_k) / \max(1, \frac{\|g\|_2}{C})$ 
15          $g(x_k) \leftarrow \frac{1}{|M_p|} (\sum_j g(x_k) + \sigma C \cdot N(0, I))$ 
16          $\theta \leftarrow \theta - \eta g(x_k)$ 
17     end
18     else
19          $\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta)$ 
20     end
21 end

```

**5.3.3 针对推断阶段的选择差分隐私解码算法**

如图 5.4 与算法 5.3 概述了针对推断阶段的解码算法。由于该场景下训练阶段使用原始包含隐私内容的数据集进行训练, 在推断阶段时, 为保护隐私内容, 需要对生成结果进行处理。具体来说, 在生成输出的过程中, 使用策略函数  $F$  对已生成的内容与当前模型输出的下一个 Token 进行判断, 若属于隐私内容, 则对 Logits 进行裁剪并加上由隐私预算与裁剪上界确定的高斯噪声, 并重新经过分词

器解码得到新的 Token。

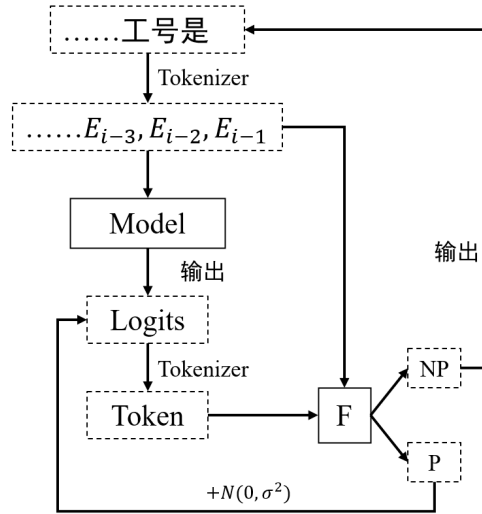


图 5.4 选择差分隐私解码算法

在文本生成任务中，生成的下一个单词通常是通过计算 Logits 值，再使用 Softmax 函数将 Logits 转化为概率分布来确定的。在差分隐私的场景下，需要对 Logits 进行处理以满足有界的全局敏感度。具体地，本章采用归一化处理将 Logits 限制在 0 到 1 之间。对于每个 Logit  $l_i$ ，计算其归一化后的值  $l'_i = \frac{l_i - l_{\min}}{l_{\max} - l_{\min}}$ ，其中  $l_{\min}$  和  $l_{\max}$  分别是 Logits 中的最小值和最大值。这样，归一化后的 Logits  $l'_i$  满足  $l'_i \in [0, 1]$ ，即全局敏感度  $C = 1$ 。

需要注意的是，在使用 Softmax 函数来确定下一个单词时，Softmax 函数不改变最大值的位置，因此选择  $\text{argmax}(\text{Softmax}(\text{Logits}))$  与  $\text{argmax}(\text{Logits})$  的结果相同。由于  $\text{Softmax}(\text{Logits})$  的输出结果在  $(0, 1)$  范围内，即有界，而 Logits 的取值范围是实数集，即无界，因此需要对 Logits 进行归一化处理以满足有界的差分隐私全局敏感度。

**算法 5.3 选择差分隐私解码算法**

**输入:** 输入解码的前缀  $P$ , 策略函数  $F$ , 裁剪上界  $C$ 、组大小  $L$ , 模型  $Model$ , 词表  $V$ , 分词器  $Tokenizer(\cdot)$

**输出:** 输入解码的前缀为  $Prefix$  时, 模型的输出结果  $Output$

```

1 # 将当前生成结果记为 CS, 初始赋值为输入前缀
2  $CS = P$ 
3 # 模型输出预测下一个 Token 的 Logits
4  $NT\_Logits = Model(CS)$ 
5 # Logits 确定最大概率的 index, 并由分词器解码成输出字符
6  $NT = Tokenizer(\argmax(\text{Softmax}(NT\_Logits)))$ 
7 # 若输出 <EOS> 符号终止流程
8 while  $NT \neq \text{<EOS>}$  do
9     # 若已生成内容与当前预测的下一个 Token 在策略函数  $F$  下是隐私
        内容, 则需要加噪处理
10    if  $F(CS, NT) == \text{True}$  then
11        # 对 Logits 进行裁剪
             $NT\_Logits \leftarrow NT\_Logits / \max(1, \frac{\|NT\_Logits\|_2}{C})$ 
12        # 加噪
             $NT\_Logits \leftarrow NT\_Logits + \sigma C \cdot N(0, I)$ 
13        # 在加噪的 Logits 下重新生成 Token
             $NT = Tokenizer(\argmax(\text{Softmax}(NT\_Logits)))$ 
14    end
15    # 将新 Token 加入当前生成结果 CS 中
16     $CS = CS + NT$ 
17    # 继续预测下一个 Token 的 Logits
18     $NT\_Logits = Model(CS)$ 
19    # 由分词器对 index 进行解码
20     $NT = Tokenizer(\argmax(\text{Softmax}(NT\_Logits)))$ 
21 end

```

## 5.4 安全性分析

本部分给出算法 5.2 的隐私分析。

对于任何给定的数据集  $D$ , 设  $D_{i,j}$  表示第  $i$  条记录的第  $j$  个属性。本章将梯度更新和隐藏状态抽象为以训练数据  $x$  和辅助信息  $w$  为输入的查询函数  $f(x, w)$ 。

本章引入  $w$  作为  $f$  的额外输入，以模拟梯度更新和隐藏状态对前几轮模型参数的依赖关系。具体而言，本章在数据集上定义以下两种类型的查询。

- 类型 1：函数  $f$  的输入只包含策略函数  $F$  判定为隐私信息的查询  $x$
- 类型 2：函数  $f$  的输入只包含策略函数  $F$  判定为非隐私信息的查询  $x$

由于算法 5.2 仅针对隐私信息进行保护，因此类型 2 的非隐私查询不会造成隐私损失。

下面的定理表明，如果一个类型 1 查询具有输出有界的属性，那么对于任意的输入，在查询中添加高斯噪声可以提供差分隐私保障。由于在策略函数  $F$  下的近邻数据集的非敏感部分可能是不同的，因此需要分析在任意辅助输入下的 DP 保证。

**定义 5.4** （隐私损失<sup>[53]</sup>）对于任意近邻数据集  $D$  与  $D'$ ，独立的辅助输入  $w$ ，算法  $M$  的输出结果为  $y$ ，定义隐私损失如下：

$$L(y; M, w, D, D') = \ln \frac{\Pr[M(w, D) = y]}{\Pr[M(w, D') = y]}. \quad (5.1)$$

**定理 5.1** 记  $\Delta_2 f = \max_{\{D, D'\}} \|f(D) - f(D')\|_2$  函数  $f$  的敏感度， $N(0, \sigma^2)$  为由参数  $\sigma$  控制的高斯分布，对于  $c^2 > 2\ln(1.25/\delta)$ ，具有  $\delta \geq c\Delta_2 f/\epsilon$  的高斯机制满足  $(\epsilon, \delta)$ -差分隐私。

**证明** 对于数据集  $D$  与函数  $f$ ，高斯机制计算结果为  $f(D) + N(0, \sigma^2)$ ，其中  $N(0, \sigma^2)$  为均值为 0，标准差为  $\sigma$  的高斯分布。考虑如下表达式：

$$\left| \ln \frac{e^{(-1/2\sigma^2)x^2}}{e^{(-1/2\sigma^2)(x+\Delta f)^2}} \right|, \quad (5.2)$$

这个式子是隐私损失的绝对值。假设数据集是  $D$ ，为证明高斯机制满足  $(\epsilon, \delta)$ -差分隐私，则需观察在  $D$  下与在其近邻数据集  $D'$  下，输出结果非常不同时的概率。上式中的分子描述了当数据集为  $D$  时看到  $f(D) + x$  的概率，分母对应的是当数据集为  $D'$  时看到这个相同值的概率，即该分式为非负的概率的比值，但其对数可能是负的。为方便起见，本部分研究隐私预算的绝对值。

$$\begin{aligned} \left| \ln \frac{e^{(-1/2\sigma^2)x^2}}{e^{(-1/2\sigma^2)(x+\Delta f)^2}} \right| &= \left| \ln e^{(-1/2\sigma^2)[x^2 - (x+\Delta f)^2]} \right| \\ &= \left| -\frac{1}{2\sigma^2} [x^2 - (x + \Delta f)^2] \right| \\ &= \left| -\frac{1}{2\sigma^2} [x^2 - (x^2 + 2x\Delta f + \Delta f^2)] \right| \\ &= \left| \frac{1}{2\sigma^2} (2x\Delta f + \Delta f^2) \right| \end{aligned} \quad (5.3)$$

。

上式结果在  $x < \sigma^2 \epsilon / \Delta f - \Delta f / 2$  时可以由  $\epsilon$  约束。为确保隐私损失在  $1 - \delta$  的概率下不超过隐私预算  $\epsilon$ ，需要

$$\Pr[|x| \geq \sigma^2 \epsilon / \Delta f - \Delta f / 2] < \delta。$$

去掉绝对值，即意味着需要找到  $\sigma$  使得

$$\Pr[x \geq \sigma^2 \epsilon / \Delta f - \Delta f / 2] < \delta / 2。$$

假设  $\epsilon \leq 1 \leq \Delta f$ ，利用

$$\Pr[x > t] \leq \frac{\sigma}{\sqrt{2\pi}} e^{-t^2/2\sigma^2}。$$

即需要

$$\begin{aligned} \frac{\sigma}{\sqrt{2\pi}} \frac{1}{t} e^{-t^2/2\sigma^2} < \delta/2 &\iff \sigma \frac{1}{t} e^{-t^2/2\sigma^2} < \sqrt{2\pi} \delta/2 \\ &\iff \frac{t}{\sigma} e^{t^2/2\sigma^2} > 2/\sqrt{2\pi} \delta \\ &\iff \ln(t/\sigma) + t^2/2\sigma^2 > \ln(2/\sqrt{2\pi} \delta)。 \end{aligned}$$

令  $t = \sigma^2 \epsilon / \Delta f - \Delta f / 2$ ，即有

$$\begin{aligned} \ln((\sigma^2 \epsilon / \Delta f - \Delta f / 2) / \sigma + (\sigma^2 \epsilon / \Delta f - \Delta f / 2)^2 / 2\sigma^2) &> \ln(2/\sqrt{2\pi} \delta) \\ &= \ln(\sqrt{\frac{2}{\pi}} \frac{1}{\delta})。 \end{aligned}$$

记  $\sigma = c \Delta f / \epsilon$ ，为了约束  $c$ ，记找到第一项非负的条件。

$$\begin{aligned} \frac{1}{\sigma} (\sigma^2 \frac{\epsilon}{\Delta f} - \frac{\Delta f}{2}) &= \frac{1}{\sigma} [(c^2 \frac{(\Delta f)^2}{\epsilon^2}) \frac{\epsilon}{\Delta f} - \frac{\Delta f}{2}] \\ &= \frac{1}{\sigma} [c^2 \frac{\Delta f}{\epsilon} - \frac{\Delta f}{2}] \\ &= \frac{\epsilon}{c \Delta f} [c^2 \frac{\Delta f}{\epsilon} - \frac{\Delta f}{2}] \\ &= c - \frac{\epsilon}{2c}。 \end{aligned}$$

由于  $\epsilon \leq 1$  且  $c \geq 1$ ，即  $c - \epsilon/c \geq c - 1/2$ ，故当  $c \geq 3/2$  时， $\ln(\frac{1}{\sigma} (\sigma^2 \frac{\epsilon}{\Delta f} - \frac{\Delta f}{2})) > 0$ 。接下来关注  $t^2/\sigma^2$  这一项。

$$\begin{aligned} (\frac{1}{2\sigma^2} \frac{\sigma^2 \epsilon}{\Delta f} - \frac{\Delta f}{2})^2 &= \frac{1}{2\sigma^2} [\Delta f (\frac{c^2}{\epsilon} - \frac{1}{2})]^2 \\ &= \frac{1}{2} [(\Delta f)^2 (\frac{c^2}{\epsilon} - \frac{1}{2})]^2 [\frac{\epsilon^2}{c^2 (\Delta f)^2}] \\ &= \frac{1}{2} (\frac{c^2}{\epsilon} - \frac{1}{2})^2 \frac{\epsilon^2}{c^2} \\ &= \frac{1}{2} (c^2 - \epsilon + \epsilon^2/4c^2)。 \end{aligned}$$

由于  $\epsilon \leq 1$  并且  $c \geq 3/2$ , 则  $c^2 - \epsilon + \epsilon^2/4c^2 \geq c^2 - 8/9$ , 故仅需

$$c^2 - 8/9 > 2 \ln(\sqrt{\frac{2}{\pi}} \frac{1}{\delta}).$$

换言之, 需要

$$c^2 > 2 \ln(\sqrt{\frac{2}{\pi}}) + 2 \ln(\frac{1}{\delta}) + \ln(e^{8/9}) = \ln(2/\pi) + \ln(e^{8/9}) + 2 \ln(\frac{1}{\delta}).$$

且由于  $(2/\pi)e^{8/9} < 1.55$ , 上式在  $c^2 > 2 \ln(1.25/\delta)$  时成立。

记  $R_1 = \{x \in R : |x| \leq c\Delta f/\epsilon\}$  与  $R_2 = \{x \in R : |x| > c\Delta f/\epsilon\}$ , 易知  $R = R_1 \cup R_2$ , 取  $S \subset R$ , 并记

$$S_1 = \{f(x) + x | x \in R_1\},$$

$$S_2 = \{f(x) + x | x \in R_2\},$$

则有

$$\begin{aligned} \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S] &= \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_1] \\ &\quad + \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_2] \\ &\leq \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_1] + \delta \\ &\leq e^\epsilon \left( \Pr_{x \sim N(0, \sigma^2)} [f(y) + x \in S_1] \right) + \delta. \end{aligned} \tag{5.4}$$

故高斯机制满足  $(\epsilon, \delta)$ -差分隐私。

■

**定理 5.2** 假设  $\max_{x,w} \|g(x, w)\| \leq C$ , 对于任意的  $w$ , 添加由  $C$  确定的高斯分布噪声可以保证  $g$  满足  $(\epsilon, \delta)$ -差分隐私, 其中  $\epsilon, \delta$  取决于  $C$  与  $\sigma$ 。形式化来说, 对于近邻数据集  $(x, x')$  以及任意的  $(w, w')$ , 有

$$\frac{P[g(x, w) + \Delta = r]}{P[g(x', w') + \Delta = r]} \leq e^\epsilon \quad w.p. \quad 1 - \delta.$$

算法 5.2 中对于梯度信息进行了裁剪, 即满足有界性, 由引理 5.1 知, 定理 5.3 成立。同样的, 算法 5.3 中对于 Logits 信息进行了裁剪, 即满足有界性, 由引理 5.1 知, 定理 5.3 成立。算法 5.2 对于非隐私内容  $B_{np,i}$  的更新属于类型 2, 这样的更新不会导致使用更多的隐私预算。对于隐私内容的更新 (包括梯度与隐藏状态 *Hidden*) 属于类型 1, 称其加上满足引理 5.1 中的高斯噪声后的数据为“模糊的”类 1 查询。算法 5.2 中的数据实际上由类型 2 与“模糊的”类型 1 构成。算法 5.3 中的数据同样由类型 2 与“模糊的”类型 1 构成。下面论证这样的组合满足  $(\epsilon, \delta)$ -差分隐私。

**定理 5.3** 记是  $f$  为由  $k$  个查询  $\{f_1, \dots, f_k\}$  构成的整体，其中  $f_i$  属于类型 1 或“模糊的”类型 2。给定策略函数  $F$ ，记  $f_{np}$  为类型 2， $f_p$  为“模糊的”类型 1。那么如果  $f_p$  满足  $(\epsilon, \delta)$ -差分隐私，则  $f$  满足  $(F, \epsilon, \delta)$ -Selective DP。

**证明** 考虑在策略函数  $F$  下的近邻数据集  $x$  与  $x'$ ，记  $x_i$  与  $x'_i$  是数据  $f_i$  中的子集。若  $f_i$  属于“模糊的”类型 1，则  $x_i$  只包含隐私内容；反之若  $f_i$  属于类型 2， $x_i$  只包含非隐私内容。由于  $x$  与  $x'$  是策略函数  $F$  下的紧邻数据集，即  $f_i$  属于“模糊的”类型 1。对于  $f$  的一个输出  $y_1, \dots, y_k$ ，有

$$\begin{aligned} & \frac{P[f_1(x_1, w_1) = y_1, \dots, f_1(x_k, w_k) = y_k]}{P[f_1(x'_1, w'_1) = y'_1, \dots, f_1(x'_k, w'_k) = y'_k]} \\ &= \prod_{f_i \in f_p} \frac{f_i(x_i, w_i) = y_i}{f_i(x'_i, w'_i) = y'_i} \end{aligned} \quad (5.5)$$

$$\leq e^\epsilon \quad w.p. \quad 1 - \delta. \quad (5.6)$$

式 5.5 是由于  $f_{np}$  不涉及隐私内容，并且每一个 token 的隐层表示与其对损失函数的贡献是独立的。式 5.6 中的不等式是因为  $f_p$  满足  $(\epsilon, \delta)$ -差分隐私的假设。 ■

通过这个证明，可以得出结论：在给定策略函数  $F$  的情况下，如果“模糊的”类型 1 查询  $f_p$  满足  $(\epsilon, \delta)$ -差分隐私，则整个查询  $f$  满足  $(F, \epsilon, \delta)$ -选择差分隐私。这意味着，通过在梯度上添加高斯噪声，可以确保模型训练过程满足选择差分隐私的要求，从而保护数据集中个体的隐私。

## 5.5 实验评估

### 5.5.1 攻击方式

本章执行两种类型的攻击：“诱饵”插入攻击和成员推断攻击。

#### (1) “诱饵”插入攻击

“诱饵”（Canary）插入攻击<sup>[107]</sup>是一种针对训练数据的隐私攻击方法，为一种定量评估意外记忆风险的测试方法。攻击者在训练数据集中插入一些特制的“诱饵”数据（即 Canary），这些数据通常具有特定的模式或特征，使其在整个数据集中独特而容易识别。通过将随机序列 Canary 插入训练数据集，并在此基础上训练模型。攻击者的目标是通过分析模型的输出结果，识别出模型是否泄露了这些插入的 Canary 数据。

在执行 Canary 插入攻击时，攻击者首先需要构建一些含有特定信息的诱饵数据。这些数据应该具有一定的复杂性，以便在模型生成的输出中能够辨别出其

所学习到的信息。攻击者将这些诱饵数据插入到训练数据集中，并记录下与这些诱饵数据相关的标签。然后，攻击者观察模型在特定输入下的输出结果，判断模型是否泄露了插入的 Canary 数据。

如果模型在生成输出时泄露了 Canary 数据，那么攻击者可以根据这些信息推断出模型的训练数据中可能包含了这些插入的诱饵数据。从而揭示了模型对训练数据的记忆情况，进而可能导致训练数据的隐私泄露。可以通过计算插入的 Canary 作为一种定量指标，以衡量模型潜在的隐私风险。其中定量的评估指标定义如下。

**定义 5.5** (Canary 暴露度<sup>[107]</sup>) 给定一个 Canary  $s[r]$ ，一个参数为  $\theta$  的模型，随机空间  $R$ ， $s[r]$  的暴露程度是： $Exposure_{\theta} = \log_2|R| - \log_2 Rank_{\theta}(s[r])$

训练后，计算所有可能实例化的 Canary 的模型困惑度，并将其按照困惑度排序。然后根据特定 Canary 序列的  $Rank_{\theta}(s[r])$  和所有可候选的数量  $|R|$  得到 Canary 的暴露量。从定义来看，当 Canary 在所有输出的排名越靠前，则暴露的程度就越高，而 rank 高意味着后面  $Rank_{\theta}(s[r])$  的值越低，则  $\log_2|R| - \log_2 Rank_{\theta}(s[r])$  的值越高。因此，若模型的 Canary 暴露度越高，则它记忆训练样本的可能性越高，即暴露程度越高。反之，若模型的 Canary 暴露度很低，则说明该模型更倾向于学习到模式而非具体的内容，即对训练数据的隐私保护程度较高。在本章设置中，实验显示了 10 个 Canary 中最高的 Canary 暴露。例如，如果一个 Canary 在 100 万个候选中排名第一，那么 Canary 的暴露量是 19.93。如图 5.5 所示，当在训练过程中插入的 Canary 为“我的单号是 #3006……”并在之前输入确定时，将 LM 输出的 logits 按照 Softmax 后的  $P$  概率值排序，找到与 Canary 匹配的 token 的 rank 排名，作为攻击的度量指标。

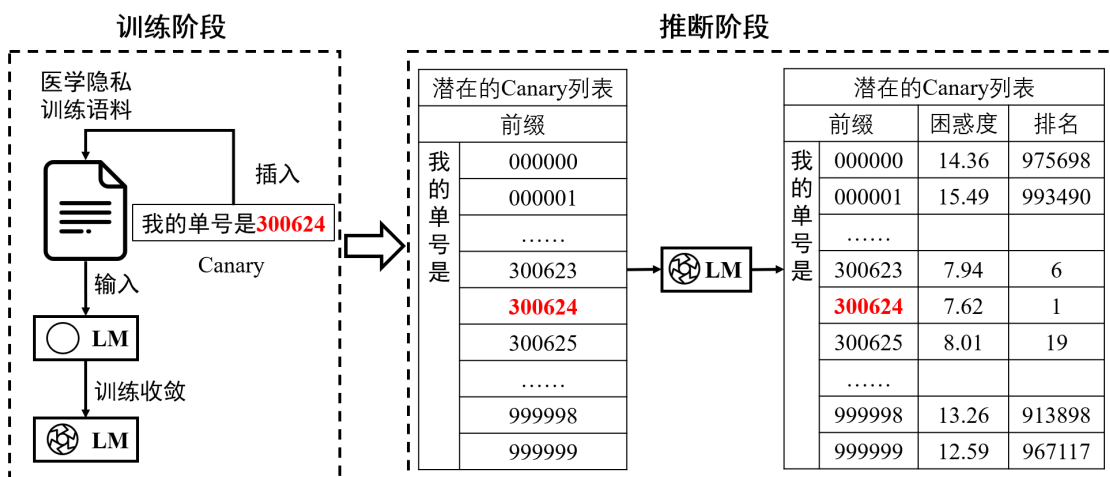


图 5.5 诱饵插入攻击

## (2) 模型反演攻击

与 3.3.1 节相同，本实验假设恶意攻击者对于模型执行黑盒攻击，即攻击者



只能从输入与模型的输出关系来推测隐私信息。

## 5.5.2 实验设置

### (1) 实验环境与模型设计

实验环境与 3.3.1 相同：CPU 为 AMD Ryzen 9 5900HX、32GB RAM、GPU 为 RTX3080-Laptop、操作系统为 Windows 11 64 位。

与 3.3.1 节中的设定相同，本节使用 Chinese Medical Dialogue Data (CMDD) 中文医疗对话数据集来训练 LM。其参数量为 81.9M，使用的词表大小为 21128，隐层维度为 768，12 层 GPT2Block。与相关工作的设定相同<sup>[49]</sup>，本章将电话号码、年龄、单号、药物计量、检测的定量结果等数字内容视为敏感信息，并使用正则表达式构建一个策略函数来检测它们。差分隐私中设置  $\epsilon = 0.5, \delta = \frac{1}{N} = 1e-6$  (为数据集大小  $N$  倒数的量级)。本章的实验基于 PyTorch 的差分隐私库<sup>[108]</sup>，以实现相关算法的设计。

与 4.2 节的设定相同，实验中在训练过程中固定了 Word Embedding。针对 Word Embedding 在应用差分隐私保护方案中的适应性，本章进行了实证研究。观察发现，模型中的 Word Embedding 值在 -0.87 到 1.66 之间，表现出明显的有界性。这种有界性的特性正符合差分隐私的基本需求，基于此，本实验在 Word Embedding 的阶段添加了噪声，以便符合差分隐私的规定。此项工作为神经网络训练中实现隐私保护打开了新的可能性。

### (2) 用于模型微调的医学数据集

在本章实验中，为了进一步提高模型在医学文本生成任务中的表现，本章采用了公开的医学教材<sup>①</sup>对预训练模型进行知识迁移和领域知识增强。这些教材涵盖了精神病学、临床药物治疗学、病理学与免疫学等多个医学领域的知识，与 CMDD 数据集中的科室信息（如内科、外科、肿瘤科等）相互补充。通过在这些医学教材的语料下进行微调，原预训练模型不仅可以获取关于疾病情况、原理、症状及治疗方面的严谨知识，还能够提高模型的准确性和科学性。这一步骤为医学文本生成任务提供了有针对性的信息补充，确保了模型生成结果的高质量 and 科学严谨性。

具体到本章的实验部分，本章选取了《神经病学》、《临床药物治疗学》、《病理学》、《免疫学》、《临床药物治疗学》以及《急诊内科学》这六本医学教材作为数据源。每一本书中，本章各自抽取约 300 条样本，每条样本的长度在 30 到 300 字之间，包含疾病定义、病因及发病机制、病理变化与临床症状等信息。这样的操作共产生了约 1800 条样本。这些样本具有较高的严谨性和正确性，来自于医学教材，因此可视为权威的高质量语料，将为本章的模型微调提供更丰富的

<sup>①</sup><https://github.com/scienceasdf/medical-books>

医学领域知识。

此外，与3.5.2节相同，本实验还采用带有隐私内容的 CMDD 数据集进行微调。

### (3) 实验评估方式

为对比本章提出的选择差分隐私的效果，本实验选择两个模型作为对比：

- a) 无隐私保护 (No\_DP)。这里直接使用原始的训练数据进行训练，可以视为隐私预算  $\epsilon = +\infty$ 。这种情况即为 3.3.1 节中在原始中文预训练模型基础上，利用 CMDD 数据上微调的模型。
- b) 对所有文本进行差分隐私保护 (All\_DP)。在这种情况下，把数据集所有的文本当成需要保护的对象。这可以视为选择差分隐私的最坏情况，即  $\forall d_i \in D$ ，策略函数  $F$  输出  $F(d_i) = 1$ 。

下面介绍上述两种攻击方式的实验设定。

#### (1) “诱饵”插入攻击

实验中，以“我的单号是 < 随机的 6 位数字 >”的形式随机生成了 5 个 Canary：“我的单号是 541684”、“我的单号是 946241”、“我的单号是 197462”、“我的单号是 678409”、“我的单号是 209118”。每个 Canary 独立测试，即一个 Canary 对应一个训练模型。每个实验中，在训练数据集中插入 10 次 Canary（这是一个常见的设定，如<sup>[49]</sup>），即在 3.2 节中定义的 10-清晰记忆。

本节以 3.3.1 节中的中文预训练模型为基础，在 CMDD 数据集上进行微调训练的。分别在 7 万条训练数据中插入上述 Canary 40 次（与研究工作<sup>[49]</sup>的插入比例相同，其中研究工作<sup>[49]</sup>在 17556 条训练数据中插入 10 次），并训练 25 个 epoch，计算在未加保护的情况下，模型的 Canary 暴露度。

#### (2) 模型反演攻击

与 3.3.2 节的设定相同，本实验使用随机采样的 10 个训练数据的前 20 个 token 作为前缀输入，使用训练样本推断攻击中的方式分别进行解码，测试其完整恢复训练数据的次数。具体来说，对于每个前缀，本节对上述每个前缀生成 10000 个解码结果，针对其进行平均统计（平均值为分数则向下取整）。

## 5.5.3 实验结果

### (1) 引入无隐私风险的医学教材语料微调的效果

这里采用 3.5.2 节中相同的训练验证测试集来验证引入域外无隐私风险的医学教材语料的效果。

表 5.1 的结果明确揭示了微调过程对于模型在特定领域的表现优化的作用。首先，观察到原始预训练模型在测试集上的困惑度是最高的，这主要因为该模型是基于大量的新闻、论坛、翻译等中文语料进行训练的，这些语料虽然涵盖了中

表 5.1 各训练方式下的模型困惑度比较

方式	困惑度
原始预训练模型	16.98
在 CMDD 上微调	7.97
在医学教材语料上微调	13.27
在医学教材语料与 CMDD 上微调	7.06

文场景的众多方面,但并未对医学领域进行专门关注,从而在医学领域的表现相对较差。

进一步的,本实验发现在 CMDD 上进行微调的效果优于仅在医学教材语料上进行微调,这主要源于 CMDD 的训练数据集与筛选出的测试集的分布更为接近,满足了独立同分布的假设,使得微调在此数据集上的效果更加显著。

然而,值得注意的是,仅在大约 1800 条医学教材语料上进行微调,模型的困惑度便有了显著的下降(从 16.98 减至 13.27)。这一结果明确展示了微调过程在模型知识转移和领域适应性提升方面的显著作用。医学教材语料质量高、内容严谨,信息密度大,即便在较小的数据量下,也能有效地为模型引入大量的医学领域知识,有力地推动了模型在医学领域的表现提升。

最后,本实验发现在同时考虑医学教材语料与 CMDD 训练数据进行微调的情况下,模型的表达能力进一步得到了提升。这一结果强化了医学教材语料在模型性能优化过程中的积极作用,也展示了在微调过程中同时考虑不同类型数据源的重要性。

以上结果从多个角度揭示了微调过程在模型领域性能优化过程中的重要作用,并为今后的模型优化策略提供了实证支持。

表 5.2 各训练方式下的模型的医学文本生成科学性指标比较

方式	医学文本生成科学性指标
原始预训练模型	17.45
在 CMDD 上微调	13.02
在医学教材语料上微调	9.77
在医学教材语料与 CMDD 上微调	9.36

最后,本节从医学文本生成科学性指标的角度对各训练方式下的模型进行了评估。如表5.2所示,模型在此项指标上的表现相对于整体测试集的困惑度来看略有提高。这一现象可以解释为,尽管预训练模型已经在大量中文语料上进行过训练,对于构成训练样本的主谓宾介词时间地点等通用文本部分有着良好的理解,但由于医学专业术语的数据量较少,预训练模型在处理这部分内容时学习的不够充分,因此在医学专业术语的生成上存在一定的挑战。

特别地,实验结果显示,仅在医学教材语料上进行微调的模型在医学文本生成科学性指标上的表现明显优于其他情况。这可以归因于医学教材语料的高质量和全面性,其中涵盖了大量常见的医学专业术语,使得模型在接受这些语料的训练后,能够更准确地生成医学专业术语。然而,模型在 CMDD 数据集上的微

调效果只是略优于原始预训练模型，这主要是因为 CMDD 数据集主要由医疗对话构成，并未专门针对医学术语进行解释和补充。

综上，这些实验结果深化了对微调过程在优化模型医学领域性能中的理解，并进一步强调了引入高质量医学数据进行微调的重要性。同时，这些发现为未来进一步提升医学文本生成模型的性能提供了实证依据，尤其强调了医学专业术语的准确生成在整体性能提升中的关键作用。

## (2) “诱饵”插入攻击

实验中，以“我的单号是 < 随机的 6 位数字 >”的形式随机生成了 5 个 Canary: “我的单号是 541684”、“我的单号是 946241”、“我的单号是 197462”、“我的单号是 678409”、“我的单号是 209118”。每个 Canary 独立测试，即一个 Canary 对应一个训练模型。每个实验中，在训练数据集中插入 10 次 Canary（这是一个常见的设定，如<sup>[49]</sup>），即在 3.2 节中定义的 10-清晰记忆。

与 3.5.2 节相同，本节也是以 3.3.1 节中的中文预训练模型为基础，在 CMDD 数据集上进行微调训练的。分别在 7 万条训练数据中插入上述 Canary 10 次，并训练 25 个 epoch，计算在未加保护的情况下，模型的 Canary 暴露度。

在输入的 Canary 为“我的单号是 541684”时，对没有使用任何隐私保护技术的模型执行攻击，其 Canary 暴露度如表 5.3 所示。其中，以“‘我的单号是’+前缀”表示实际输入模型的完整前缀。

**表 5.3 不同前缀长度下的语言模型的诱饵暴露度**

位数	前缀	排名	总可能数	Canary 暴露度
0	NULL	10718	1e6	2.32
1	5	483	1e5	5.64
2	54	91	1e4	5.57
3	541	21	1e3	6.78
4	5416	2	1e2	7.69
5	54168	2	1e1	6.54

从表 5.3 可以看出，在没有隐私保护时，前缀与原训练样本匹配度越高（这里指提供的前缀长度越长），其 Canary 暴露度越高，即模型越有可能恢复出原始数据，与预期相符。

**表 5.4 各模型的诱饵暴露度**

数字位数	No_DP	SDP_Train	SDP_Decode	All_DP
1	2.32	1.73	2.56	1.00
2	5.64	0.25	0.62	0.32
3	5.57	0.11	0.26	0.67
4	6.78	0.37	1.87	0.98
5	7.69	0.49	3.11	0.96
6	6.54	0.60	2.89	1.01

对于全部 5 组 Canary，其暴露度的平均情况如图 5.6 所示，其中 No\_DP 指在训练与推断阶段均未使用隐私保护技术的模型，All\_DP 指对所有训练样本使用

DP 训练的模型，SDP\_Train 指对训练样本使用上述实验设置中定义的策略函数的选择差分隐私训练优化器训练的模型，SDP\_Decode 指在训练阶段未使用 DP 而推断阶段使用选择差分隐私解码算法的模型。




图 5.6 各模型的诱饵暴露度

对于表5.4和图5.6 中的实验结果，可以进行以下深入的解释：

首先，SDP\_Train 在预测长度大于等于 3 时，其隐私保护效果优于 All\_DP。这是由于 SDP\_Train 和 All\_DP 在差分隐私噪声的处理上存在差异。All\_DP 对所有的 Token 都引入了差分隐私噪声，而 SDP\_Train 仅在数字 Token 上进行此类处理。在处理非隐私文本时，SDP\_Train 能保持正常的更新，但当处理包含数字 Token 的隐私文本时，由于噪声的影响，其 Loss 会突然增加，导致困惑度的上升。这使得模型在处理包含数值的信息时，难以记住具体的数值。例如，当模型在处理“单号是 134...”时，训练引入的差分隐私噪声可能等价于模型处理“单号是 79C...”，这使得 SDP\_Train 对长隐私序列的保护效果更好。因此，SDP\_Train 在处理长序列时的表现更优，特别是在预测长度较长的情况下，这种优势更加明显。

然后，SDP\_Decode 在处理长度为 4、5、6 的序列时，其暴露度较高。这是由于 SDP\_Decode 在解码阶段使用了原始的 No\_DP 模型的参数，其记忆性问题的在选择差分隐私解码算法的保护下，依然比其他 DP 算法更突出。为了获得更好的隐私保护效果，需要在与其他 DP 方法相比时，适当降低一些隐私预算。

最后，对于 No\_DP 模型，在处理较短的预测长度时，其暴露度与其他使用隐私保护的模型相差不大。然而，在处理长序列时，其暴露度迅速上升。这是由于语言模型的记忆性，在接收过目标诱饵样本作为输入训练后，模型在给定指定特殊前缀时，会为出现过的文本分配更高的概率值。这导致模型可能会逐字逐句地恢复出原始训练样本，从而增加了隐私泄露的风险。

针对模型的可用性，本节主要从模型在特定场景下的表达能力进行分析。困

表 5.5 各模型的困惑度

方式	困惑度
No_DP	7.06
All_DP	37.59
SDP_Train	13.42
SDP_Declare	8.77

惑度是一种有效的指标，用于衡量模型在应对未知数据时的性能，如表5.5所示。困惑度指标的变化主要与其计算方式有关。具体来说，困惑度可以被视为对测试数据集中每个句子的交叉熵损失的指数结果的平均值，即  $PPL(D) = \frac{1}{N} \sum_{i=1}^N \exp(\text{Loss}(\text{Model}(S_i)))$ ，其中  $D = S_1, S_2, \dots, S_N$ 。

在 CMDD 数据集上训练的损失通常在 2-4 之间。根据交叉熵的定义，模型平均损失为 4，即相当于在  $e^2 = 7.389$  个 Token 中随机猜测，而损失为 2 即相当于在  $e^4 = 54.598$  个 Token 中随机猜测。与词表大小 21128 相比，这样的预测结果是相对较好的。因此，预期的困惑度变化范围就从  $e^2 = 7.389$  变化到  $e^4 = 54.598$ ，这与观察到的困惑度范围相符。

通过对比不同模型的困惑度，可以看出 No\_DP 模型的困惑度最低，这意味着模型对于测试数据的“惊讶”程度最小，因此其生成效果最佳。相反，All\_DP 的效果最差，这是由于该方法将所有的文本都视为隐私信息，而忽视了其中大部分内容是非敏感的。

值得注意的是，SDP\_Train 相较于 SDP\_Declare 在 Canary 暴露度上低了 58%，但 SDP\_Declare 的困惑度却比 SDP\_Train 高了 53.0%。这是因为 SDP\_Declare 在训练过程中是正常的，只在推断阶段对生成的隐私内容加噪。而 SDP\_Train 虽然只针对隐私部分的内容加噪，但其在隐私内容的语义范畴上的噪声加入会降低模型的表达能力。另一方面，回到平均损失的空间下，SDP\_Train 与 SDP\_Declare 的平均损失分别为 2.609 与 3.059，这在图 3.6 所示的训练情况下，二者的差异并不显著。

基于以上内容，本节为选择性差分隐私训练和解码算法的优化提供了重要参考。同时，这些分析也对实际操作中如何保护隐私提供了指导意义。

### (3) 模型反演攻击

表 5.6 表示 No\_DP、All\_DP、SDP\_Train 与 SDP\_Declare 情况下的成员推断成功次数。从中可以看出使用 All\_DP 取得了 10000 个生成样本中没有任何成功恢复的效果，而 SDP\_Train 和 SDP\_Declare 仅比 No\_DP 的成功次数少一点，与 All\_DP 之间的差别还是很大。

这样的现象符合逻辑预期，并主要由以下原因导致：

- a) 在 5.5.2 节设定中，策略函数仅将数字部分视为隐私内容，并对其进行差分隐私处理，然而非数字内容占比很大，这可能导致模型更容易记住这些非

表 5.6 各模型的模型反演攻击成功次数

类型	成功次数
No_DP	14
All_DP	0
SDP_Train	13
SDP_Decode	11

数字内容。因此，虽然 SDP\_Train 与 SDP\_Decode 采取符合选择差分隐私定义的步骤进行处理，但是受保护的内容相对较少。成员推断攻击主要关注于某句子是否在训练语料中出现，所以 SDP\_Train 与 SDP\_Decode 相对于 No\_DP 的保护效果有限。相反，All\_DP 对所有样本进行差分隐私处理，所以在面对需要对样本整体内容进行验证的成员推断攻击时，其保护效果较好。

- b) 相对于预训练模型的语料，CMDD 训练语料较少。在微调过程中，由于医学文本语料具有特殊性，其分布与预训练语料的差异较大。在轮训练后，模型会逐渐记住这种特殊风格和具体数据内容。因此，在数据量较少的数据集上进行微调，模型更容易记住该数据集。

## 5.6 本章小结

本章首先对该场景下的系统模型与设计目标进行介绍，随后引入了选择差分隐私的概念，并针对训练与推断阶段分别设计了选择差分隐私隐私优化器与选择差分隐私解码算法，作为两种提供选择差分隐私的方式。在理论分析完这两种方式的安全性后，通过基于预训练模型在 CMDD 数据集上微调的实验，将各种设定下的结果进行对比分析，证明了本章提出的选择差分隐私优化器与选择差分隐私解码算法的优势。

## 第6章 总结与展望

本章对本文的工作进行一个全面的总结，并对未来的工作进行展望。

### 6.1 工作总结

本文从三个方面全面探讨了医学文本生成任务的隐私保护问题，为实际应用中的隐私保护提供了理论基础和实践指导。

#### (1) 医学文本生成任务的隐私攻击模型研究

本研究首先关注了医学文本生成任务在训练和推断阶段的隐私泄露风险，详细阐述了语言模型的生成过程及其记忆问题。针对公开的预训练模型执行了模型反演攻击，并提出了一些改进的攻击策略。同时，探讨了攻击者在训练与推断阶段可采用的攻击手段，通过实验分析了攻击效果，展示了语言模型记忆问题带来的隐私挑战。

#### (2) 医学文本生成任务训练阶段的隐私保护研究

针对医学文本生成任务训练阶段的隐私保护问题，本研究明确了系统模型和威胁模型，并设计了安全目标。扩展了基于秘密共享的协议，使其能够构建复杂的 Transformer 结构。通过多方安全计算手段来保障数据机密性，利用可信硬件 Intel SGX 确保执行过程的完整性。为提高协议的执行效率，设计了一个可验证的外包计算方法。通过安全性分析和实验验证，证明了该协议的有效性和高效性。

#### (3) 医学文本生成任务推断阶段的隐私保护研究

在推断阶段的隐私保护研究中，为防止攻击者执行模型反演攻击以恢复训练隐私数据，同时保持语言模型的性能效果，本研究基于选择差分隐私提出了两种缓解医学文本生成任务语言模型的技术。针对训练与推断阶段分别设计了选择差分隐私优化器与选择差分隐私解码算法，同时进行了隐私性分析，并通过实验说明了这两种保护方法的优势。

### 6.2 未来展望

本文对医学文本生成任务的隐私保护进行了深入研究，对于训练与推断阶段面临的攻击与效果进行了分析，并分别提出了隐私保护方法。尽管本文已经提出了相对安全的解决方案，但由于医学文本生成任务的复杂性，本文既要考虑语言模型相关的研究进展，也要跟进隐私保护技术的发展。此外，还受到公开数据集与预训练模型的制约。因此本文的工作在一些方面仍然存在局限性，需要进一



步的深入研究。以下的方向可以作为未来研究的指引:

(1) 研究更大规模语言模型的记忆问题

本文基于公开预训练模型,在医学文本数据集上进行微调训练,以得到针对该领域的语言模型。受困于训练资源以及训练语料,本文的语言模型相对于前沿的语言模型在规模上差距很多。因此,未来工作可以针对更大规模的语言模型进行记忆问题的分析,并使用本文提出的隐私保护算法来缓解其记忆问题。

(2) 提升多方安全计算函数协议的效率

由于在训练阶段中,数据隐私是最重要的考量,因此在满足同样隐私设定情况下提升协议效率是一项重要的问题。由于深度学习模型的特殊性,可以考虑在模型的部分层上执行一些参数量化与裁剪,以减少参数量与计算量。同时,针对该场景下的多方安全假设协议进行优化,减少各方之间的交互与执行时间。

(3) 探索引入差分隐私的位置对语言模型表达能力的影响

本文分别对训练阶段与推断阶段加入差分隐私来缓解医学文本生成任务的语言模型的记忆问题。而在相同的隐私预算与加噪方式下,在模型的执行流程中,如分词编码、词向量、编码器与解码器的各个模块、最后映射到词表的线性变换等环节中加入差分隐私,模型表现效果的区别(如在损失与困惑度等指标下)仍需进一步研究。通过对这些问题的深入探究,可以使隐私保护算法在保护隐私的同时,尽量降低对模型效果的影响。

## 参 考 文 献

- [1] GUAN J, LI R, YU S, et al. Generation of synthetic electronic medical record text[C]//IEEE International Conference on Bioinformatics and Biomedicine (BIBM). Madrid, Spain, 2018.
- [2] MELAMUD O, SHIVADE C. Towards automatic generation of shareable synthetic clinical notes using neural language models[J]. Proc. of Annual Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2019: 35-45.
- [3] 邓露, 胡珀, 李炫宏. 知识增强的生物医学文本生成式摘要研究[J]. 数据分析与知识发现, 2022, 6(11): 1-12.
- [4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [5] KENTON J D M W C, TOUTANOVA L K. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proc. of Annual Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). Minneapolis, USA, 2019.
- [6] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners [J]. OpenAI blog, 2019, 1(8): 9-33.
- [7] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.
- [8] KAIROUZ P, MCMAHAN H B, AVENT B, et al. Advances and open problems in federated learning[J]. Foundations and Trends® in Machine Learning, 2021, 14(1): 1-210.
- [9] DWORK C. Differential privacy: A survey of results[C]//Theory and Applications of Models of Computation. Xi'an, China, 2008.
- [10] CRAMER R, DAMGÅRD I B, et al. Secure multiparty computation[M]. Cambridge University Press, 2015.
- [11] ACAR A, AKSU H, ULUAGAC A S, et al. A survey on homomorphic encryption schemes: Theory and implementation[J]. ACM Computing Surveys (Csur), 2018, 51(4): 1-35.
- [12] SABT M, ACHEMLAL M, BOUABDALLAH A. Trusted execution environment: what it is, and what it is not[C]//IEEE Trustcom/BigDataSE/Ispa. Helsinki, Finland, 2015.
- [13] TANG H, GAN S, ZHANG C, et al. Communication compression for decentralized training [J]. Advances in Neural Information Processing Systems, 2018, 31: 7663--7673.
- [14] SUI D, CHEN Y, ZHAO J, et al. Feded: Federated learning via ensemble distillation for medical relation extraction[C]//Proc. of the 2020 conference on empirical methods in natural

- language processing (EMNLP). virtual conference, 2020.
- [15] LI T, SAHU A K, TALWALKAR A, et al. Federated learning: Challenges, methods, and future directions[J]. IEEE signal processing magazine, 2020, 37(3): 50-60.
- [16] CARLINI N, TRAMER F, WALLACE E, et al. Extracting training data from large language models.[C]//USENIX Security Symposium. virtual conference, 2021.
- [17] GEHMAN S, GURURANGAN S, SAP M, et al. RealToxicityPrompts: Evaluating Neural Toxic Degeneration in Language Models[C]//Findings of the Association for Computational Linguistics (ACL). virtual conference, 2020.
- [18] ZHANG C, IPPOLITO D, LEE K, et al. Counterfactual Memorization in Neural Language Models[EB/OL]. 2023. <https://openreview.net/forum?id=PvOo1sHKzf>.
- [19] BROWN H, LEE K, MIRESHGHALLAH F, et al. What Does it Mean for a Language Model to Preserve Privacy?[C]//ACM Conference on Fairness, Accountability, and Transparency. Chicago, USA, 2022.
- [20] GOLOVANOV S, KURBANOV R, NIKOLENKO S, et al. Large-scale transfer learning for natural language generation[C]//Proce. of the 57th Annual Meeting of the Association for Computational Linguistics. virtual conference, 2019.
- [21] DABRE R, CHU C, KUNCHUKUTTAN A. A survey of multilingual neural machine translation[J]. ACM Computing Surveys (CSUR), 2020, 53(5): 1-38.
- [22] FENG Q, HE D, LIU Z, et al. SecureNLP: A system for multi-party privacy-preserving natural language processing[J]. IEEE Transactions on Information Forensics and Security, 2020, 15: 3709-3721.
- [23] WAGH S, GUPTA D, CHANDRAN N. Securenn: 3-party secure computation for neural network training.[J]. Proc. Priv. Enhancing Technol., 2019, 2019(3): 26-49.
- [24] WANG S, ZHENG Y, JIA X. Secgnn: Privacy-preserving graph neural network training and inference as a cloud service[J]. IEEE Transactions on Services Computing, 2023: 1-16.
- [25] KUMAR N, RATHEE M, CHANDRAN N, et al. Cryptflow: Secure tensorflow inference [C]//IEEE Symposium on Security and Privacy (SP). virtual conference, 2020.
- [26] YUE X, DU M, WANG T, et al. Differential privacy for text analytics via natural text sanitization[C]//Findings of the Association for Computational Linguistics. virtual conference, 2021.
- [27] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J]. Advances in Neural Information Processing Systems, 2022, 35: 27730-27744.
- [28] OPENAI. GPT-4 Technical Report[EB/OL]. 2023. <https://cdn.openai.com/papers/gpt-4.pdf>.
- [29] MIRESHGHALLAH F, UNİYAL A, WANG T, et al. Memorization in NLP Fine-tuning

- Methods[EB/OL]. 2022. <https://arxiv.org/pdf/2205.12506.pdf>.
- [30] MOHASSEL P, ZHANG Y. Secureml: A system for scalable privacy-preserving machine learning[C]//IEEE symposium on security and privacy (SP). San Jose, USA, 2017.
- [31] CRAMER R, DAMGÅRD I, ESCUDERO D, et al. SPD: efficient MPC mod for dishonest majority[C]//Advances in Cryptology. Santa Barbara, USA, 2018.
- [32] WU S, LI G, CHEN F, et al. Training and Inference with Integers in Deep Neural Networks [C]//International Conference on Learning Representations. Vancouver, Canada, 2018.
- [33] AGRAWAL N, SHAHIN SHAMSABADI A, KUSNER M J, et al. QUOTIENT: two-party secure neural network training and prediction[C]//Proc. of the ACM SIGSAC Conference on Computer and Communications Security. London, UK, 2019.
- [34] 董业, 侯炜, 陈小军, 等. 基于秘密分享和梯度选择的高效安全联邦学习[J]. 计算机研究与发展, 2020, 57(10): 2241-2250.
- [35] PATRA A, SCHNEIDER T, SURESH A, et al. ABY2.0: Improved Mixed-Protocol Secure Two-Party Computation.[C]//USENIX Security Symposium. virtual conference, 2021.
- [36] MOHASSEL P, RINDAL P. ABY3: A mixed protocol framework for machine learning[C]//Proc. of the ACM SIGSAC conference on computer and communications security. Toronto, Canada, 2018.
- [37] DEMMLER D, SCHNEIDER T, ZOHNER M. ABY-A framework for efficient mixed-protocol secure two-party computation.[C]//Network and Distributed System Security Symposium. San Diego, USA, 2015.
- [38] CHAUDHARI H, RACHURI R, SURESH A. Trident: Efficient 4pc framework for privacy preserving machine learning[C]//Network and Distributed Systems Security (NDSS). San Diego, USA, 2019.
- [39] SHEN L, DONG Y, FANG B, et al. ABNN2: secure two-party arbitrary-bitwidth quantized neural network predictions[C]//Proc. of the 59th ACM/IEEE Design Automation Conference. San Francisco, USA, 2022.
- [40] GAO C, YU J. SecureRC: A system for privacy-preserving relation classification using secure multi-party computation[J]. Computers & Security, 2023, 128: 103-142.
- [41] HARDT M, PRICE E. The noisy power method: A meta algorithm with applications[J]. Advances in neural information processing systems, 2014, 27.
- [42] ABADI M, CHU A, GOODFELLOW I, et al. Deep learning with differential privacy[C]//Proc. of the ACM SIGSAC conference on computer and communications security. Vienna, Austria, 2016.
- [43] PAPERNOT N, ABADI M, ERLINGSSON Ú, et al. Semi-supervised knowledge transfer for deep learning from private training data[C]//International Conference on Learning Rep-

- resentations. Toulon, France, 2017.
- [44] 梁文娟, 陈红, 赵素云, 等. 一种面向数据流 Top-K 繁模式发布的差分隐私保护方案[J]. 计算机学报, 2021, 44(4): 741-760.
- [45] 史鼎元, 王晏晟, 郑鹏飞, 等. 面向企业数据孤岛的联邦排序学习[J]. 软件学报, 2021, 32(3): 669-688.
- [46] BOMBARI S, ACHILLE A, WANG Z, et al. Towards Differential Relational Privacy and its use in Question Answering[EB/OL]. 2022. <https://arxiv.org/pdf/2203.16701.pdf>.
- [47] ZHAO X, LI L, WANG Y X. Provably Confidential Language Modelling[C]//Proc. of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Seattle, USA, 2022.
- [48] WU X, LI F, KUMAR A, et al. Bolt-on Differential Privacy for Scalable Stochastic Gradient Descent-Based Analytics[C]//Proc. of the ACM International Conference on Management of Data. Chicago, USA, 2017.
- [49] SHI W, CUI A, LI E, et al. Selective differential privacy for language modeling[C]//Proc. of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Seattle, USA, 2022.
- [50] BU Z, WANG Y X, ZHA S, et al. Differentially Private Bias-Term only Fine-tuning of Foundation Models[C]//Workshop on Trustworthy and Socially Responsible Machine Learning. virtual conference, 2022.
- [51] DINH M H, FIORETTO F. Context-Aware Differential Privacy for Language Modeling [EB/OL]. 2023. <https://arxiv.org/pdf/2301.12288.pdf>.
- [52] DWORK C, KENTHAPADI K, MCSHERRY F, et al. Our data, ourselves: Privacy via distributed noise generation[C]//Advances in Cryptology. Santa Barbara, USA, 2006.
- [53] DWORK C, ROTH A, et al. The algorithmic foundations of differential privacy[J]. Foundations and Trends® in Theoretical Computer Science, 2014, 9(3–4): 211-407.
- [54] MCSHERRY F, TALWAR K. Mechanism design via differential privacy[C]//IEEE Symposium on Foundations of Computer Science. Providence, USA, 2007.
- [55] DWORK C, MCSHERRY F, NISSIM K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of Cryptography. New York, USA, 2006.
- [56] DWORK C, MCSHERRY F, NISSIM K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of Cryptography. New York, USA, 2006.
- [57] MCSHERRY F, TALWAR K. Mechanism design via differential privacy[C]//IEEE Symposium on Foundations of Computer Science. Providence, USA, 2007.
- [58] SENNRICH R, HADDOW B, BIRCH A. Neural machine translation of rare words with subword units[C]//54th Annual Meeting of the Association for Computational Linguistics.

- Berlin, Germany, 2016.
- [59] DEUTSCH P, GAILLY J L. Zlib compressed data format specification version 3.3[R]. 1996.
- [60] MOHASSEL P, RINDAL P. Aby3: A mixed protocol framework for machine learning[C]//Proc. of the ACM SIGSAC conference on computer and communications security. Toronto, Canada, 2018.
- [61] LEE T, LIN Z, PUSHK S, et al. Occlumency: Privacy-preserving remote deep-learning inference using SGX[C]//The 25th Annual International Conference on Mobile Computing and Networking. Los Cabos, Mexico, 2019.
- [62] HUA W, UMAR M, ZHANG Z, et al. Guardnn: Secure DNN accelerator for privacy-preserving deep learning[EB/OL]. 2020. <https://arxiv.org/pdf/2008.11632.pdf>.
- [63] HASHEMI H, WANG Y, ANNAVARAM M. Darknight: A Data Privacy Scheme for Training and Inference of Deep Neural Networks[EB/OL]. 2021. <https://arxiv.org/pdf/2006.01300.pdf>.
- [64] BRASSER F, MÜLLER U, DMITRIENKO A, et al. Software grand exposure: SGX cache attacks are practical[C]//USENIX Workshop on Offensive Technologies. Vancouver, Canada, 2017.
- [65] HÄHNEL M, CUI W, PEINADO M. High-resolution side channels for untrusted operating systems[C]//USENIX Annual Technical Conference. Vancouver, Canada, 2017.
- [66] GÖTZFRIED J, ECKERT M, SCHINZEL S, et al. Cache attacks on Intel SGX[C]//Proc. of the 10th European Workshop on Systems Security. Belgrade, Serbia, 2017.
- [67] MOGHIMI A, IRAZOQUI G, EISENBARTH T. Cachezoom: How SGX amplifies the power of cache attacks[C]//Cryptographic Hardware and Embedded Systems. Taipei, China, 2017.
- [68] SCHWARZ M, WEISER S, GRUSS D, et al. Malware guard extension: Using SGX to conceal cache attacks[C]//Detection of Intrusions and Malware, and Vulnerability Assessment. Bonn, Germany, 2017.
- [69] WANG W, CHEN G, PAN X, et al. Leaky cauldron on the dark land: Understanding memory side-channel hazards in SGX[C]//Proc. of the 2017 ACM SIGSAC Conference on Computer and Communications Security. Dallas, USA, 2017.
- [70] CHEN Z, OSWALD D F. Pmfault: Faulting and bricking server CPUs through management interfaces[EB/OL]. 2023. <https://arxiv.org/pdf/2301.05538.pdf>.
- [71] QIU P, WANG D, LYU Y, et al. Voltjockey: A new dynamic voltage scaling-based fault injection attack on Intel SGX[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2021, 40: 1130-1143.
- [72] GIRIJA S S. Tensorflow: Large-scale machine learning on heterogeneous distributed systems [J]. Software available from tensorflow, 2016, 39(9-42).

- [73] GAO T, FISCH A, CHEN D. Making pre-trained language models better few-shot learners [C]//Joint Conference of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. virtual conference, 2021.
- [74] WEI J, TAY Y, BOMMASANI R, et al. Emergent abilities of large language models[EB/OL]. 2022. <https://arxiv.org/pdf/2206.07682.pdf>.
- [75] XU F F, ALON U, NEUBIG G, et al. A systematic evaluation of large language models of code[C]//Proc. of the 6th ACM SIGPLAN International Symposium on Machine Programming. San Diego, USA, 2022.
- [76] BEIMEL A. Secret-sharing schemes: A survey[C]//Coding and Cryptology. Qingdao, China, 2011.
- [77] SHAMIR A. How to share a secret[J]. Communications of the ACM, 1979, 22(11): 612-613.
- [78] COSTAN V, DEVADAS S. Intel SGX Explained[EB/OL]. 2016. <https://eprint.iacr.org/2016/086>.
- [79] NILSSON A, BIDEH P N, BRORSSON J. A survey of published attacks on Intel SGX [EB/OL]. 2020. <https://arxiv.org/pdf/2006.13598.pdf>.
- [80] RAMACHANDRAN P, AGARWAL S, MONDAL A K, et al. S++: A fast and deployable secure-computation framework for privacy-preserving neural network training[EB/OL]. 2021. <https://arxiv.org/pdf/2101.12078.pdf>.
- [81] CATRINA O, SAXENA A. Secure computation with fixed-point numbers[C]//Financial Cryptography and Data Security. Tenerife, Canary Islands, 2010.
- [82] MOTWANI R, RAGHAVAN P. Randomized algorithms[J]. ACM SIGACT News, 1995, 26(3): 48-50.
- [83] CANETTI R. Universally composable security: A new paradigm for cryptographic protocols [C]//Proc. 42nd IEEE Symposium on Foundations of Computer Science. Washington, USA, 2001.
- [84] CANETTI R, COHEN A, LINDELL Y. A simpler variant of universally composable security for standard multiparty computation[C]//Advances in Cryptology. Santa Barbara, USA, 2015.
- [85] LINDELL Y. How to simulate it—a tutorial on the simulation proof technique[J]. Tutorials on the Foundations of Cryptography: Dedicated to Oded Goldreich, 2017: 277-346.
- [86] BOGDANOV D, LAUR S, WILLEMSON J. Sharemind: A framework for fast privacy-preserving computations[C]//Computer Security. 2008.
- [87] DOERNER J, KONDI Y, LEE E, et al. Threshold ecDSA from ecDSA assumptions: The multiparty case[C]//IEEE Symposium on Security and Privacy (SP). San Francisco, USA, 2019.
- [88] BEAVER D. Efficient multiparty protocols using circuit randomization[C]//Advances in

- Cryptology. Santa Barbara, USA, 1992.
- [89] CATRINA O, SAXENA A. Secure computation with fixed-point numbers[C]//Financial Cryptography and Data Security. Tenerife, Canary Islands, 2010.
  - [90] MISHRA P, PODDAR R, CHEN J, et al. Oblix: An efficient oblivious search index[C]//IEEE Symposium on Security and Privacy (SP). San Francisco, USA, 2018.
  - [91] CHEN S, ZHANG X, REITER M K, et al. Detecting privileged side-channel attacks in shielded execution with déjà vu[C]//Proc. of the ACM on Asia Conference on Computer and Communications Security. Abu Dhabi, United Arab Emirates, 2017.
  - [92] COSTAN V, LEBEDEV I A, DEVADAS S. Sanctum: Minimal hardware extensions for strong software isolation.[C]//USENIX Security Symposium. Vancouver, Canada, 2016.
  - [93] GRUSS D, LETTNER J, SCHUSTER F, et al. Strong and efficient cache side-channel protection using hardware transactional memory.[C]//USENIX Security Symposium. Vancouver, Canada, 2017.
  - [94] KIM D, JANG D, PARK M, et al. SGX-LEGO: Fine-grained SGX controlled-channel attack and its countermeasure[J]. computers & security, 2019, 82: 118-139.
  - [95] KOGLER A, GRUSS D, SCHWARZ M. Minefield: A software-only protection for SGX enclaves against DVFS attacks[C]//USENIX Security Symposium. Boston, USA, 2022.
  - [96] LANG F, WANG W, MENG L, et al. Mole: Mitigation of side-channel attacks against SGX via dynamic data location escape[J]. Proc. of the 38th Annual Computer Security Applications Conference, 2022: 978-988.
  - [97] GINER L, KOGLER A, CANELLA C, et al. Repurposing segmentation as a practical LVI-NULI mitigation in SGX[C]//USENIX Security Symposium. Boston, USA, 2022.
  - [98] LEE D, KOHLBRENNER D, SHINDE S, et al. Keystone: An open framework for architecting trusted execution environments[C]//Proc. of the Fifteenth European Conference on Computer Systems. Heraklion, Greece, 2020.
  - [99] JIA Y, LIU S, WANG W, et al. {HyperEnclave}: An open and cross-platform trusted execution environment[C]//USENIX Annual Technical Conference. Carlsbad, USA, 2022.
  - [100] TAN S, KNOTT B, TIAN Y, et al. Cryptgpu: Fast privacy-preserving machine learning on the gpu[C]//IEEE Symposium on Security and Privacy (SP). San Francisco, USA, 2021.
  - [101] ZHANG X, LIU S, ZHANG R, et al. Fixed-point back-propagation training[C]//Proc. of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA, 2020.
  - [102] FANG J, SHAFIEE A, ABDEL-AZIZ H, et al. Post-training piecewise linear quantization for deep neural networks[C]//European Conference on Computer Vision (ECCV). virtual conference, 2020.



- [103] GUPTA M, VARMA V, DAMANI S, et al. Compression of deep learning models for NLP [C]//Proc. of the 29th ACM International Conference on Information & Knowledge Management. virtual conference, 2020.
- [104] ZAFRIR O, BOUDOUKH G, IZSAK P, et al. Q8bert: Quantized 8bit bert[C]//Energy Efficient Machine Learning and Cognitive Computing-NeurIPS Edition (EMC2-NIPS). Vancouver, Canada, 2019.
- [105] EBADI H, SANDS D, SCHNEIDER G. Differential privacy: Now it's getting personal[J]. Acm Sigplan Notices, 2015, 50(1): 69-81.
- [106] KOTSOGIANNIS I, DOUDALIS S, HANEY S, et al. One-sided differential privacy[C]//IEEE 36th International Conference on Data Engineering (ICDE). Dallas, USA, 2020.
- [107] CARLINI N, LIU C, ERLINGSSON Ú, et al. The secret sharer: Evaluating and testing unintended memorization in neural networks.[C]//USENIX Security Symposium. Santa Clara, Germany, 2019.
- [108] YOUSEFPOUR A, SHILOV I, SABLAYROLLES A, et al. Opacus: User-Friendly Differential Privacy Library in PyTorch[C]//Conference and Workshop on Neural Information Processing Systems Workshop Privacy in Machine Learning. virtual conference, 2021.

## 致 谢

在完成本论文的过程中，我得到了众多人士的无私支持和慷慨帮助，我在此向他们表达深深的感谢。

首要之中，我想表达对我的导师张驰老师的衷心感谢。张老师始终以慷慨的耐心和关心支持我，他在我选择研究方向的过程中提供指导，而在学术论文的撰写过程中则给予我宝贵的意见和建议。他赋予我充分的学术自由，鼓励我自由探索和进行实验。同时，我也要感谢师兄、王师兄、茹师兄、任师兄与张师姐表示感谢，他们在我的研究旅程中提供了许多有益的建议和帮助。

此外，我要对我的家人和朋友们表示深深的谢意，他们始终如一的支持和鼓励，赋予我克服困难的信心和勇气。同时，我感激商汤、阿里、佳期与明沚的主管、员工以及实习伙伴们，他们的培养和影响促使我的学术研究和工程能力得到大幅提升。

最后，我要向学校的所有老师和工作人员表示感谢，他们在我学习和生活中的支持和关怀是我前进的重要力量。

我再次向所有在我成长和学习道路上给予我支持的人们表示感谢，是你们的陪伴让我有力量走到了今天。

## 在读期间发表的学术论文与取得的研究成果

### 已发表会议论文

1. Y. Jie, Y. Ren, Q. Wang, Y. Xie, C. Zhang, L. Wei and J. Liu, “Multi-Party Secure Computation with Intel SGX for Graph Neural Networks”, IEEE International Conference on Communications (ICC), Seoul, South Korea, 2022, pp. 528-533, doi: 10.1109/ICC45855.2022.9839282.
2. Y. Ren, Y. Jie, Q. Wang, B. Zhang, C. Zhang and L. Wei, “A Hybrid Secure Computation Framework for Graph Neural Networks”, International Conference on Privacy, Security and Trust (PST), Auckland, New Zealand, 2021, pp. 1-6, doi: 10.1109/PST52912.2021.9647843.
3. S. Ru, B. Zhang, Y. Jie, C. Zhang, L. Wei and C. Gu, “Graph Neural Networks for Privacy-Preserving Recommendation with Secure Hardware”, International Conference on Networking and Network Applications (NaNA), Lijiang, China, 2021, pp. 395-400, doi: 10.1109/NaNA53684.2021.00075.